INSTITUTO NACIONAL DE ESTATÍSTICA
STATISTICS PORTUGAL

» *Data Analytics* com Aplicações

Pedro Campos
João Lopes

DMSI / ME

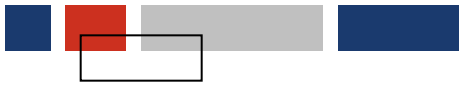

Dezembro de 2019

Índice

Índice

Modelos

» Modelos exploratórios

- modelos não-supervisionados (não têm variável-resposta);
- associações e agrupamentos.

» Modelos preditivos

- modelos supervisionados (têm variável-resposta);
- relações entre variáveis que permitem fazer previsões.

Modelos

» Modelos exploratórios

- Regras de Associação
- Agrupamento (e.g. Hierárquico, K-*Means*)

» Modelos preditivos

- Distâncias (e.g. *k-Nearest Neighbour*)
- Probabilísticos (e.g. Redes *Bayesianas*)
- Procura (e.g. Árvores de Decisão e Regras de Decisão)
- Otimização (e.g. Redes Neuronais, *Support Vector Machine*)

Modelos preditivos

» Visão Geral

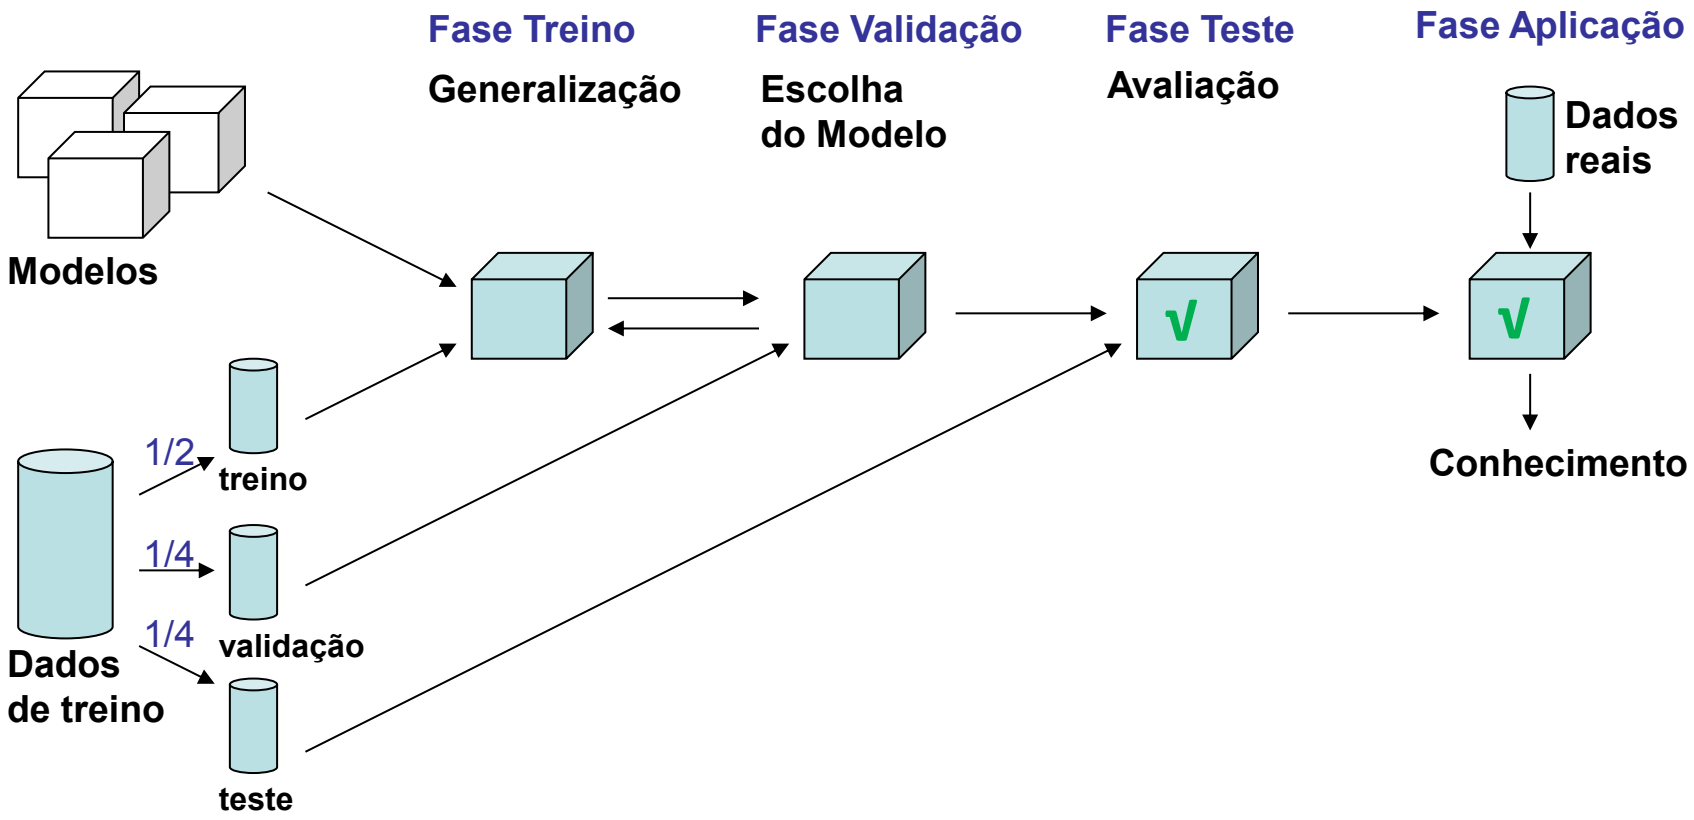

Modelos preditivos

» Conceitos

- variável-resposta e variáveis-preditivas;
- problemas no conjunto de treino (e.g. ruído, dados em falta, …);
- *curse of dimensionality*;
- generalização (*lazy learners* vs. *eager learners*);
- precisão e exactidão;
- sub-ajustamento vs. sobre-ajustamento;
- critérios de paragem de um algoritmo;
- máximos locais e máximo global.

Modelos preditivos

» Conceitos: conjunto de treino

e.g.

- variável-resposta (qualitativa)
- 2 variáveis-preditivas (x_1 e x_2)

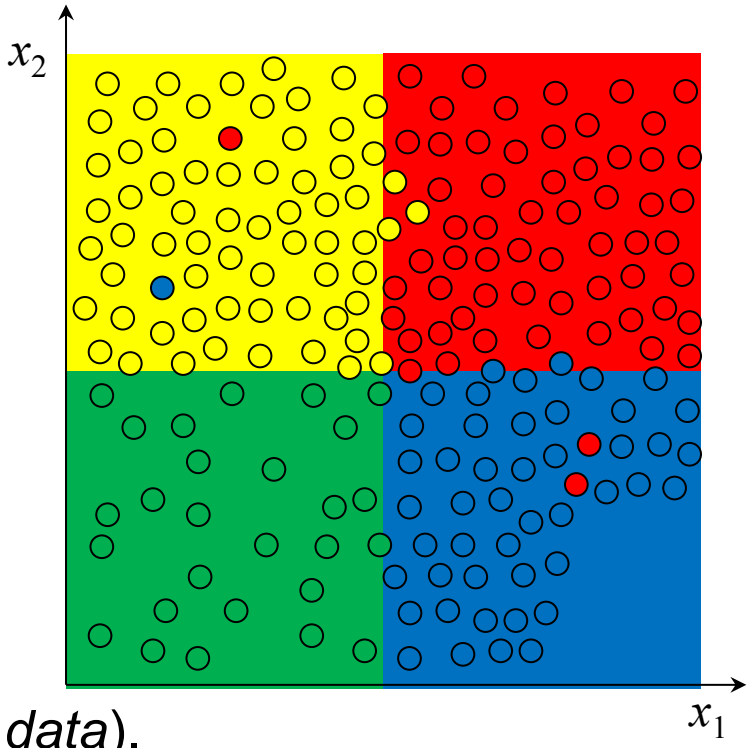

- ruído nos dados (*noisy data*);
- dados em falta (*missing data*);
- exemplos fronteiriços (*borderline*);
- dados desequilibrados (*imbalanced data*).

Modelos preditivos

» Conceitos: *curse of dimensionality*

+ variáveis => + informação

=> + espaço a explorar

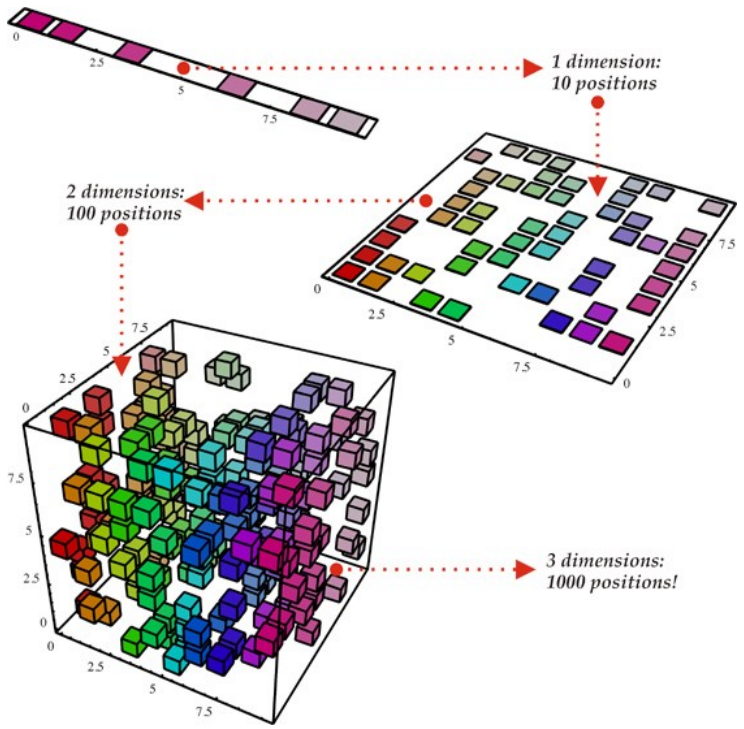

Y. Bengio (2008) “CurseDimensionality.jpg”

Modelos preditivos

» Conceitos: generalização

- *lazy learner*: previsões usam conjunto de treino;

- *eager learner*: previsões usam generalizações.

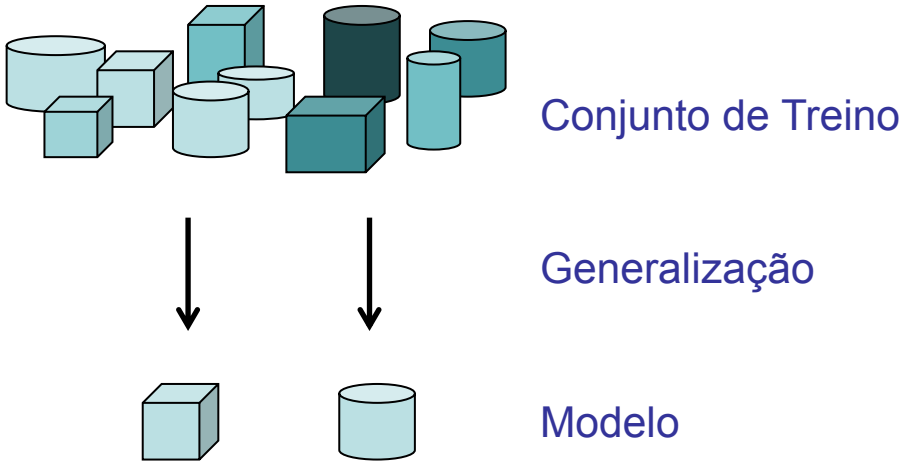

Modelos preditivos

» Conceitos: precisão e exactidão

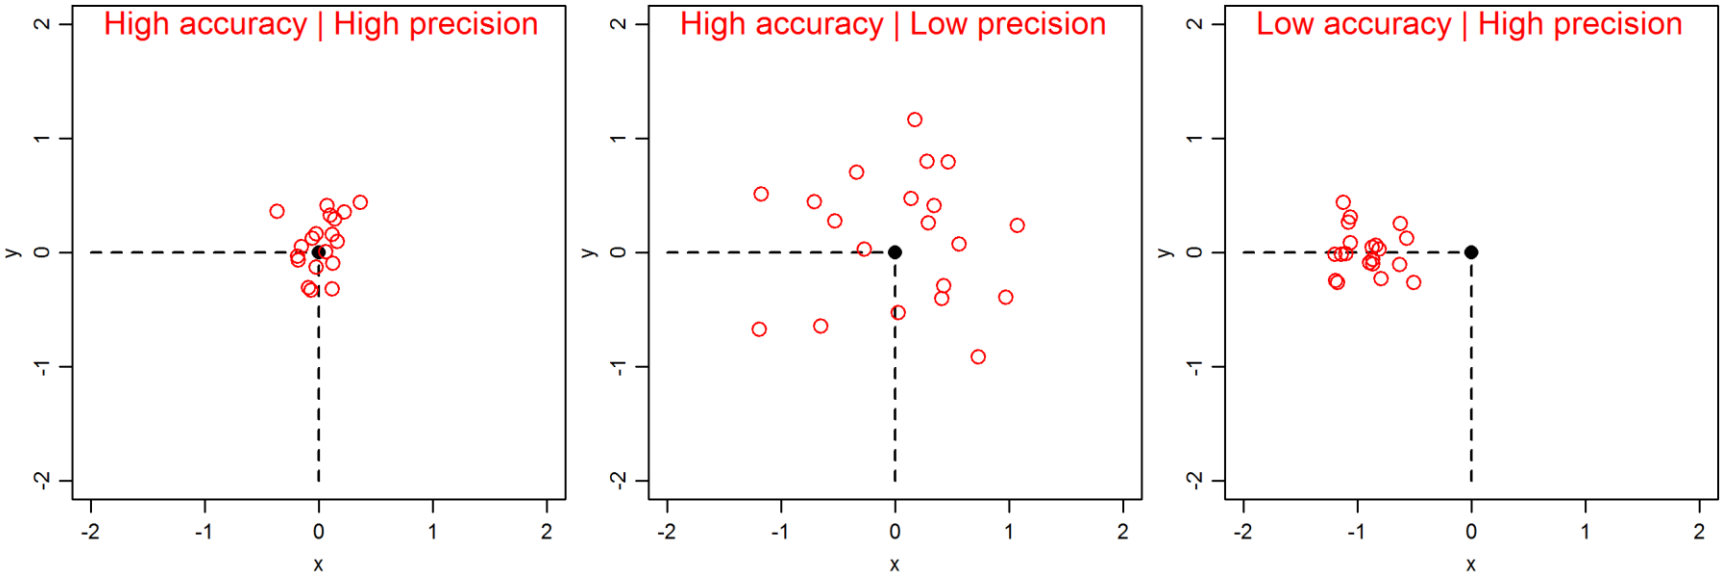

- Os conceitos precisão e exactidão não são antagónicos;

- Mas é comum que para obter uma maior precisão se tenha que "sacrificar" a exactidão (e.g. k-NN, Árvores de decisão).

Modelos preditivos

» Conceitos: sub- e sobre-ajustamento

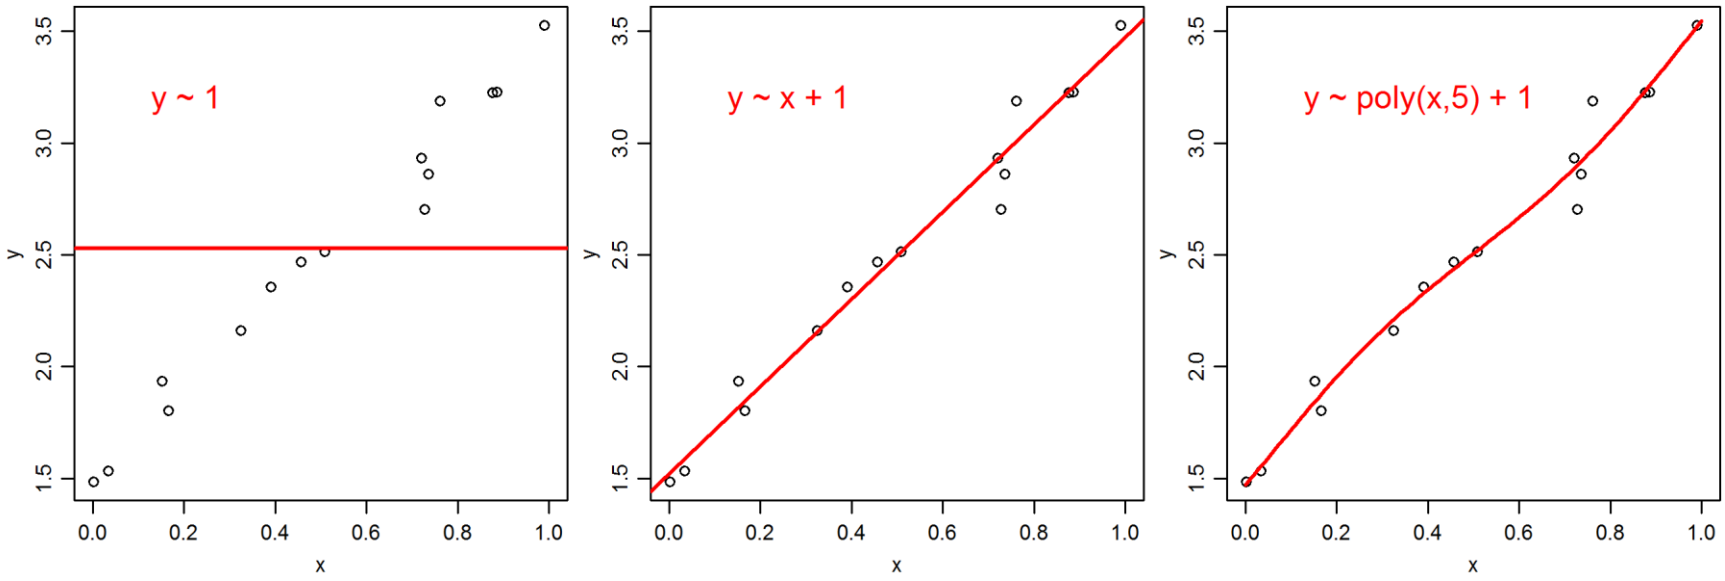

- sub-ajustamento: extrai pouco conhecimento;

- sobre-ajustamento: não constrói generalizações.

Modelos preditivos

» Conceitos: critérios de paragem

- Modelos preditivos são tipicamente iterativos;
- Cada iteração ajusta o modelo ao conjunto de treino;
- Critérios de paragem do ajustamento:

    i) número de iterações máximo atingido;

    ii) erro reduz-se abaixo de limiar de erro;

    iii) modelo não é alterado.

Modelos preditivos

» Conceitos: máximos locais e globais

- *hill climbing* (algoritmo *greedy*);
- *stochastic hill climbing;*
- *simulated annealing*.

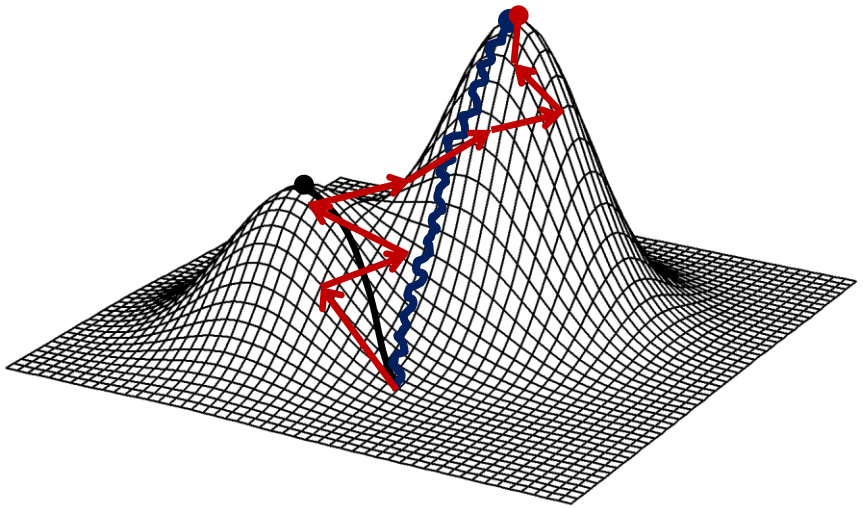

adaptado de Headlessplatter (2007) “Local_maximum.png”

» Enquadramento

- k-NN ou k-*Nearest Neighbours*, é baseado em distâncias, e é dos modelos mais simples;

- O exemplo a avaliar é comparado aos exemplos mais próximos do conjunto de treino;

- É considerado *lazy learner* (cf. *eager learning*), estando muito susceptível a ruído e a dados em falta;

- Pode ser usado em classificação ou regressão.

» Metodologia

- O algoritmo envolve cálculo de distâncias;

- Atributos quantitativos: a distância euclidiana é a mais usual

$$d(\vec{x},\vec{y}) = \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2}$$

- Atributos qualitativos: e.g., distância de *Hamming*

$$d(x_i, x_j) = \begin{cases} 0 & sse \quad x_i = x_j \\ 1 & sse \quad x_i \neq x_j \end{cases}$$

» Algoritmo para Classificação

Dado um ponto x = {?} a classificar:

1) Calcular a distância desse ponto a todos os pontos do conjunto de treino.

2) Observar os k vizinhos mais próximos;

3) Calcula-se o número de ocorrência de cada classe;

4) O ponto a classificar é classificado pela classe mais frequente.

» Algoritmo para Regressão

Dado um ponto x = {?} a prever:

1) Calcular a distância desse ponto a todos os pontos do conjunto de treino.

2) Observar os k vizinhos mais próximos;

3) Calcula-se uma média ponderada pelas distâncias;

4) A previsão é dada por essa média.

» Exemplo

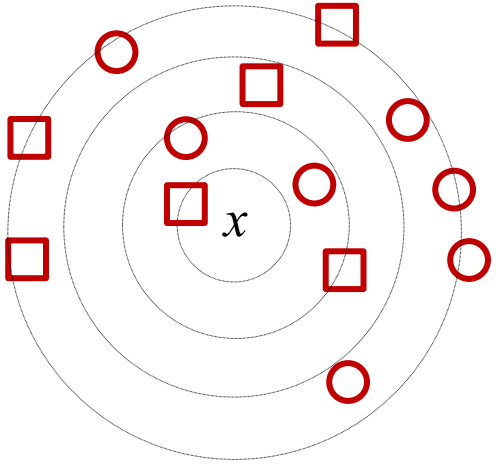

Para 1 vizinho mais próximo, x é classificado como □

Para 3 vizinhos mais próximos, x é classificado como ○

Para 5 vizinhos mais próximos, x é classificado como □

» Vantagens e Desvantagens

- Modelos são simples de usar e interpretar.

- Não faz generalizações e é susceptível a ruído e a dados em falta;

- Podem-se tornar computacionalmente intensos com números elevados de atributos (i.e. *curse of dimensionality*);

- Escolha da métrica de distância e do parâmetero *k* pode ser complexa (mas existem algoritmos desenvolvidos para o efeito);

» Exercícios

1. Considere o seguinte conjunto de treino:

ID	a1	a2	a3	classe
1	1	1	0	X
2	0	1	1	Z
3	0	0	1	X
4	1	1	1	X
5	0	1	0	X
6	1	0	1	Z

Classifique o exemplo $x = \{a_1 = 1, a_2 = 0, a_3 = 1\}$ usando:

a) classificador 1-NN (distância Euclideana);

b) classifcador 5-NN (distância Euclideana).

» Exercícios (no **RapidMiner**)

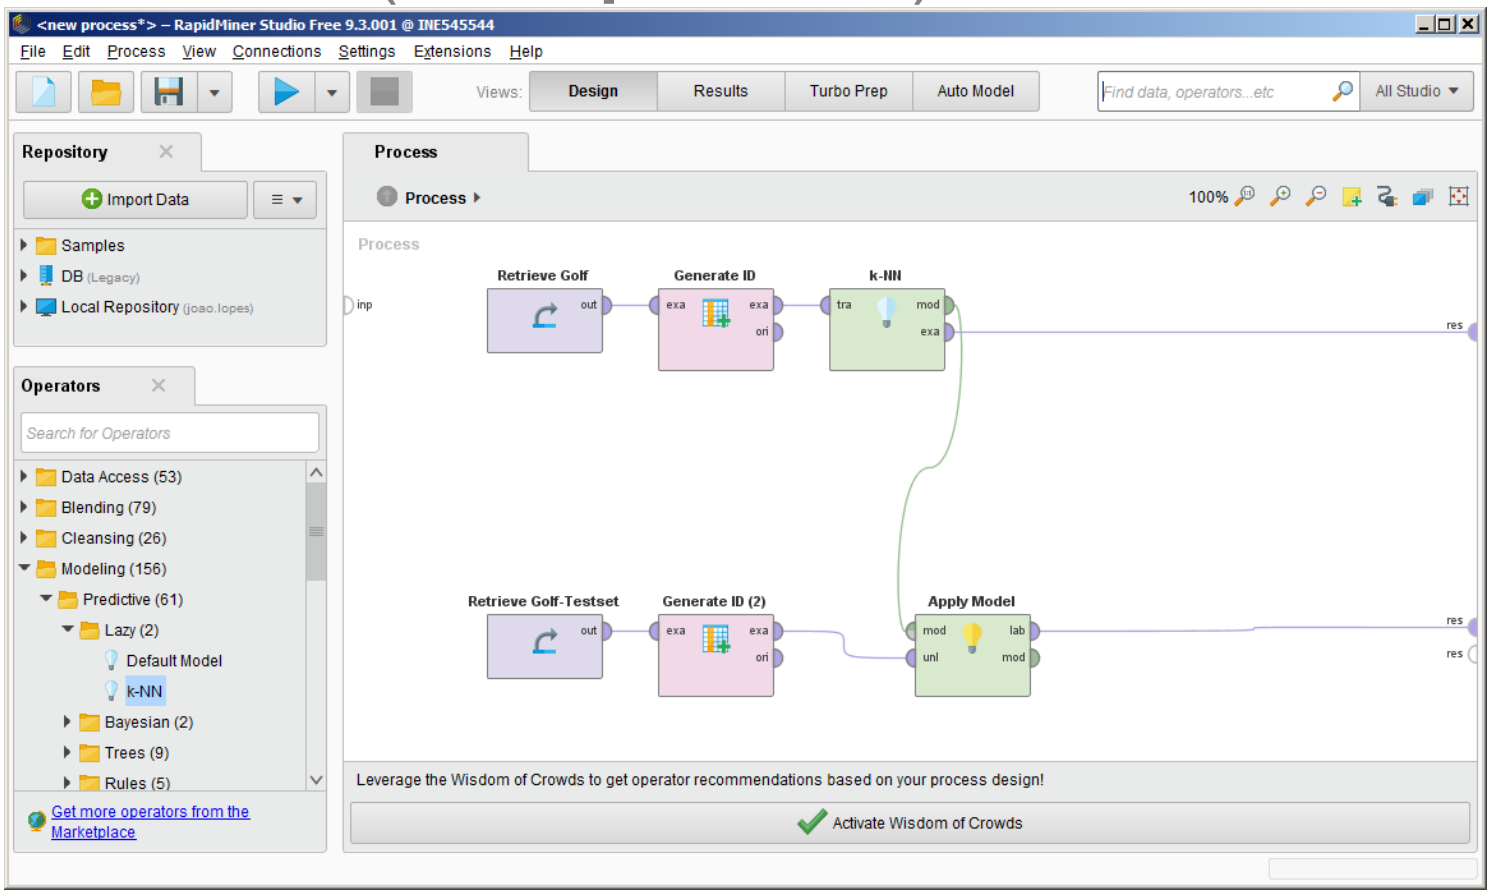

» Exercícios (no **R**)

```
library("class")

trainset <- read.csv("../data/golf.csv",header=TRUE)
testset <- read.csv("../data/golf-testset.csv",header=TRUE)

#Test model
res <- knn(trainset[,c("Temperature","Humidity")], #training set (attr.)
           testset[,c("Temperature","Humidity")],  #testing set
           trainset[,"Play"],                      #training set (cl.)
           k=3,                                    #k-Nearest Neighbour
           prob=TRUE)                              #proportion of winning class

#Confusion Matrix
conf_mat <- table(testset[,"Play"],res)
conf_mat
```

```
#Error rate
err_rt <- 100*(sum(conf_mat) - sum(diag(conf_mat)))/sum(conf_mat)
err_rt
```

Naive Bayes

» Enquadramento

- *Naive Bayes* é baseado em probabilidades, e apesar de ter sido desenvolvido nos anos 60, mantém-se competitivo em *Text Mining*;

- Pressupõe ingenuamente (*naive*) independência das variáveis-preditivas, mas é robusto a ligeiras violações;

- A classificação é tipicamente exacta, apesar da estimativa das probabilidade poder ter pouca exactidão;

- O algoritmo requer um número de parâmetros linear com o número de atributos (i.e. não sofre de *curse of dimensionality*);

- Usado em classificação.

» Teorema de Bayes

- *Naive Bayes* é baseado no teorema de *Bayes*.

$$P(\theta \mid D) = \frac{P(\theta) \cdot P(D \mid \theta)}{P(D)}$$

$$P(\theta, D) = P(\theta) \cdot P(D \mid \theta)$$

$$P(\theta, D) = P(D) \cdot P(\theta \mid D)$$

$P(\theta)$ - Prob. dos parâmetros θ (Probabilidade *a priori*);

$P(D)$ - Prob. dos dados D (Probabilidade dos dados);

$P(\theta \mid D)$ - Prob. dos parâmetros θ dado os dados D (Probabilidade posterior).

$P(D \mid \theta)$ - Prob. dos dados D dados os parâmetros θ (Verosimilhança)

$P(T, \theta)$ - Prob. dos dados D e dos parâmetros θ (Probabilidade conjunta)

» Metodologia

- Probabilidade de cada classe c para um conjunto de teste T é

$$P(c \mid T) = \frac{P(c) \cdot P(T \mid c)}{P(T)}$$

onde,

$P(c)$ é a probabilidade *a priori* de cada classe c (e.g. proporcional à frequência de cada classe; uniforme; …);

$P(T)$ é a probabilidade de observar o conjunto de teste T;

$P(T \mid c)$ é a verosimilhança, ou seja a probabilidade de observar T para cada classe c.

» Metodologia

- Sendo $X_1,\ldots,X_p$ valores de p atributos do conjunto de teste T,

$$P(c \mid X_1,\ldots,X_p) = \frac{P(c)\cdot P(X_1,\ldots,X_p \mid c)}{P(X_1,\ldots,X_p)}$$

- $P(X_1,\ldots,X_p)$ é constante para todas as classes. Para comparar classes só precisamos do numerador,

$$P(c \mid X_1,\ldots,X_p) \propto P(c)\cdot P(X_1,\ldots,X_p \mid c)$$

- Assumindo independência entre atributos,

$$P(c \mid X_1,\ldots,X_p) = P(c)\prod_{i=1}^{p} P(X_i \mid c)$$

» Exemplo

Conjunto de Teste (1000 elementos):

Classe	Tamanho		Doçura		Cor		Total
	Longa	Curta	Doce	Amarga	Amarela	Outra	
Banana	400	100	350	150	450	50	500
Laranja	0	300	150	150	300	0	300
Outra	100	100	150	50	50	150	200
Total	500	500	650	350	800	200	1000

Exemplo a testar x = {Longa; Doce; Amarela}

» Exemplo

Probabilidades a priori:

P(Banana) = 0.5

P(Laranja) = 0.3

P(Outra) = 0.2

Probabilidade dos dados:

P(Longa) = 0.5

P(Doce) = 0.65

P(Amarela) = 0.8

Verosimilhança:

P(Longa | Banana) = 0.8

P(Longa | Laranja) = 0.0

P(Longa | Outra) = 0.5

P(Doce | Banana) = 0.7

P(Doce | Laranja) = 0.5

P(Doce | Outra) = 0.75

P(Amarela | Banana) = 0.9

P(Amarela | Laranja) = 1.0

P(Amarela | Outra) = 0.25

» Exemplo

$$P(Banana \mid Longa, Doce, Amarela) = \frac{P(Banana)P(Longa, Doce, Amarela \mid Banana)}{P(Longa) \cdot P(Doce) \cdot P(Amarela)} = \frac{0.252}{P(Longa) \cdot P(Doce) \cdot P(Amarela)}$$

$$P(Laranja \mid Longa, Doce, Amarela) = \frac{P(Laranja)P(Longa, Doce, Amarela \mid Laranja)}{P(Longa) \cdot P(Doce) \cdot P(Amarela)} = \frac{0}{P(Longa) \cdot P(Doce) \cdot P(Amarela)}$$

$$P(Outra \mid Longa, Doce, Amarela) = \frac{P(Outra)P(Longa, Doce, Amarela \mid Outra)}{P(Longa) \cdot P(Doce) \cdot P(Amarela)} = \frac{0.01875}{P(Longa) \cdot P(Doce) \cdot P(Amarela)}$$

» Exemplo

$$\frac{P(Banana \mid Longa, Doce, Amarela)}{P(Laranja \mid Longa, Doce, Amarela)} = \frac{0.252}{0} = +\infty$$

$$\frac{P(Banana \mid Longa, Doce, Amarela)}{P(Outra \mid Longa, Doce, Amarela)} = \frac{0.252}{0.01875} = 13.44$$

Naive Bayes

» Para variáveis-preditoras contínuas

1. Assumindo distribuição normal, probabilidade do atributo x = v é,

$$P(x = v \mid c) = Normal(x = v \mid \mu_c, \sigma_c) = \frac{1}{\sqrt{2\pi\sigma_c^2}} \, e^{-\frac{(v-\mu_c)^2}{2\sigma_c^2}}$$

onde μ_c e σ_c são a média e o desvio padrão de x para a classe c;

ou

2. Transformação dos valores contínuos em valores discretos.

» Vantagens e Desvantagens

- Modelos são simples de usar e interpretar;

- Permitem fazer generalizações;

- Podem usar facilmente grandes quantidades de dados (i.e. não sofre de *curse of dimensionality*).

- As probabilidades obtidas podem ser pouco exactas (sobretudo para conjuntos de teste pequenos);

- O pressuposto de independência entre atributos raramente se verifica (apesar de alguma robustez à sua violação).

» Exercícios

1. Considere o seguinte conjunto de treino:

ID	a1	a2	a3	classe
1	1	1	0	X
2	0	1	1	Z
3	0	0	1	X
4	1	1	1	X
5	0	1	0	X
6	1	0	1	Z

Classifique o exemplo $x = \{a_1 = 0, a_2 = 1, a_3 = 1\}$ usando *Naive Bayes*.

» Exercícios

2. Considere os dados do ficheiro “golf.csv”. Classifique o exemplo

x = {Outlook = “sunny“, Temperature = 66, Humidity = 90, Wind = TRUE}

usando *Naive Bayes*.

Naive Bayes

» Exercícios (no **RapidMiner**)

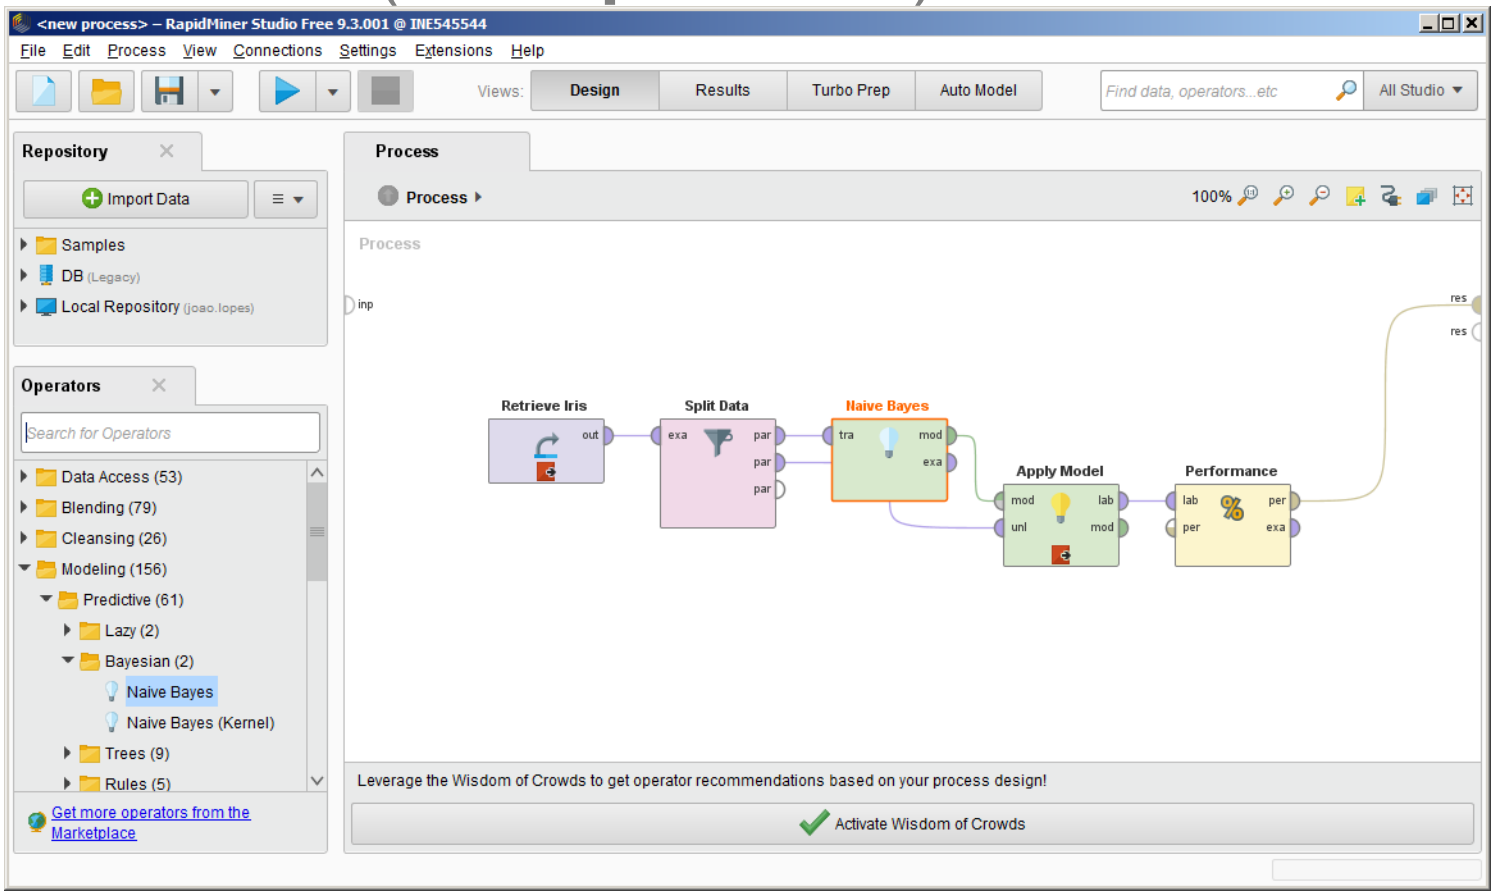

Naive Bayes

» Exercícios (no **R**)

```
library("e1071")

#Create testing set by hold out
set.seed(12345)
n <- nrow(iris)
n_test <- floor(n/3)
sampindex <- sample(1:n,size=n_test,replace=FALSE)
testset <- iris[sampindex,]
trainset <- iris[-sampindex,]

#Perform Naive Bayes fit
mod <- naiveBayes(Species ~ .,          #model design
                  trainset,             #training set
                  laplace=1)            #Laplace correction
```

Naive Bayes

```
#Test model
res <- predict(mod,                          #model
               testset)                      #testing set

#Confusion Matrix
conf_mat <- table(testset[,"Species")],res)
conf_mat

#Error rate
err_rt <- 100*(sum(conf_mat) - sum(diag(conf_mat)))/sum(conf_mat)
err_rt
```

Árvores de Decisão

» Enquadramento

- Árvores de Decisão são baseados em procura que produzem uma estrutura de árvore com base no conjunto de treino;

- Produzem modelos facilmente interpretáveis e são bastante úteis para descrever os dados;

- Podem ser usados em classificação (i.e. árvores de classificação) ou regressão (i.e. árvores de regressão).

Árvores de Decisão

» Metodologia

- A estrutura de árvore é um gráfico de fluxo em forma de árvore.

- A árvore é composta pelos seguintes elementos: nó-raiz, nós-internos, ramos e nós-folha.

- O nó-raiz é o nó que inicia a árvore, os nós-internos representam um teste a um atributo, os ramos representam o resultado do teste, e os nós-folha são portadores da informação sobre a variável-alvo.

Árvores de Decisão

» Exemplo*

Processo de decisão na concessão de crédito bancário

Conjunto de teste: 99 exemplos, 5 atributos (incl. variável-resposta)

Exemplo de dados:

Montante	Idade	Salário	Conta	Decisão
médio	júnior	médio	sim	concedido
médio	júnior	baixo	não	não concedido
alto	sénior	alto	sim	concedido
baixo	júnior	médio	sim	concedido
alto	sénior	médio	não	não concedido
…				

*Faculdade de Economia do Porto, Apontamentos de Informática Aplicada, 2011

Árvores de Decisão

» Exemplo*

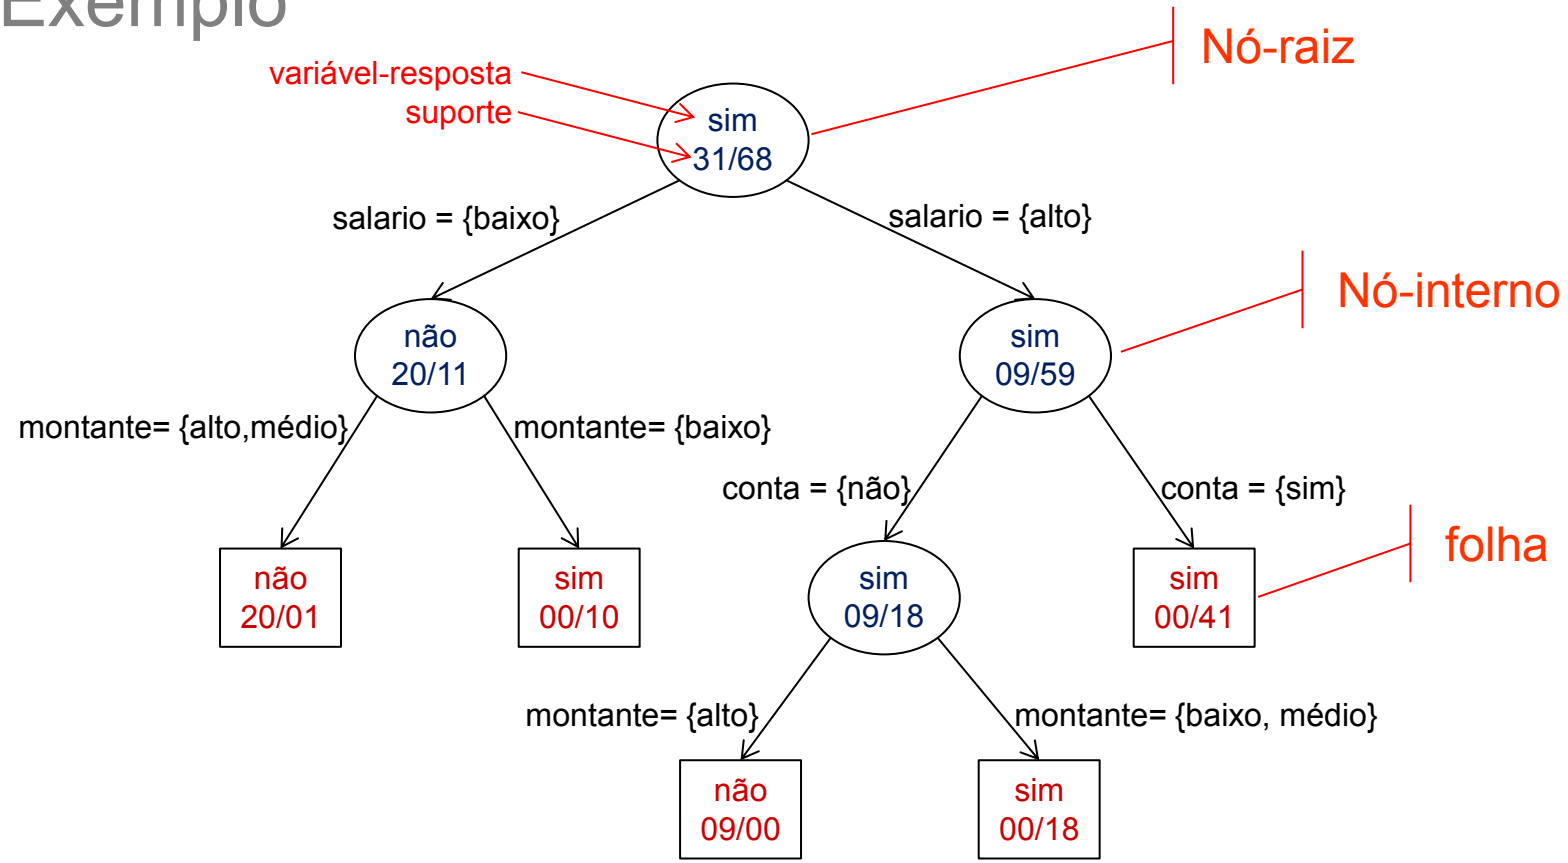

*Faculdade de Economia do Porto, Apontamentos de Informática Aplicada, 2011

Árvores de Decisão

» Algoritmo *ad hoc* para atributos binários

- Como escolher o nó-raíz (e os nós-internos subsequentes)?

- Como dividir e (subdividir) o conjunto de teste?

- Quando parar de acrescentar nós-internos e terminar numa folha?

- Que valor dar a cada folha?

Árvores de Decisão

» Algoritmo *ad hoc* para atributos binários

- Como escolher o nó-raíz (e os nós-internos subsequentes)?
Escolher aleatoriamente (e.g. ordem alfabética).

- Como dividir e (subdividir) o conjunto de teste?
Para atributos binários a divisão nos seus dois valores é natural.

- Quando parar de acrescentar nós-internos e terminar numa folha?
Criar folhas quando obtiver folhas "puras".

- Que valor dar a cada folha?
O valor da folha "pura" é o valor único da variável-alvo.

Árvores de Decisão

» Exemplo*

Diagrama em árvore da conjunção (i.e. AND)

A	B	∧
F	F	F
F	T	F
T	F	F
T	T	T

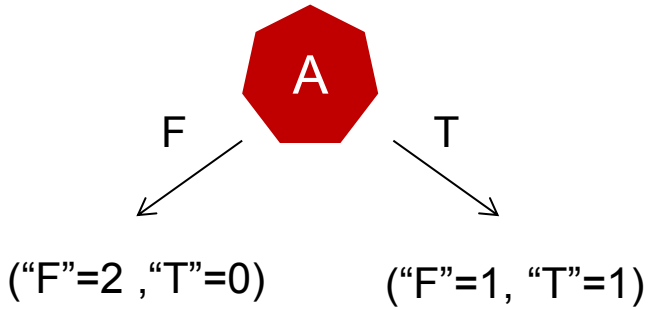

* Adaptado de Gama, J. Faculdade de Economia do porto, EDC1, 2000/2001

Árvores de Decisão

» Exemplo*

Diagrama em árvore da conjunção (i.e. AND)

A	B	∧
F	F	F
F	T	F
T	F	F
T	T	T

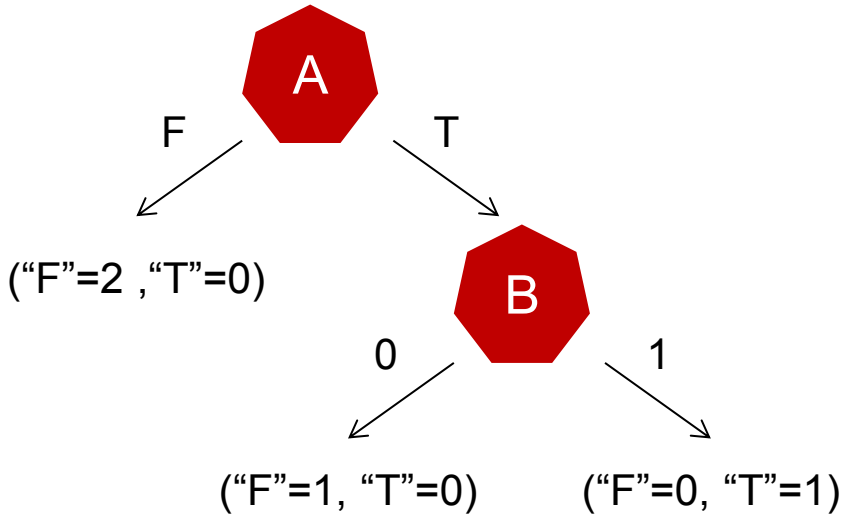

* Adaptado de Gama, J. Faculdade de Economia do porto, EDC1, 2000/2001

Árvores de Decisão

» Exemplo*

Diagrama em árvore da conjunção (i.e. AND)

A	B	∧
F	F	F
F	T	F
T	F	F
T	T	T

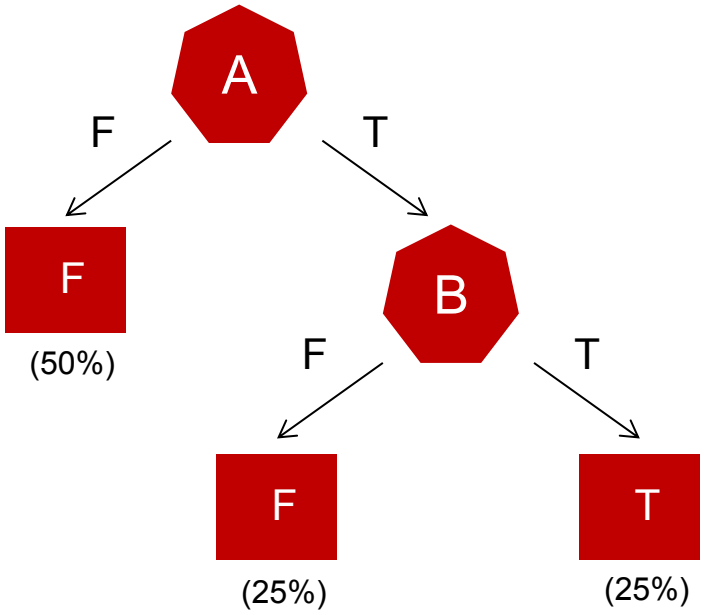

* Adaptado de Gama, J. Faculdade de Economia do porto, EDC1, 2000/2001

Árvores de Decisão

» Algoritmo "Particionamento recursivo"

- As árvores são criadas dividindo recursivamente o conjunto de teste em subconjuntos (i.e. os subconjuntos formados são eles próprios divididos em subconjuntos mais pequenos);

- A escolha do atributo para o nó-raiz (e nós-internos subsequentes) e como realizar a sua divisão é feito de modo a obter a "melhor" divisão dos dados após uma procura exaustiva;

- Esta avaliação depende da métrica escolhida (tipicamente relacionadas com a homogeneidade dos subconjuntos formados);

- Esta divisão termina quando é atingido determinado critério de paragem (e.g. obtém-se uma folha "pura"; o suporte da folha não reduz abaixo de determinado limiar; …).

Árvores de Decisão

» Algoritmo “Particionamento recursivo”

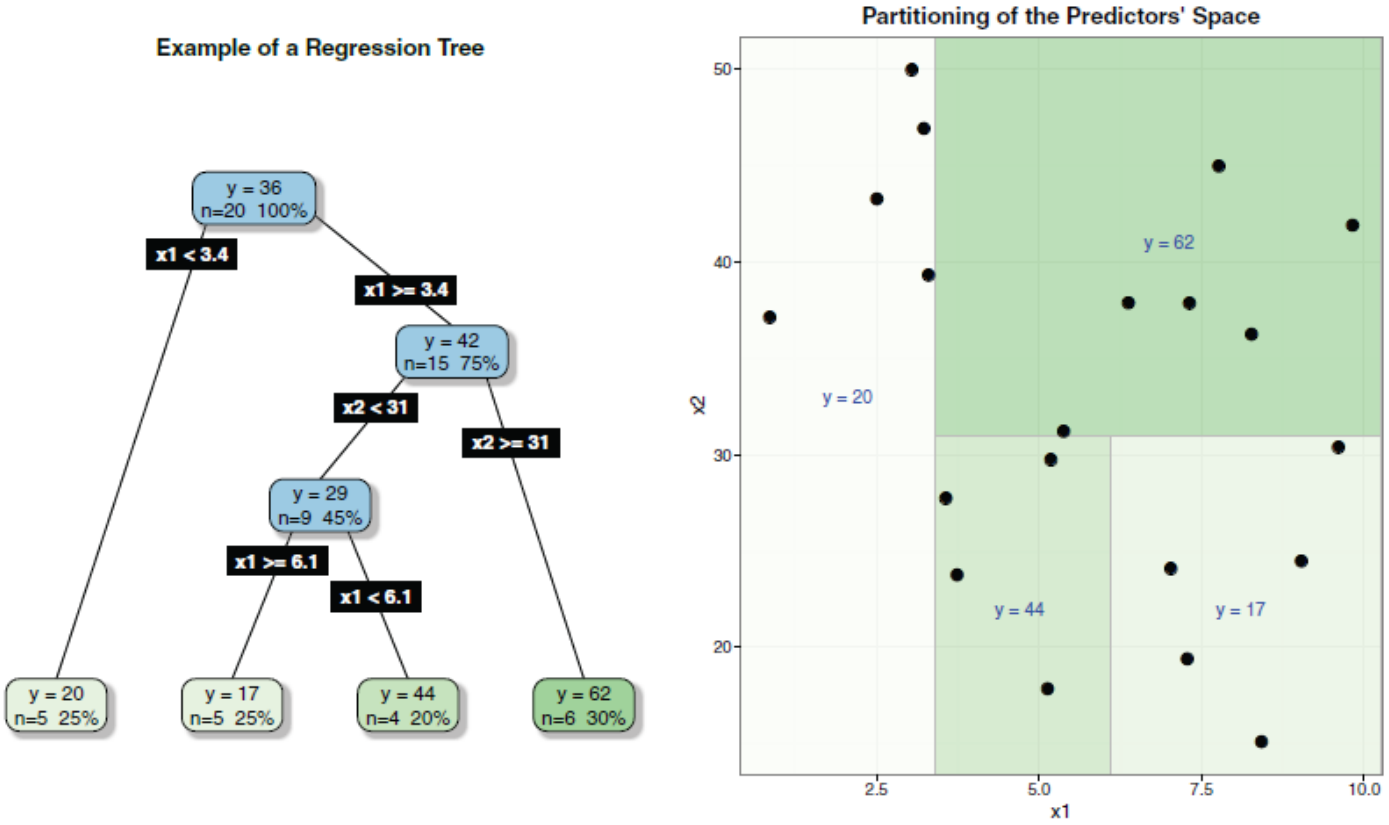

Figura 3.27 de Torga L. “Data Minig with R” (2017)

Árvores de Decisão

» Algoritmo “Particionamento recursivo”

Métrica C4.5

métrica *information gain*

divisões multiplas

Métrica CART (Classification and Regression Trees)

métricas *Gini impurity* (categórica) e Redução de Variância (contínua)

divisões binárias

Árvores de Decisão

» Critério de paragem e Poda (*pruning*)

- **Árvores grandes de folhas pequenas**: resultados demasiado específicos e com muito ruído (i.e. sobre-ajustamento);

- **Árvores pequenas de folhas grandes**: resultados extraem pouco conhecimento dos dados (i.e. sub-ajustamento);

Poda (substituir nós-internos por folhas):

1) parar a construção da árvore quando se atinge determinado critério (i.e. pré-poda)

2) criar árvores muito grandes, seguido de eliminação de ramos estatisticamente pouco significantes (i.e. pós-poda).

Árvores de Decisão

» Valores das folhas

Variável-alvo categórica

valor mais frequente do subconjunto de teste da folha

Variáveis-alvo contínua

valor médio do subconunto de teste da folha

Árvores de Decisão

» Vantagens e Desvantagens

- Modelos são simples de usar e interpretar;

- Mimetizam bem o processo de decisão humana.

- São pouco exactos relativamente a outros métodos (problemas de enviesamento);

- São pouco robustos a dados em falta e ruído dos dados (problemas de generalização);

- Algoritmos de procura podem não capturar facilmente alguns conceitos de decisão.

Árvores de Decisão

» Exercícios

1. Faça o diagrama em árvore da disjunção (i.e. OR).

A	B	v
F	F	F
F	T	T
T	F	T
T	T	T

Árvores de Decisão

» Exercícios (no **RapidMiner**)

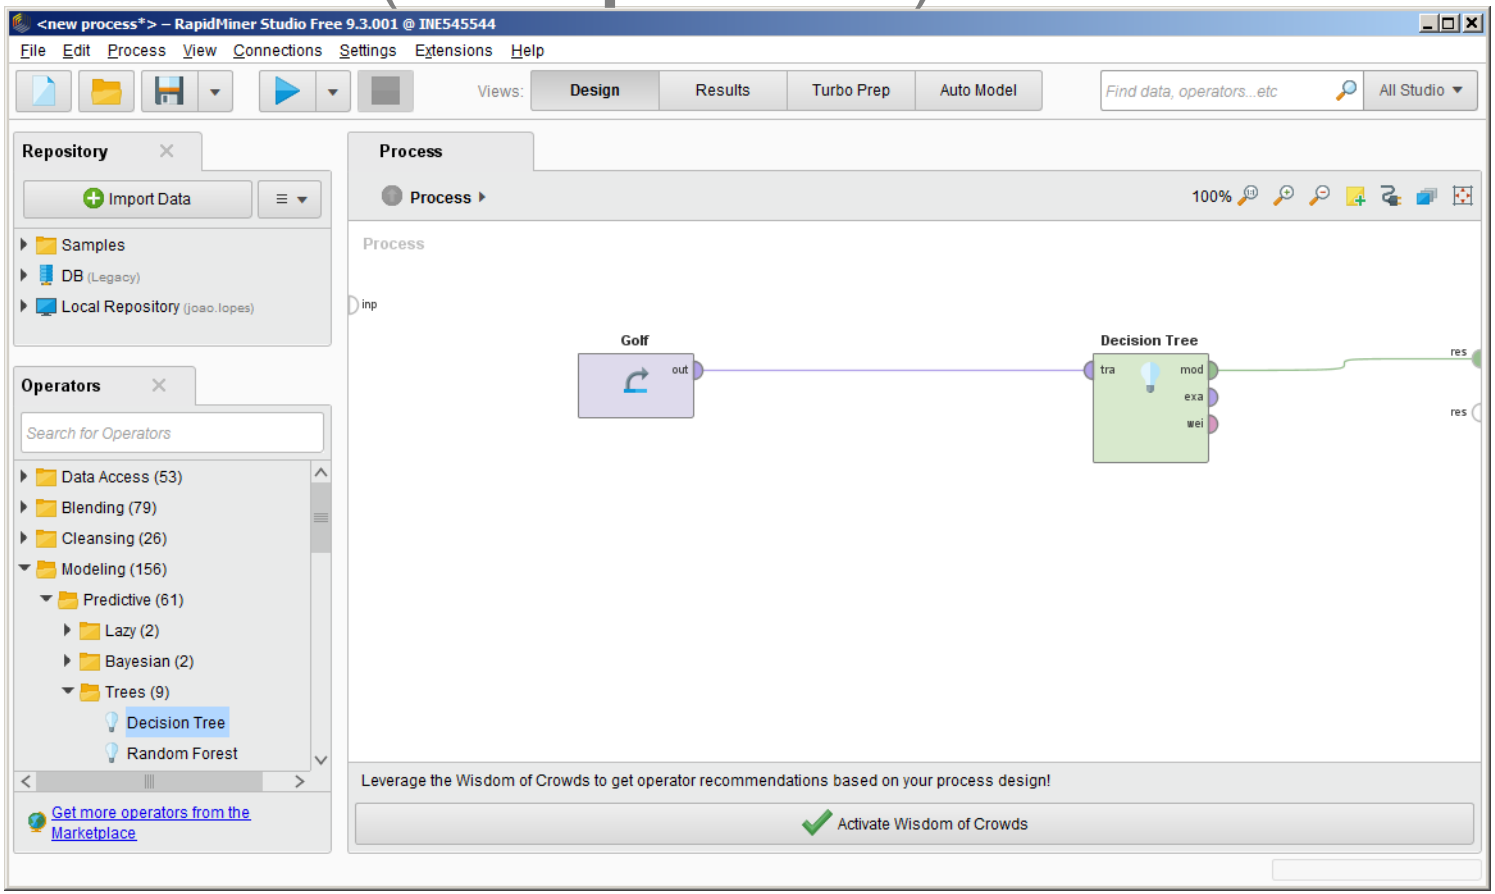

Árvores de Decisão

» Exercícios (no **RapidMiner**)

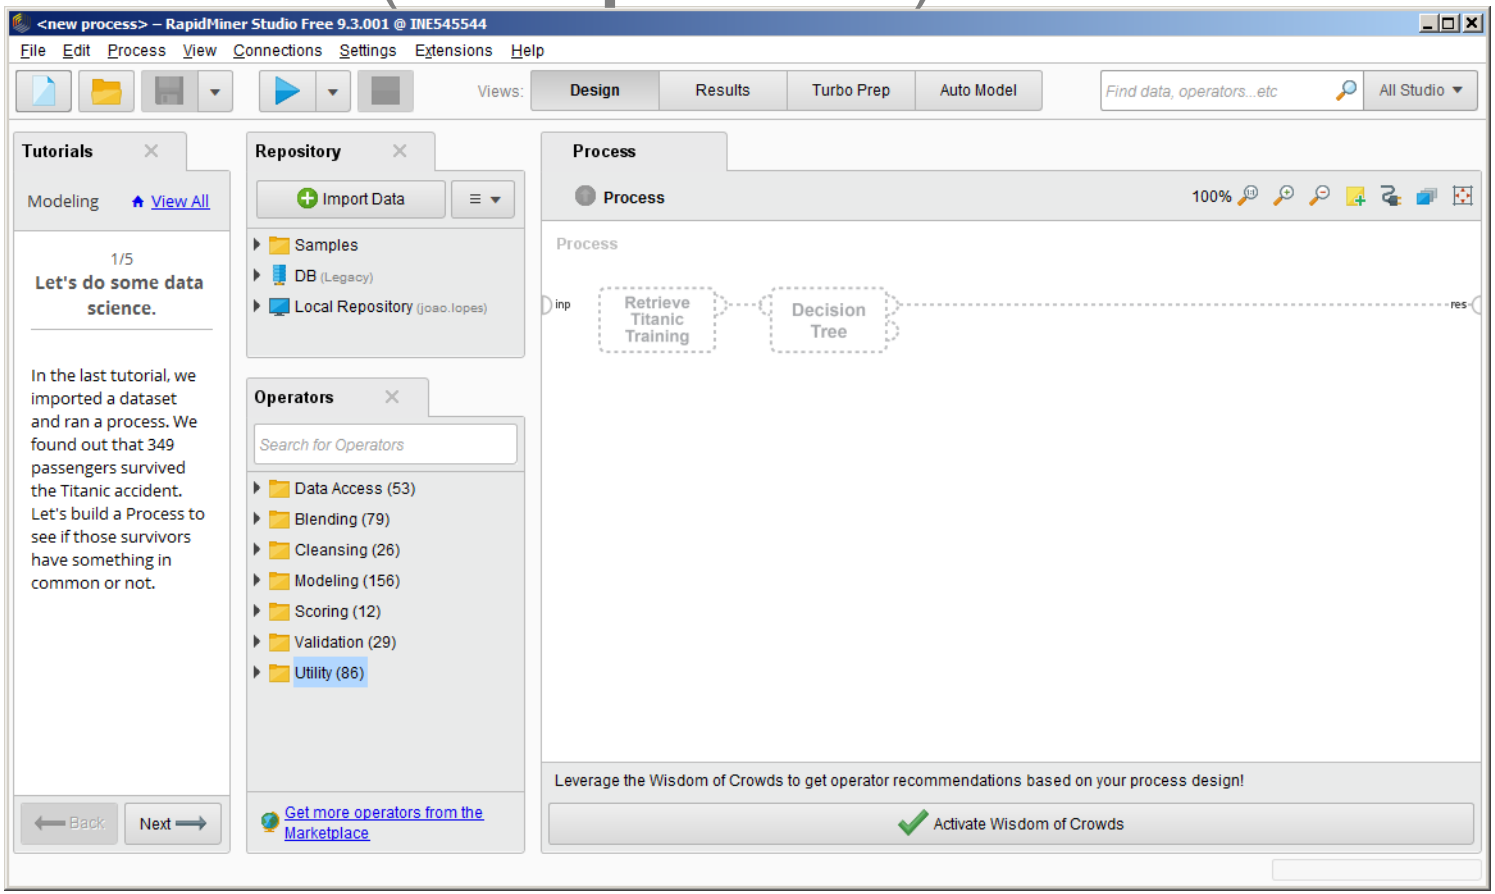

Árvores de Decisão

» Exercícios (no **R**)

```
library("rpart")

trainset <- read.csv("../data/golf.csv",header=TRUE)
testset <- read.csv("../data/golf-testset.csv",header=TRUE)

#Perform Decision Trees fit
mod <- rpart(Play ~.,                    #model design
             trainset,                   #training set
             method="class",             #Categorical Tree
             parms=list(split="gini"), #Metric "Gini Impurity"
             control=rpart.control(
               minsplit=4,               #minimal size for split
               minbucket=2,              #minimal leaf size
               cp=0.1,                   #minimal gain
               maxdepth=20))             #maximal depth
```

Árvores de Decisão

```
#Plot model
plot(mod,uniform=TRUE,branch=0.5,margin=0.05,main="Classification Tree")
text(mod,use.n=TRUE,all=TRUE,cex=0.8,fancy=TRUE,pretty=0)

#Test model
res <- predict(mod,                    #model
               testset,                #testing set
               type="class")           #can be "prob" or "class"

#Confusion Matrix
conf_mat <- table(testset[,"Play"],res)
conf_mat

#Error rate
err_rt <- 100*(sum(conf_mat) - sum(diag(conf_mat)))/sum(conf_mat)
err_rt
```

Regras de Decisão

» Enquadramento

- Árvores de Decisão podem decompor-se em Regras de Decisão;

- Regras de Decisão podem obter-se simplesmente atravessando as árvores desde o nó-raíz até às folhas;

- Regras de Decisão são da forma **IF** A **THEN** B (e.g. **IF** salário= baixo & montante = baixo **THEN** conceder = sim)

- Conjunto completo das Regras de Decisão é equivalente à Árvore de Decisão;

- Regras aumentam a interpretabilidade da Árvore.

Regras de Decisão

» Exemplo*

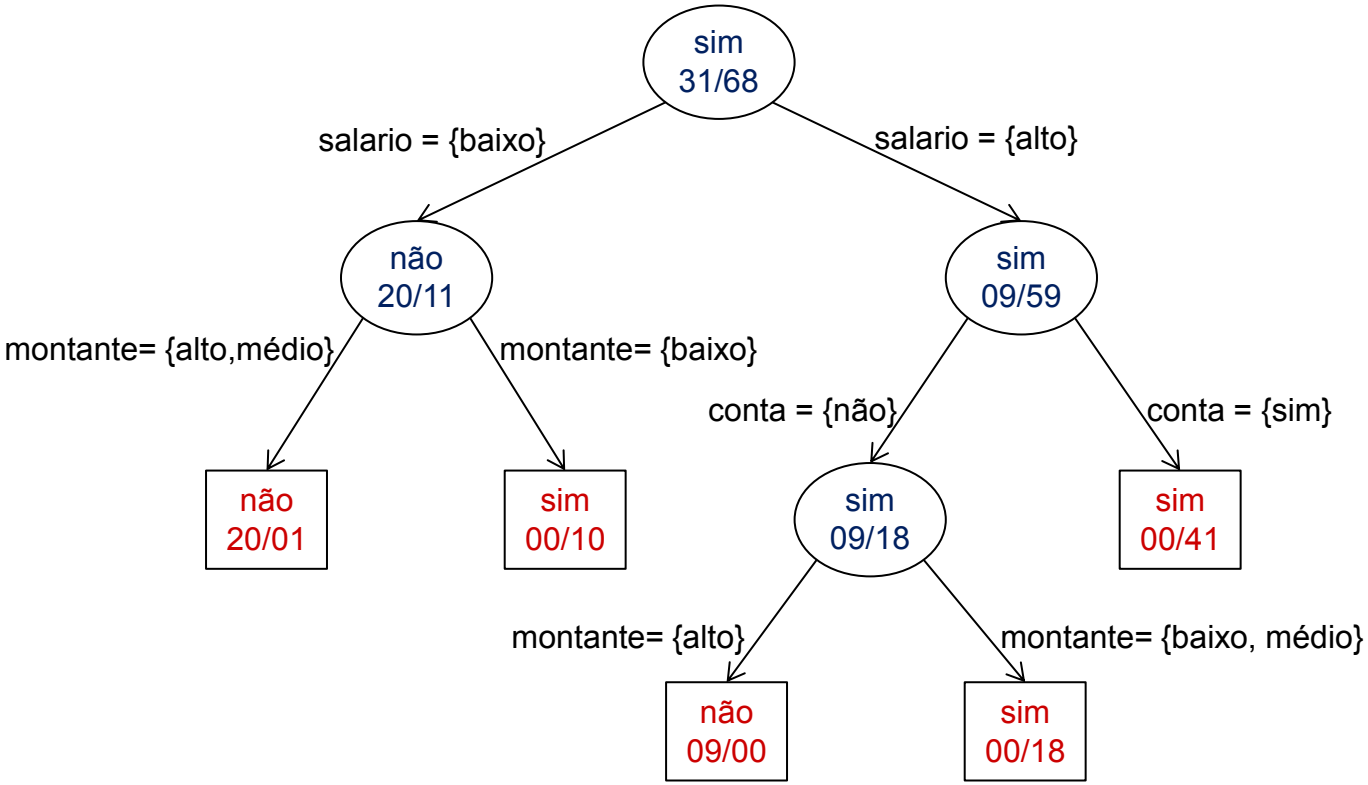

*Faculdade de Economia do Porto, Apontamentos de Informática Aplicada, 2011

Regras de Decisão

» Exemplo*

1) **IF** salário=baixo & montante={alto,médio} **THEN** não conceder

2) **IF** salário=baixo & montante=baixo **THEN** conceder

3) **IF** salário=alto & conta=não & montante=alto **THEN** não conceder

4) **IF** salário=alto & conta=não & montante={baixo,médio} **THEN** conceder

5) **IF** salário=alto & conta=sim **THEN** conceder

*Faculdade de Economia do Porto, Apontamentos de Informática Aplicada, 2011

Regras de Decisão

» Exemplo*

IF salário=baixo

IF montante={alto,médio} **THEN** não conceder

ELSE conceder

ELSE

IF conta=não

IF montante=alto **THEN** não conceder

ELSE conceder

ELSE conceder

*Faculdade de Economia do Porto, Apontamentos de Informática Aplicada, 2011

Regras de Decisão

» Algoritmos

- ***One R*** (*One Rule*): regra criada directamente dos dados, gerada apenas com base numa variável. Cria uma árvore só com folhas.

- ***Top Down***: parte de uma regra mais geral e vai acrescentando condições (de variáveis presentes ou de outras).

- ***Bottom up***: parte de uma regra mais específica e vai-se retirando condições (eliminando variáveis ou não).

Regras de Decisão

» Algoritmo "*One R*"

1) Para cada atributo A constrói-se uma regra $A = v_i \rightarrow C$,

onde v_i = valores de A e C = classe mais frequente da variável;

2) Seleciona-se o atributo que possui menor erro.

- Os erros são calculados como:

$$erro_A = \frac{\sum_{v_i} erro_{v_i}}{\sum_{v_i} total_{v_i}}$$

onde $erro_{v_i}$ é a proporção de exemplos mal classificados quando o atributo $A = v_i$.

Regras de Decisão

» Algoritmo "*Top down*"

1) Começa com uma regra principal (*Top*);

2) Remove os pontos cobertos por essa regra;

2) Enquanto não se verifica a condição de paragem:

   2.1) Adiciona uma nova regra

   2.2) Remove os pontos cobertos por essa regra

Condição de paragem:

- cobertura da regra atingir determinado limiar;

- acerto da regra baixar de determinado limiar.

Regras de Decisão

» Algoritmo "*Bottom up*"

1) Começa com uma regra complexa (*Bottom*);

2) Enquanto não se verifica a condição de paragem:

   2.1) Remove uma regra

Condição de paragem:

- cobertura da regra atingir determinado limiar;

- acerto da regra baixar de determinado limiar.

Regras de Decisão

» Avaliar qualidade da regra

- A qualidade de uma regra pode ser medida por:

$$\text{Taxa cobertura} = \frac{\text{número exemplos da regra}}{\text{total}}$$

$$\text{Taxa acerto} = \frac{\text{número exemplos bem classificados}}{\text{número exemplos da regra}}$$

Regras de Decisão

» Exercícios

2. Considere o conjunto de dados:

DMC	FUM	CT	Ab
alta	alta	sim	sim
alta	alta	não	não
baixa	alta	não	não
baixa	alta	sim	sim
baixa	baixa	sim	não

onde **DMC** = duração média de chamada, **FUM** = facturação último mês, **CT** = contrato terminou, e **Ab** = abandonou (variável-resposta).

Extraia a Regra de Decisão utilizando o algoritmo oneR.

Regras de Decisão

» Exercícios

3. Considere a árvore criada anteriormente. Expanda a folha "impura" utilizando o oneR, e considerando apenas as variáveis **DMC** e **FUM**.

4. Da árvore criada, extraia um conjunto de regras com o algoritmo *top-down* (STOP: cobertura = 80%, qualidade = 100%).

5. Usando o algoritmo *bottom-up*, e a partir da regra "**IF** CT = sim **&** FUM = alto **THEN** Ab = sim", extraia uma regra com cobertura ≥ 60% e qualidade ≥ 60%.

Regras de Decisão

» Exercícios (no **RapidMiner**)

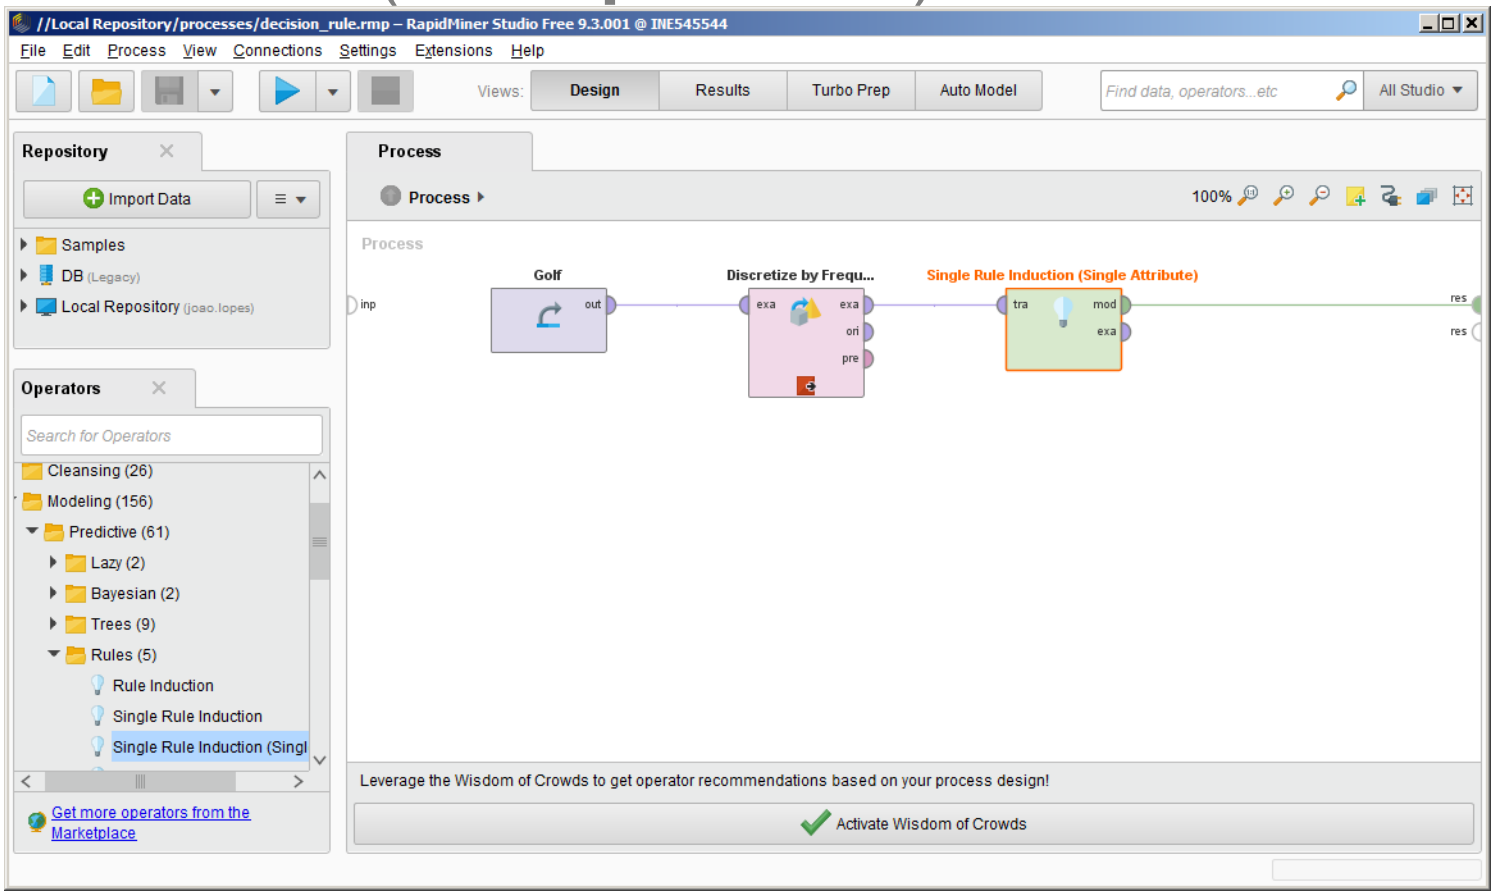

Regras de Decisão

» Exercícios (no **RapidMiner**)

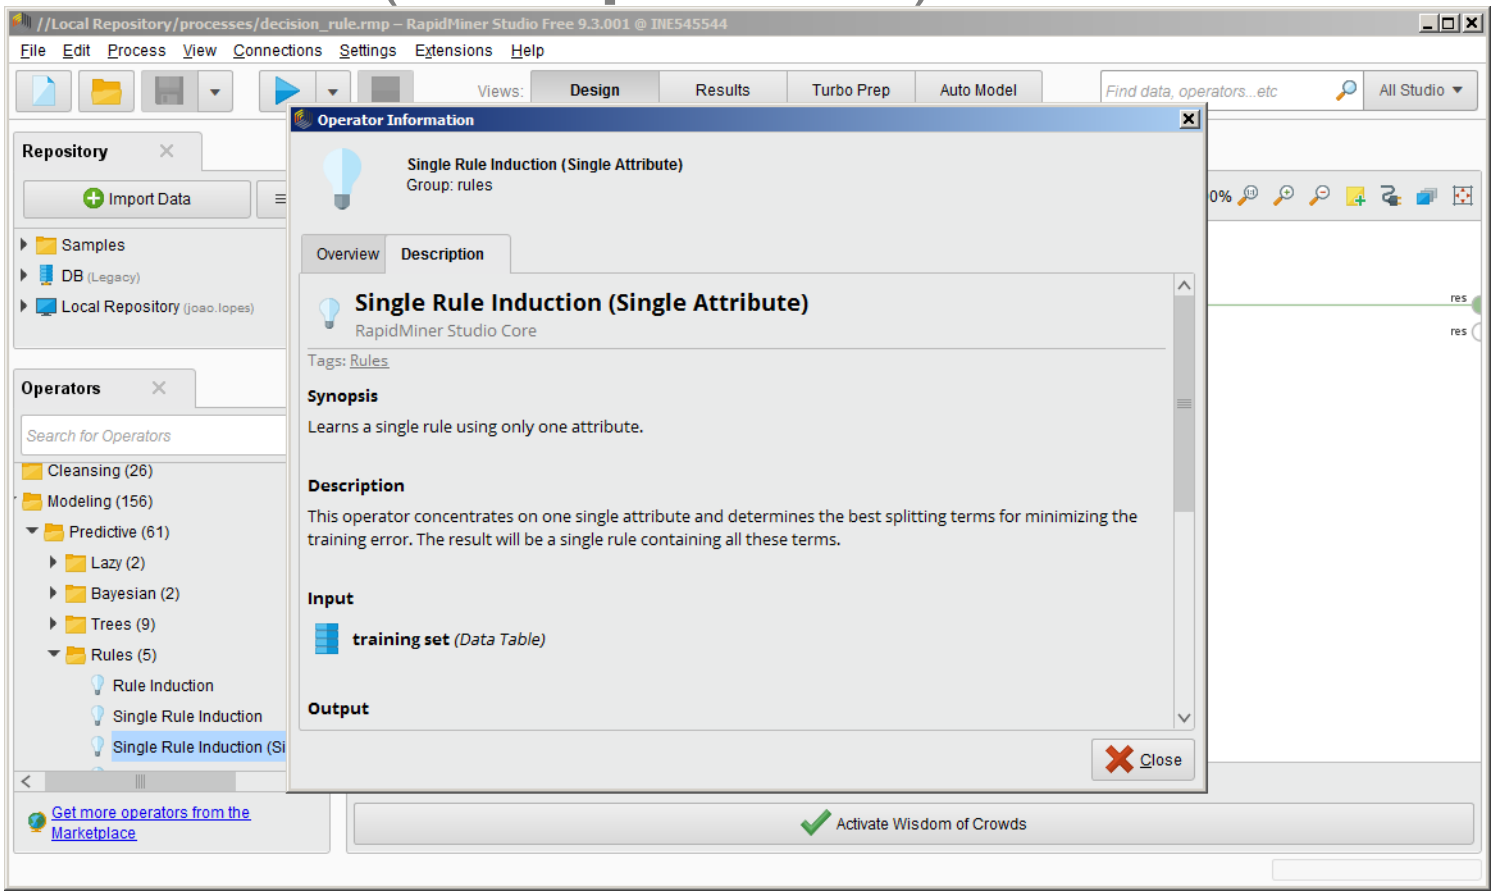

Regras de Decisão

» Exercícios (no **RapidMiner**)

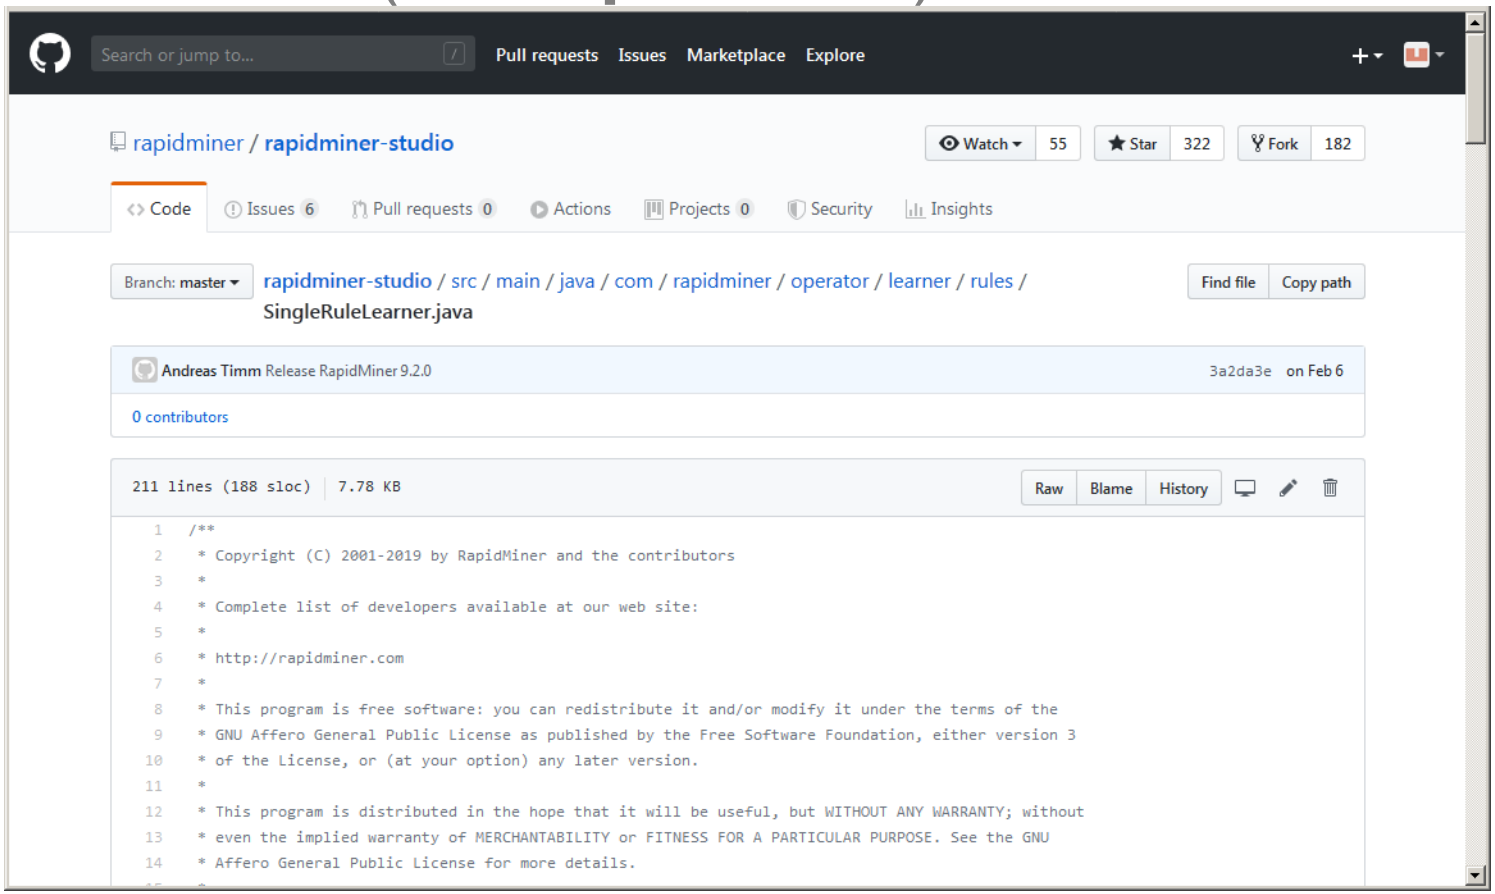

Regras de Decisão

» Exercícios (no **R**)

```
library("OneR")

trainset <- read.csv("../data/golf.csv",header=TRUE)
testset <- read.csv("../data/golf-testset.csv",header=TRUE)

#Discretize numerical variables
trainset <- bin(trainset,                #training set
                nbins=2)                 #number of bins
testset <- bin(testset,                  #test set
                nbins=2)                 #number of bins

#Perform Decision Rule fit
mod <- OneR(Play ~.,                     #model design
            trainset)                    #training set
```

Regras de Decisão

```
#Summarize model
summary(mod)

#Test model
res <- predict(mod,                    #model
               testset,                #testing set
               type="class")           #can be "prob" or "class"

#Confusion Matrix
conf_mat <- table(testset[,"Play"],res)
conf_mat

#Error rate
err_rt <- 100*(sum(conf_mat) - sum(diag(conf_mat)))/sum(conf_mat)
err_rt
```

Redes Neuronais Artificiais

» Enquadramento

- Algoritmos de optimização inspirados nas redes neuronais do cérebro, onde redes densas de neurónios realizam aprendizagens complexas;

- Os neurónios recebem um input de estímulos que se combinam na função de combinação e produzem, através da função de activação, um output de resposta;

- Modelos simples: um neurónio (i.e. *single-layer perceptron*);

- Modelos complexos: multi-camadas (i.e. *multi-layer perceptron*).

Redes Neuronais Artificiais

» *Single-layer perceptron*

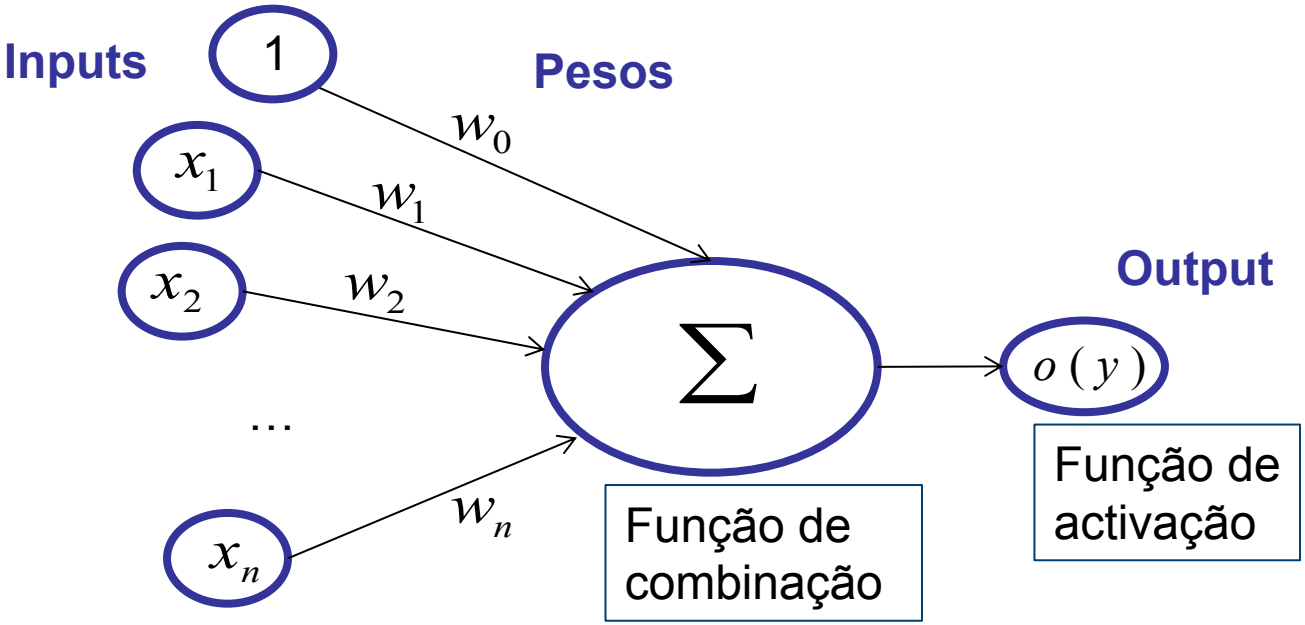

Redes Neuronais Artificiais

» *Single-layer perceptron*

Função de combinação

$$y = w_0 + w_1 x_1 + w_2 x_2 + \ldots + w_n x_n$$

$$= \sum_{i=0}^{n} w_i x_i$$

Função de activação

$$o(y) = \begin{cases} 1 \ sse \ \ y > 0 \\ 0 \ c.c. \end{cases}$$

$$o(y) = \frac{1}{1 + e^{-y}}$$

$$o(y) = y$$

- Classificador Linear
- Regressão Múltipla Linear

Redes Neuronais Artificiais

» *Multi-layer Perceptron*

- Camadas dispostas paralelamente: camada de entrada, camadas intermédias (i.e. camadas escondidas) e camada de saída.

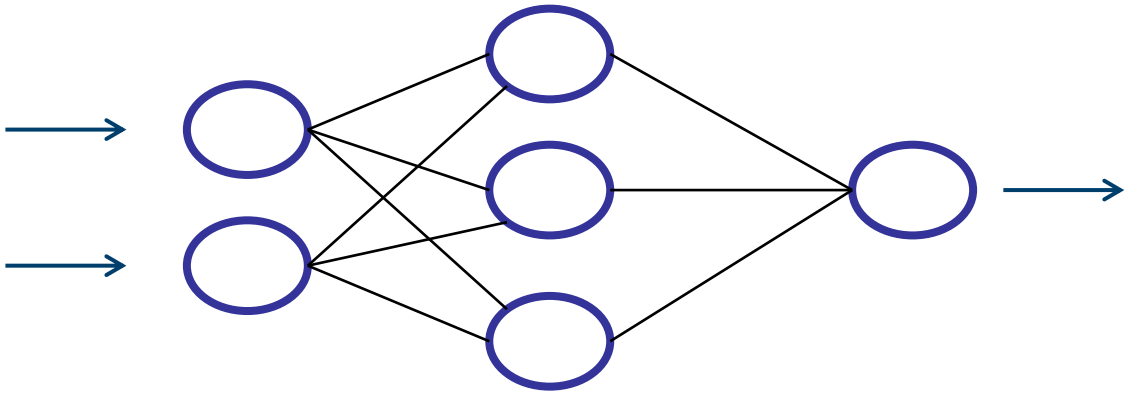

Redes Neuronais Artificiais

» Algoritmo *Backpropagation*

- Constituído por duas fases: propagação e actualização dos pesos;

- Inputs propagam-se para a frente pelas camadas da rede até à camada de output;

- Output observado é comparado com o esperado usando uma função de custo e obtendo o erro;

- Erro propaga-se para trás pelas camadas da rede desde o output até que todos os neurónios têm um erro associado;

- Esse erro actualiza os pesos de cada neurónio minimizando a função de custo.

Redes Neuronais Artificiais

» Algoritmo *Backpropagation*

$$w(t+1) = f\left(x, w(t), Err(o_{real}, o(y))\right)$$

função-custo

$$w_i(t+1) = w_i(t) + \eta \cdot (Esperado - Observado) \cdot x_i$$

taxa de aprendizagem

- Define a magnitude do ajuste feito no valor de cada peso;
- A magnitude define a velocidade de convergência da rede.

Redes Neuronais Artificiais

» Algoritmo *Backpropagation*: Dificuldades

1. Inputs e outputs devem ter valores entre 0 e 1;

2. Número de neurónios das camadas escondidas influenciam o ajustamento do modelo aos dados:

   - número reduzido pode levar a um sub-ajustamento;

   - número elevado pode levar a um sobre-ajustamento;

3. Taxa de aprendizagem influencia a convergência da optimização:

   - taxa reduzida pode levar a longos tempos de aprendizagem;

   - taxa elevada pode levar a perda de precisão;

4. Pesos iniciais influenciam o local de convergência da optimização.

Redes Neuronais Artificiais

» Algoritmo *Backpropagation*: Estratégias

1. Transformação dos dados (e.g. minmax para atributos contínuos, variáveis indicadores (*dummy*) para atributos categóricos);

2. Utilizar avaliação de modelos para definir a arquitectura da rede;

3. Taxa de aprendizagem dinâmica (e.g. começar elevada e reduzir progressivamente);

4. Treinar a rede várias vezes utilizando diferentes valores iniciais para os pesos.

Redes Neuronais Artificiais

» Vantagens e Desvantagens

- Grande capacidade para generalizar, tolerante a ruído e a dados em falta;

- Ajusta modelos complexos sem tratamento analítico.

- Parâmetros do modelo de difícil interpretação (*blackbox*);

- Resultados dependem da arquitectura da rede (i.e. pouco robustos);

- Número de neurónios pode levar a sobre-ajustamento do modelo.

» Exercícios

1. Considere o seguinte conjunto de dados e o *perceptron*:

A	B	∧
0	0	0
0	1	0
1	0	0
1	1	1

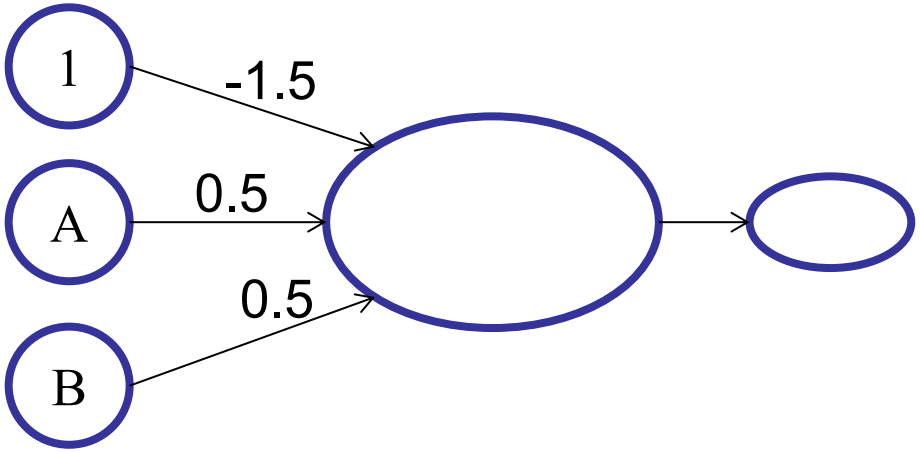

Utilizando a taxa de aprendizagem $\eta = 0.25$ e a função de activação,

$$f(x_1, x_2, \ldots, x_n) = \begin{cases} 1, & \text{sse } \sum x_i w_i > 0 \\ 0, & \text{c.c.} \end{cases}$$

descreva uma iteração do algoritmo. O algoritmo convergiu?

Redes Neuronais Artificiais

» Exercícios (no **RapidMiner**)

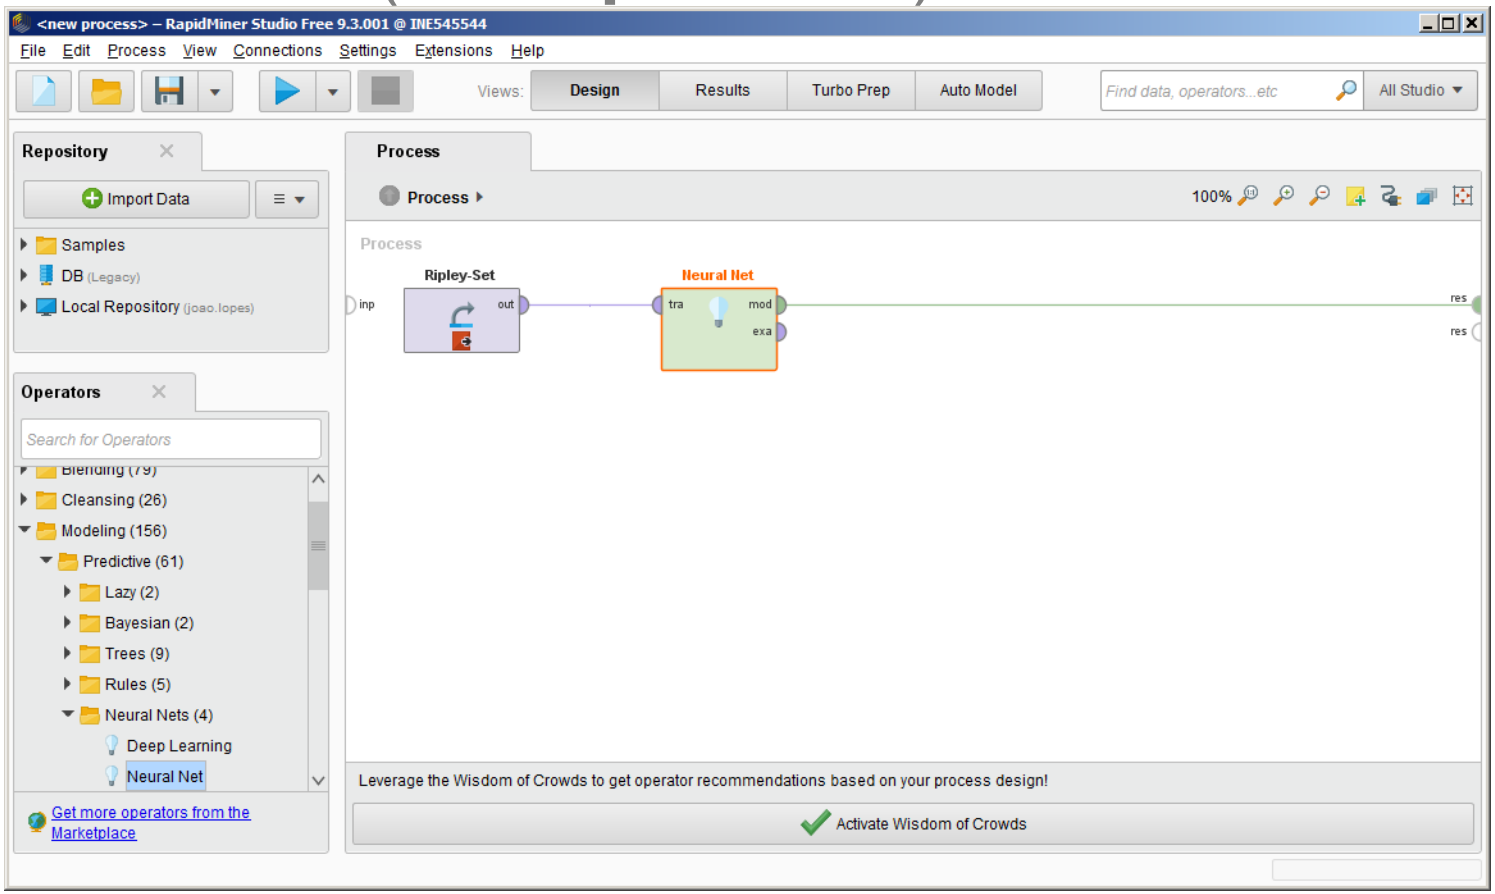

Redes Neuronais Artificiais

» Exercícios (no **R**)

```
library("nnet")
library("caret")
library("NeuralNetTools")

trainset <- read.csv("../data/ripley-set.csv",header=TRUE)
trainset[,"label"] <- factor(trainset[,"label"],levels=c("0","1"))

#Create testing set by hold out
set.seed(12345)
n <- nrow(trainset)
n_test <- floor(n/3)
sampindex <- sample(1:n,size=n_test,replace=FALSE)
testset <- trainset[sampindex,]
trainset <- trainset[-sampindex,]
```

Redes Neuronais Artificiais

```
#Select settings for artificial neural network
nn_decay <- 0.3                          #weight decay
nn_maxit <- 500                          #maximum number of iterations
grid1 <- expand.grid(size=1:5,decay=nn_decay)
train1 <- train(label ~.,                #model design
                trainset,                #training set
                maxit=nn_maxit,          #maximum number of iterations
                tuneGrid=grid1,          #parameter space to explore
                metric="Accuracy",       #metric to evaluate models
                method="nnet",trace=FALSE)
nn_size <- train1$bestTune[1,1]          #number of nodes in hidden layer

#Perform Neural Network fit
mod <- nnet(label ~.,                    #model design
            trainset,                    #training set
            size=nn_size,decay=nn_decay,maxit=nn_maxit)
```

Redes Neuronais Artificiais

```
#Plot model
summary(mod)
plotnet(mod,cex_val=0.7,circle_cex=3)
olden(mod,bar_plot=TRUE)

#Test model
res <- predict(mod,                    #model
               testset,                #testing set
               type="class")           #can be "raw" or "class"

#Confusion Matrix
conf_mat <- table(testset[,c("label")],res)
conf_mat

#Error rate
err_rt <- 100*(sum(conf_mat) - sum(diag(conf_mat)))/sum(conf_mat)
err_rt
```

Support Vector Machine

» Enquadramento

- Algoritmos de optimização que se baseiam na construção de um hiperplano óptimo (ou conjunto de hiperplanos) com o objetivo de separar as classes de dados com a maior margem possível;

- É utilizado para categorizações lineares, mas também permite classificações não-lineares (utilizando funções kernel);

- Tanto permite modelos supervisionados (usando conjuntos de testes) como não-supervisionados (formando *clusters* naturais);

- Pode ser usado em classificação ou regressão.

Support Vector Machine

» *Linear* SVM *Classifier*

- Em termos geométricos pode ser visto como a procura de um hiperplano que separa um atributo categórico binário;

- A separação completa (hard-margin) só é possível se o conjunto de treino for linearmente separável;

- Escolhe, de entre um número infinito de hiperplanos, aquele que faz a separação máxima das duas classes;

- No caso de não haver separação linear pode-se usar uma função de custo e ainda assim se encontrar a separação incompleta máxima (soft-margin);

- Tipicamente existe um único máximo global bem definindo.

Support Vector Machine

» *Linear* SVM *Classifier*

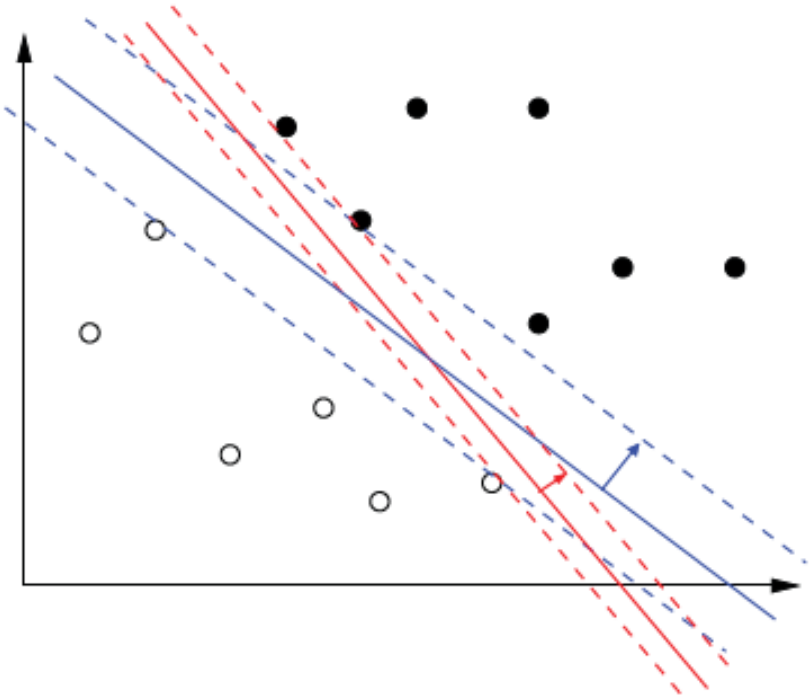

hiperplano

margem

vectores de suporte

Figura 3.31 de Torga L. “Data Minig with R” (2017)

Support Vector Machine

» Exemplo *Linear* SVM *Classifier**

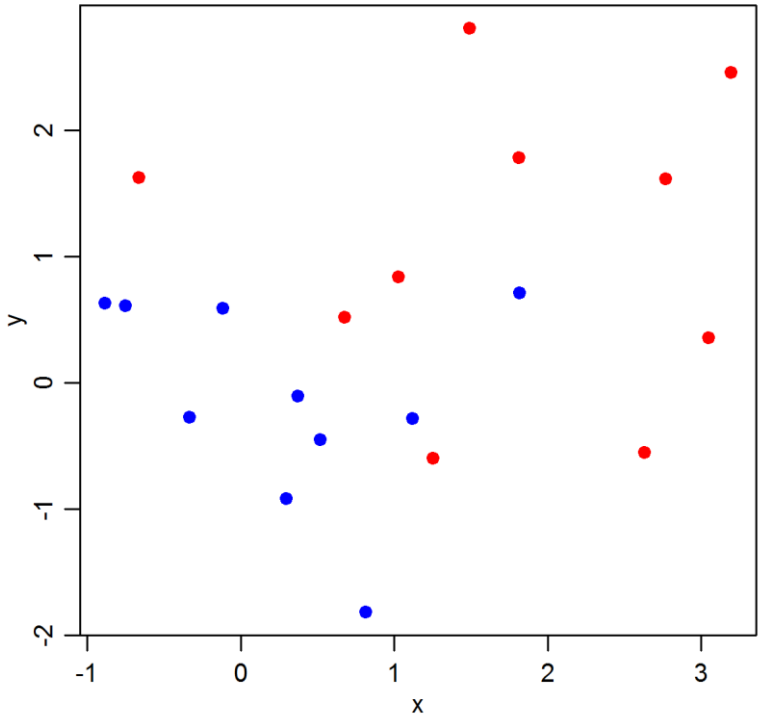

*https://www.datacamp.com/community/tutorials/support-vector-machines-r (acedido em 04-12-2019)

Support Vector Machine

» Exemplo *Linear* SVM *Classifier**

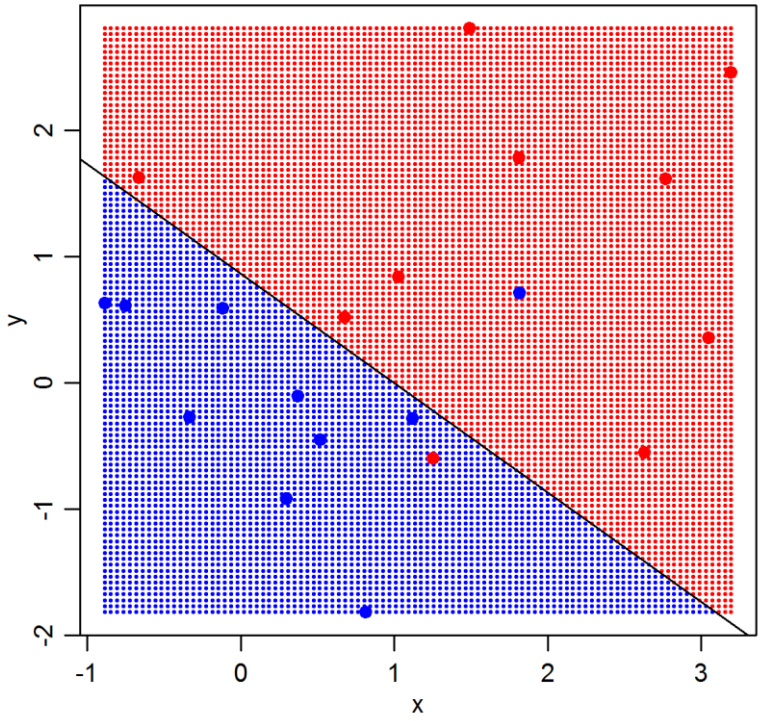

*https://www.datacamp.com/community/tutorials/support-vector-machines-r (acedido em 04-12-2019)

Support Vector Machine

» *Non-Linear* SVM *Classifier*

- Na maioria dos problemas reais não é possível separar as classes linearmente;

- Usa-se funções de *kernel* para definir fronteiras locais (e.g. Gaussiano, Epanechnikov, Polinomial, Radial)

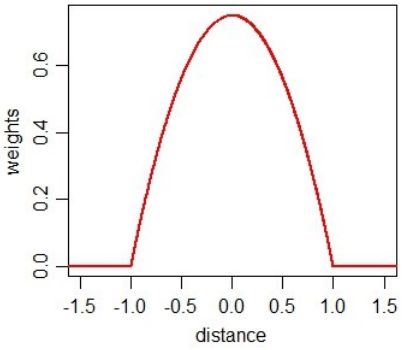

epanechnikov kernel

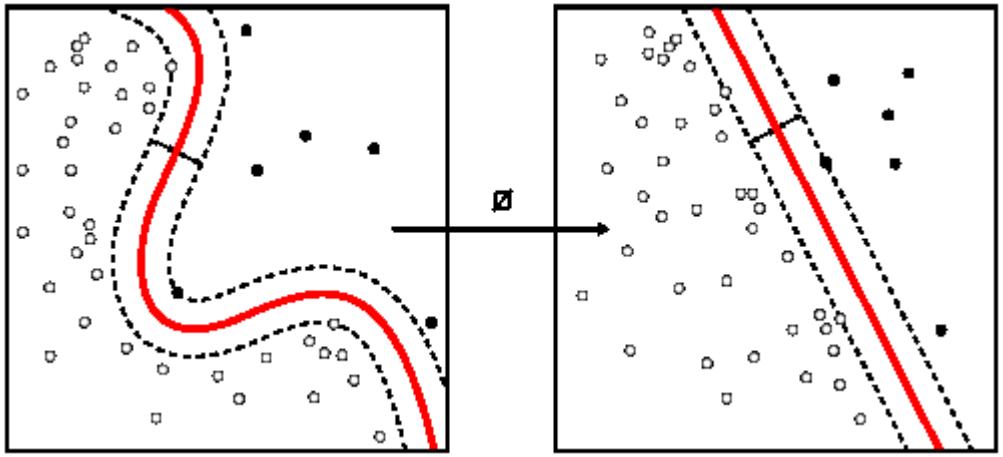

Alisneaky (2011) "Kernel Machine.png"

Support Vector Machine

» Exemplo *Non-linear* SVM *Classifier**

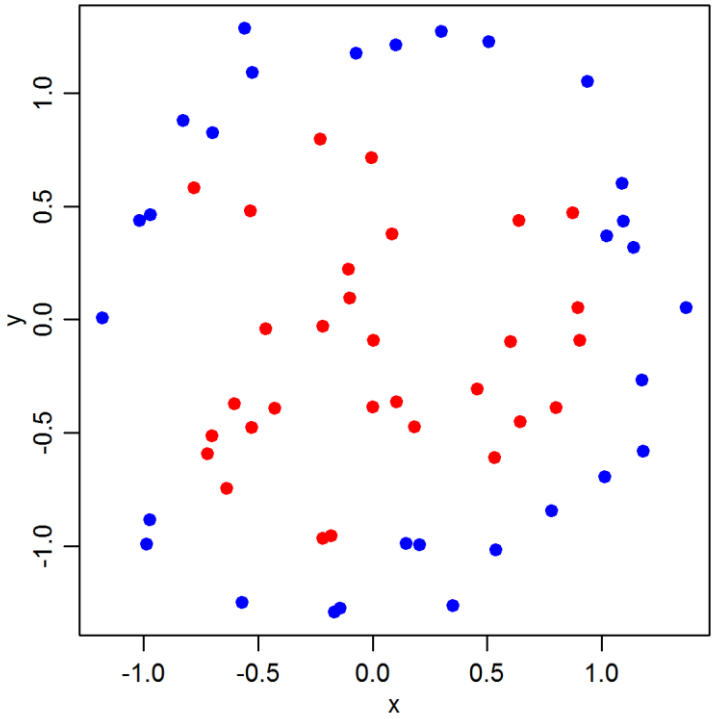

hiper-plano:

$$z = x_2 + y_2$$

*https://www.datacamp.com/community/tutorials/support-vector-machines-r (acedido em 04-12-2019)

Support Vector Machine

» Exemplo *Non-linear* SVM *Classifier**

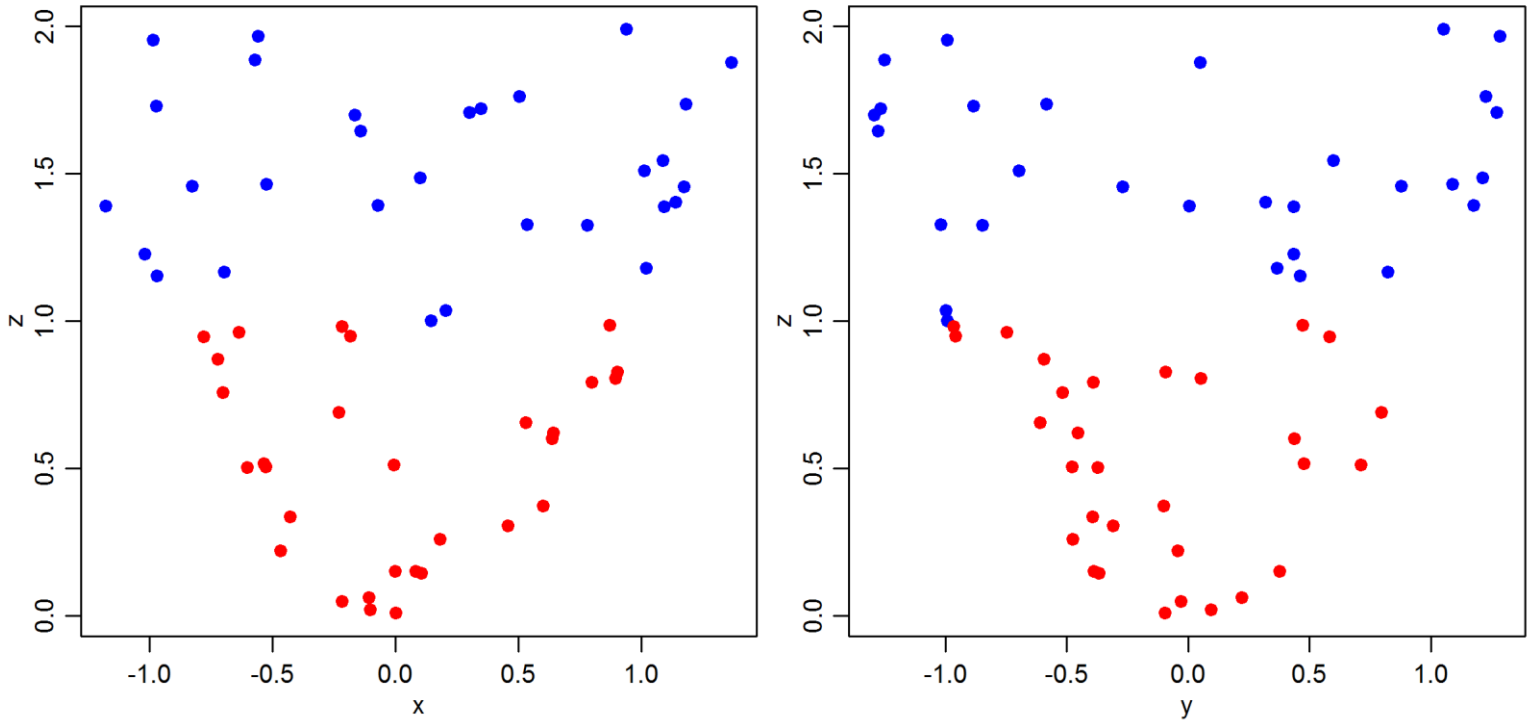

*https://www.datacamp.com/community/tutorials/support-vector-machines-r (acedido em 04-12-2019)

Support Vector Machine

» Exemplo *Non-linear* SVM *Classifier**

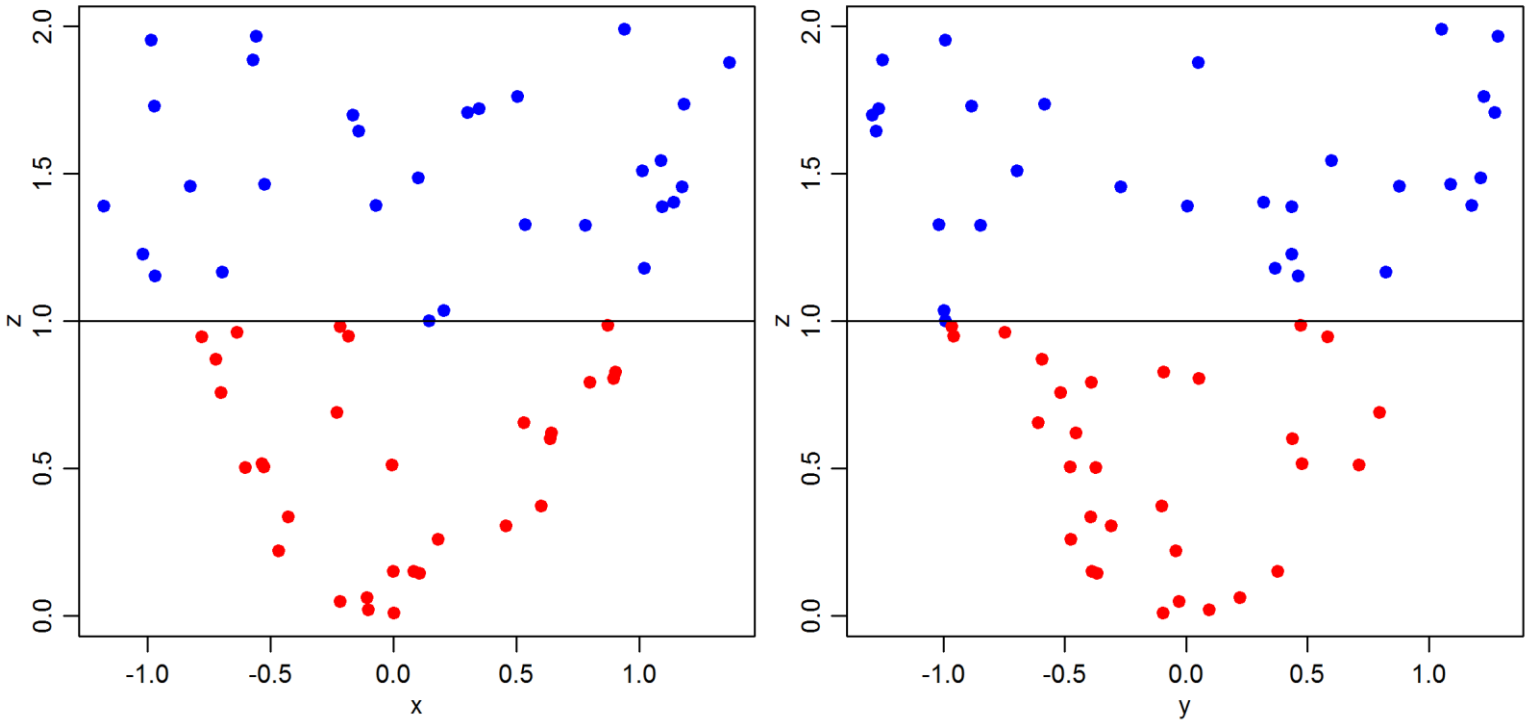

*https://www.datacamp.com/community/tutorials/support-vector-machines-r (acedido em 04-12-2019)

Support Vector Machine

» Exemplo *Non-linear* SVM *Classifier**

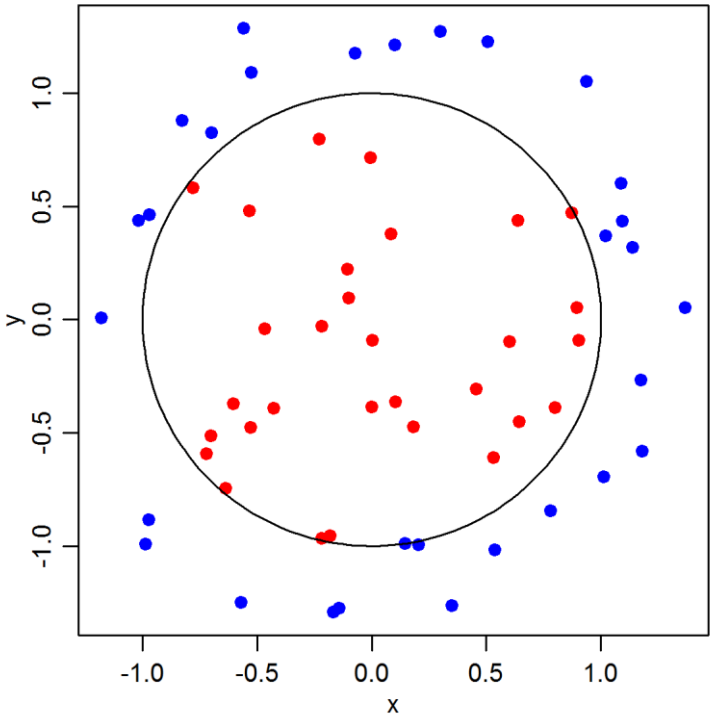

hiper-plano:

$$z = x_2 + y_2$$

*https://www.datacamp.com/community/tutorials/support-vector-machines-r (acedido em 04-12-2019)

Support Vector Machine

» Exemplo *Non-linear* SVM *Classifier**

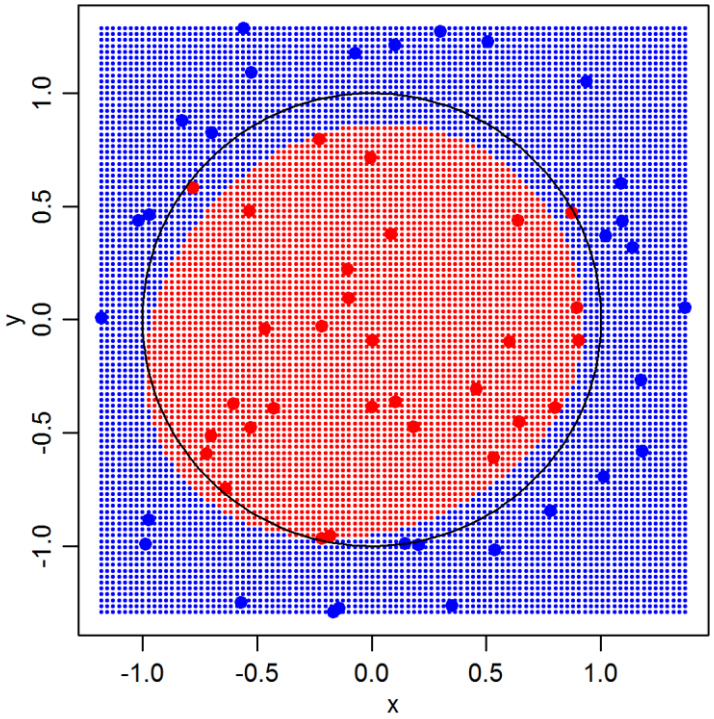

*https://www.datacamp.com/community/tutorials/support-vector-machines-r (acedido em 04-12-2019)

Support Vector Machine

» *Linear* SVM *Regression*

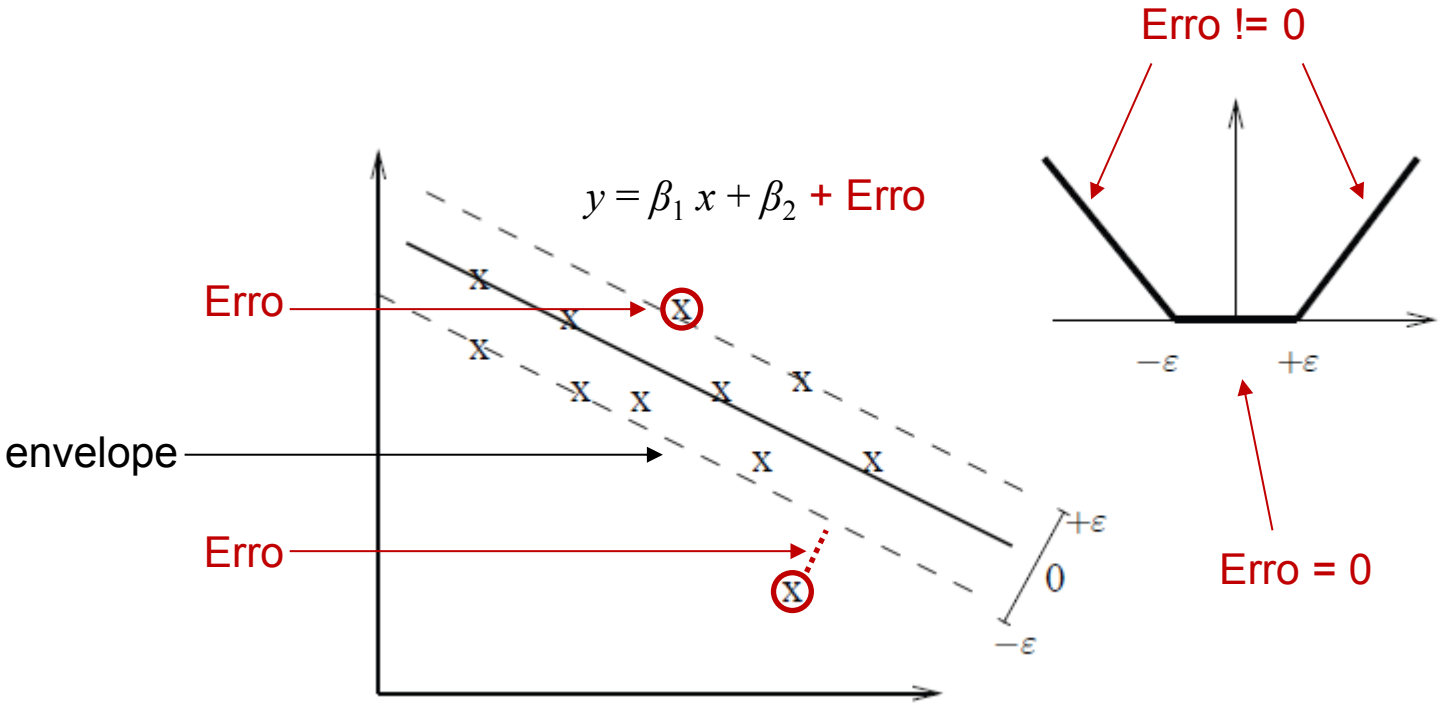

Figura 3.33 de Torga L. “Data Minig with R” (2017)

Support Vector Machine

» Exemplo *Linear* SVM *Regressor**

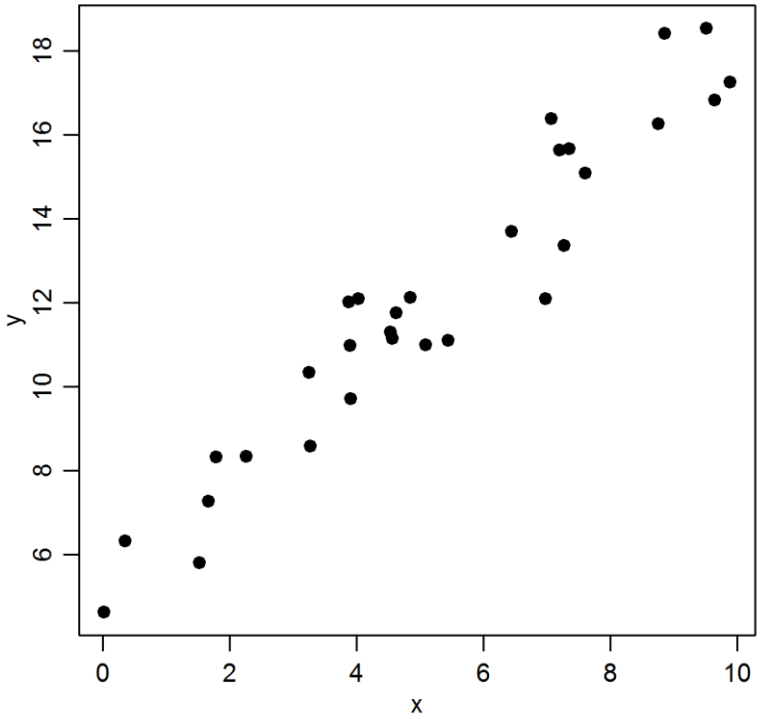

*https://www.datacamp.com/community/tutorials/support-vector-machines-r (acedido em 04-12-2019)

Support Vector Machine

» Exemplo *Linear* SVM *Regressor**

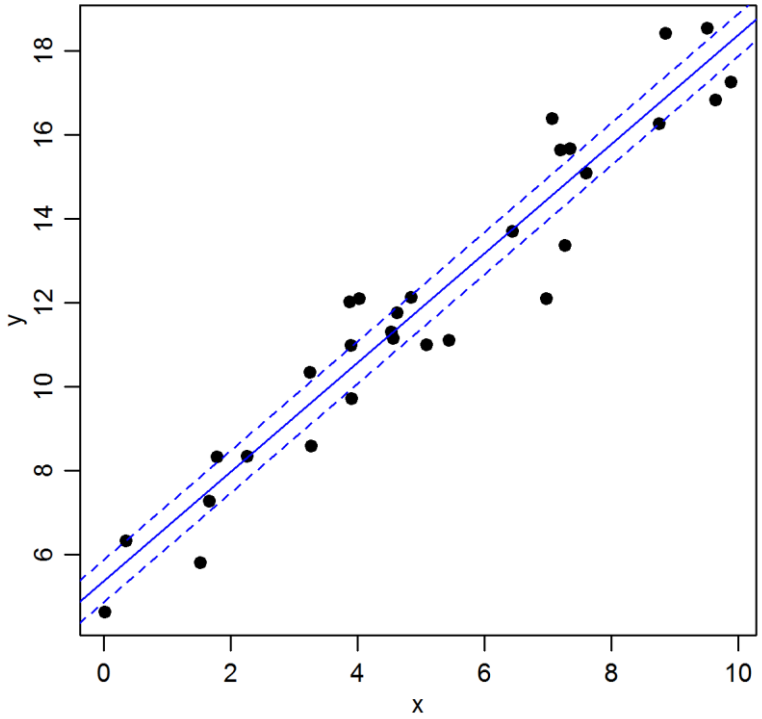

Linear SVM

$\varepsilon = 0.5$

*https://www.datacamp.com/community/tutorials/support-vector-machines-r (acedido em 04-12-2019)

Support Vector Machine

» Exemplo *Linear* SVM *Regressor**

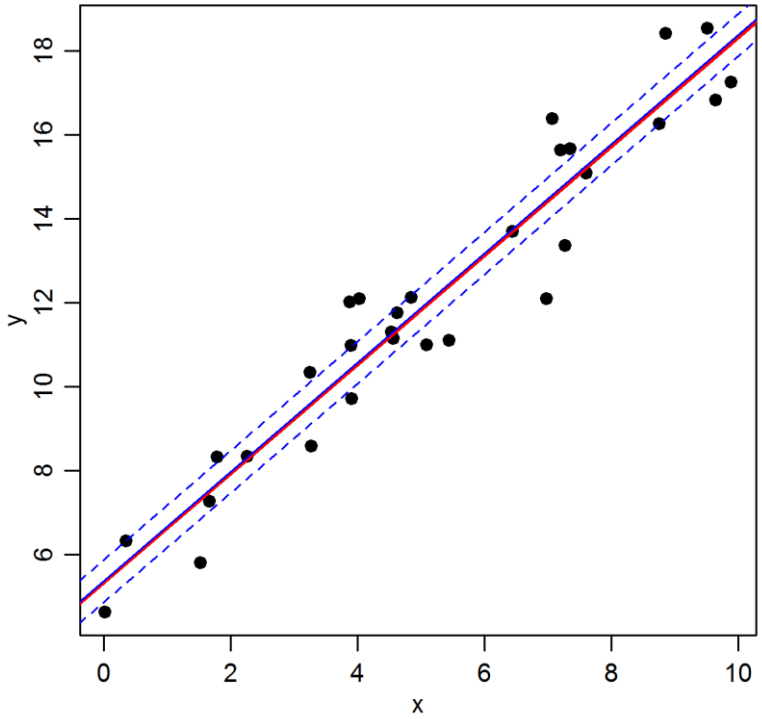

Linear SVM

$\varepsilon = 0.5$

Least-Squares

*https://www.datacamp.com/community/tutorials/support-vector-machines-r (acedido em 04-12-2019)

Support Vector Machine

» Algoritmos

Variável-alvo categórica

e.g. *C-classification* onde o *C* é o custo da classificação errada (soft-margin).

Variável-alvo contínua

e.g. *ε-regression* onde *ε* é o tamanho do "envelope" que define a "linha de regressão".

Support Vector Machine

» Vantagens e Desvantagens

- Grande capacidade de generalização.

- Ajusta modelos complexos aos dados sem necessidade da sua discriminação prévia;

- Tipicamente não tem problemas de convergência local, garantindo a procura pelo máximo global.

- Os parâmetros ajustados dos modelos não-lineares são de difícil interpretação (blackbox);

- Falta de objectividade na escolha dos parâmetros da função kernell.

» Exercícios

1. Considere os seguintes pontos:

x	y	classe
2	5	●
5	6	●
3	7	●
6	8	●

x	y	classe
1	1	■
2	3	■
4	2	■
5	4	■

1.1. Qual é o hiperplano paralelo ao eixo do x com a maior margem?

1.2. Este será o melhor hiperplano?

Support Vector Machine

» Exercícios (no **RapidMiner**)

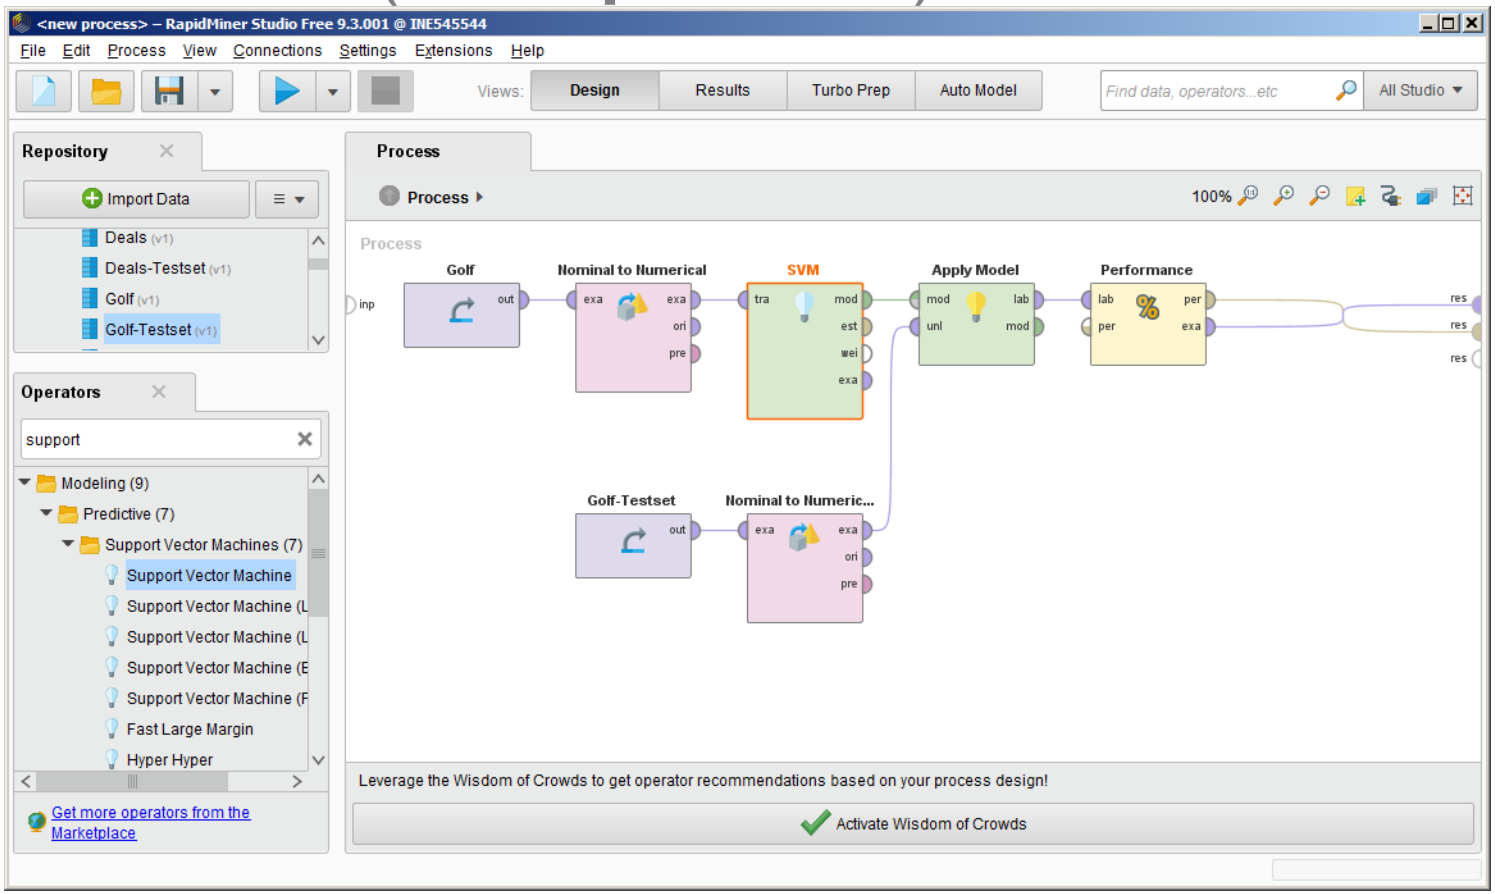

Support Vector Machine

» Exercícios (no **R**)

```
library("e1071")

trainset <- read.csv("../data/golf.csv",header=TRUE)
testset <- read.csv("../data/golf-testset.csv",header=TRUE)

#Recoding dummy variables
tmp1 <- model.matrix(~trainset[,"Outlook"] - 1)
tmp2 <- model.matrix(~trainset[,"Wind"] - 1)
colnames(tmp1) <- paste("Outlook",levels(trainset[,"Outlook"]),sep="_")
colnames(tmp2) <- paste("Wind",levels(trainset[,"Wind"]),sep="_")
trainset <- cbind(tmp1,tmp2,trainset[,c("Temperature","Humidity","Play")])

testset[,"Wind"] <- factor(testset[,"Wind"])
tmp1 <- model.matrix(~testset[,"Outlook"] - 1)
tmp2 <- model.matrix(~testset[,"Wind"] - 1)
```

Support Vector Machine

```
colnames(tmp1) <- paste("Outlook",levels(testset[,"Outlook"]),sep="_")
colnames(tmp2) <- paste("Wind",levels(testset[,"Wind"]),sep="_")
testset <- cbind(tmp1,tmp2,testset[,c("Temperature","Humidity","Play")])

#Perform SVM fit
set.seed(12345)
mod <- svm(Play ~ .,                          #model design
                  trainset,                   #training set
                  scale=TRUE,                 #scaling stored for testing
                  type="C-classification",    #SVM algorithm
                  kernel="radial",            #kernel type
                  gamma=1.0,                  #kernel gamma
                  cost=1.0,                   #C-constant (cost)
                  tolerance=0.001)            #convergence epsilon
```

Support Vector Machine

```
#Test model
res <- predict(mod,                          #model
               testset)                      #testing set

#Confusion Matrix
conf_mat <- table(testset[,c("Play")],res)
conf_mat

#Error rate
err_rt <- 100*(sum(conf_mat) - sum(diag(conf_mat)))/sum(conf_mat)
err_rt
```

Computação Natural

» Enquadramento

- Algoritmos que se inspiram em processos que ocorrem na Natureza;
- Usados quando os métodos matemáticos tradicionais não podem ser usados ou são demasiado "dispendiosos";
- Algoritmos desenvolvidos para procura e otimização (i.e. seleção do melhor elemento de um conjunto);
- São normalmente constituídos por heurísticas de procura acopladas a funções de custo (minimização) ou de *fitness* (maximização);

e.g. inteligência de enxames e computação evolutiva.

Computação Natural

» Algoritmos

Inteligência de Enxames (e.g. *Particle Swarm Optimization)*

Baseada na inteligência colectiva de uma população de agentes que interagem a nível local. Os agentes são caracterizados pela sua posição e velocidade, e são influenciados pelo seu conhecimento e pelo conhecimento da sua vizinhança.

Computação Evolutiva (e.g. Algoritmos Genéticos)

Baseada na evolução natural dos sistemas biológicos, em que uma população de agentes em evolução (mutação) é selecionada (seleção) e troca informação entre si (crossover).

» Enquadramento

- Proposto em 1995 por Everhart e Kennedy;

- Baseado no comportamento de grupo de animais (e.g. bandos de aves, cardumes de peixes);

- Utiliza uma populações de agentes (tal como os AGs) para explorar iterativamente o espaço de atributos até atingir determinada condição de paragem;

- Cada agente (ou partícula) interage com a sua vizinhança influenciando a sua trajectória;

- As posições no espaço de atributos é caracterizada por uma função de custo que deve ser minimizada.

» Algoritmo

- Cada partícula *i* é caracterizada por:

x_i, posição actual

p_i, melhor posição histórica

I_i, melhor posição histórica da vizinhança

v_i, velocidade

- Outros parâmetros:

$w(t)$, inércia dinâmica (facilita procura)

φ_1 φ_2, coeficientes de aceleração (impõe o peso dos componentes)

$f(x)$, função custo

» Algoritmo

Atualização da velocidade:

$$v_{t+1} = w_t v_t + \varphi_1 \cdot (p_t - x_t) + \varphi_2 \cdot (I_t - x_t)$$

inércia — componente cognitiva — componente social

Atualização da posição:

$$x_{t+1} = x_t + v_t$$

- A função custo $f(x)$ actua em p_i e em I_i .

» Algoritmo

```
Gerar uma população inicial de partículas;
Gerar uma velocidade inicial das partículas;
WHILE critério de paragem não é atingido DO
        FOR cada partícula i DO
                IF f(x_i) < f(p_i) THEN p_i = x_i
                I_i = min(p_vizinhança)
                Actualização_da_velocidade( )
                Actualização_da_posição( )
        END
END
```

» Vantagens e Desvantagens

- Algoritmo é tendencialmente mais eficiente que os AG;

- Processo de optimização robusto a ruído e a máximos locais.

- Alguma dificuldade em selecionar os parâmetros dos modelos (que influenciam posição e velocidade) e critérios de paragem;

- A construção da função de custo requer algum cuidado;

- Podem-se tornar computacionalmente intensas com números elevados de atributos (i.e. *curse of dimensionality*).

Algoritmos Genéticos

» Enquadramento

- Algoritmos de optimização inspirados na evolução natural de sistemas biológicos (popularizados por John Holland nos anos 70);

- Utilizam população de soluções (i.e. agentes), cada uma constituída por sequências de variáveis (i.e. cromossomas). Cada solução tem valores diferentes para cada variável (i.e. genes);

- As populações de soluções são avaliadas por função de *fitness*, e geram novas gerações de soluções;

- A população evolui ao longo das gerações através de mecanismos evolutivos (seleção, recombinação, mutação, …).

Algoritmos Genéticos

» Mecanismos evolutivos

Seleção: as “melhores” soluções passam para a geração seguinte;

Recombinação: troca de informação entre soluções;

Mutação: a transferência de informação entre gerações é imperfeita;

outros (e.g. Migração): entrada de soluções novas na população.

Algoritmos Genéticos

» Algoritmo

- Cada indivíduo é caracterizada por:

x_i, vector de valores dos atributos (cromossoma)

- Parâmetros do modelo evolutivo:

m, taxa de mutação

r, taxa de *crossover*

Outros parâmetros:

$f(x)$, função *fitness*

Algoritmos Genéticos

» Algoritmo

```
Gerar uma população inicial de indivíduos;
WHILE critério de paragem não é atingido DO
        Avaliar fitness de cada indivíduo;
        Selecionar pais através da sua fitness;
        Aplicar crossover entre pais;
        Aplicar mutações aos pais;
END
```

Algoritmos Genéticos

» Exemplo*

- Um explorador vai para a selva;
- Mochila com capacidade de 20Kg;
- Conjunto de itens caracterizados por pontos de sobrevivência e peso;

- Qual o melhor conjunto de itens?

ITEM	SURV. PTS.	WEIGHT
pocketknife	10.00	1.00
beans	20.00	5.00
potatoes	15.00	10.00
unions	2.00	1.00
sleeping bag	30.00	7.00
rope	10.00	5.00
compass	30.00	1.00

**Knapsack problem* é um problema de otimização clássico do século XIX. Adaptado de Marek Obitko. http://www.r-bloggers.com/genetic-algorithms-a-simple-r-example/

Algoritmos Genéticos

» Exemplo*

- O número possível de instâncias é $2^7=128$;
- Maximizar pontos de sobrevivência, mas mantendo peso < 20Kg.

Exemplos de instâncias:

pkt-knife	beans	potatoes	unions	sleep bag	rope	compass	Fitness
0	1	0	1	1	0	0	52
1	0	0	0	1	1	1	80
0	0	1	0	1	1	0	0

**Knapsack problem* é um problema de otimização clássico do século XIX. Adaptado de Marek Obitko. http://www.r-bloggers.com/genetic-algorithms-a-simple-r-example/

Algoritmos Genéticos

» Vantagens e Desvantagens

- Algoritmo é facilmente interpretável;

- Processo de optimização robusto a ruído e a máximos locais;

- Facilmente paralelizável, (i.e. redução de tempo de computação).

- Rapidez de convergência depende da escolha dos parâmetros do modelo e dos critérios de paragem;

- A função de *fitness* requer tratamento analítico;

- Número de variáveis utilizado influencia grandemente a intensidade computacional (i.e. *curse of dimensionality*).

» Exercícios

1. Crie 10 instâncias para o "problema no *Knapsack*". Considere uma taxa de seleção de 50% (as melhores 5 instâncias contribuem com 2 cópias cada). Como *crossover*, escolha 3 pares diferentes das instâncias selecionadas e troque os últimos 3 genes. Finalmente, insira uma mutação aleatória em cada instância. Repita o processo 2 vezes e indique a solução final.

Algoritmos Genéticos

» Exercícios (no **R**)

```
library("GA")

#Define data
n <- c("pocketknife","beans","potatoes","unions","sleepingbag","rope","compass")
p <- c(10,20,15,2,30,10,30)            #profits
w <- c(1,5,10,1,7,5,1)                 #weights
W <- 20                                #knapsack capacity

#Define fitness function
knapsack <- function(x){
    if(sum(x*w) > W)
        return(0)
    else
          return(sum(x*p))
}
```

Algoritmos Genéticos

```
#Run SGA
SGA <- ga(type="binary",
  fitness=knapsack,                    #fitness function
  nBits=length(n),                     #chromosome length
  popSize=100,                         #population size
  pcrossover=0.8,                      #crossover rate
  pmutation=0.1,                       #mutation rate
  elitism=5,                           #number of best individuals sure to be selected
  maxiter=100,                         #number of generations
  names=n,                             #name of "genes"
  seed=12345)                          #random seed

res <- SGA@solution
print(res)                             #best solution
sum(res)                               #total number of selected items
sum(res*p)                             #total profit of selected items
sum(res*w)                             #total weight of selected items
```

Algoritmos Genéticos

```
#Plot model
plot(SGA@summary[,"mean"],type="l",ylab="mean fitness",xlab="iteration",lwd=2)
barplot(SGA@fitness,ylab="fitness",xlab="",col="blue")
```

Exemplos *Data Analytics*

» EU BD Hackathon 2017

- **Objectivo:** ajudar a definir políticas sobre o mercado laboral
- **Organização:** Eurostat and CEDEFOP
- **Projecto:**

  - Caracterização do Mercado Laboral.

  - Estabelecer associações entre indicadores relevantes (e.g. Mobilidade Laboral na UE) e características do mercado laboral.

https://github.com/jsollari/EUhackathon2017

https://ec.europa.eu/eurostat/web/products-statistical-working-papers/-/KS-TC-18-002

Exemplos *Data Analytics*

» Dados: caracaterísticas do Mercado Laboral

- "reg_dem" – informação demográfica
- "earn" – estrutura de ganhos
- "educ_uoe_fin" – gastos públicos em educação
- "ilc" – rendimento e condições de vida
- "employ" – informação sobre o emprego
- "nama10" – contas nacionais
- "educ_part" – informação sobre educação

7 datasets, **17** main variables

Exemplos *Data Analytics*

» Dados: caracaterísticas do Mercado Laboral

- "reg_dem" by **age**
- "earn" by **occupation** and **economic activity**
- "educ_uoe_fin"
- "ilc"
- "employ" by **age**, **education level**, **economic activity**
- "nama10"
- "educ_part"

7 datasets, **17** main variables, **76** variables

Exemplos *Data Analytics*

» Dados: Mobilidade Laboral na UE

- "lfso_14leeow" – informação sobre a força laboral

1 dataset, **1** main variable

subjects: **25 (NUTS0)**

Exemplos *Data Analytics*

» *Clustering* de países EU (no **RapidMiner**)

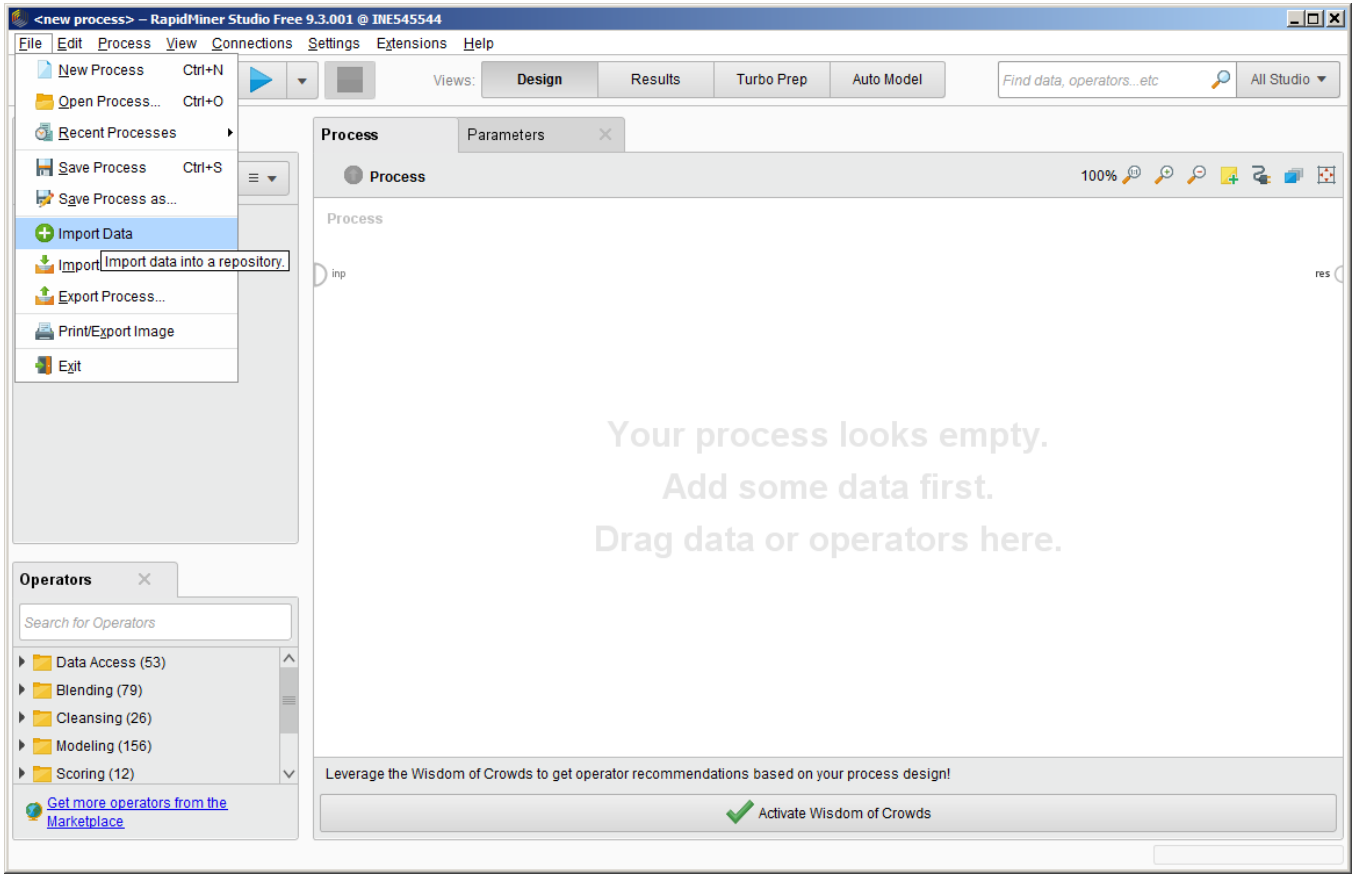

Exemplos *Data Analytics*

» *Clustering* de países EU (no **RapidMiner**)

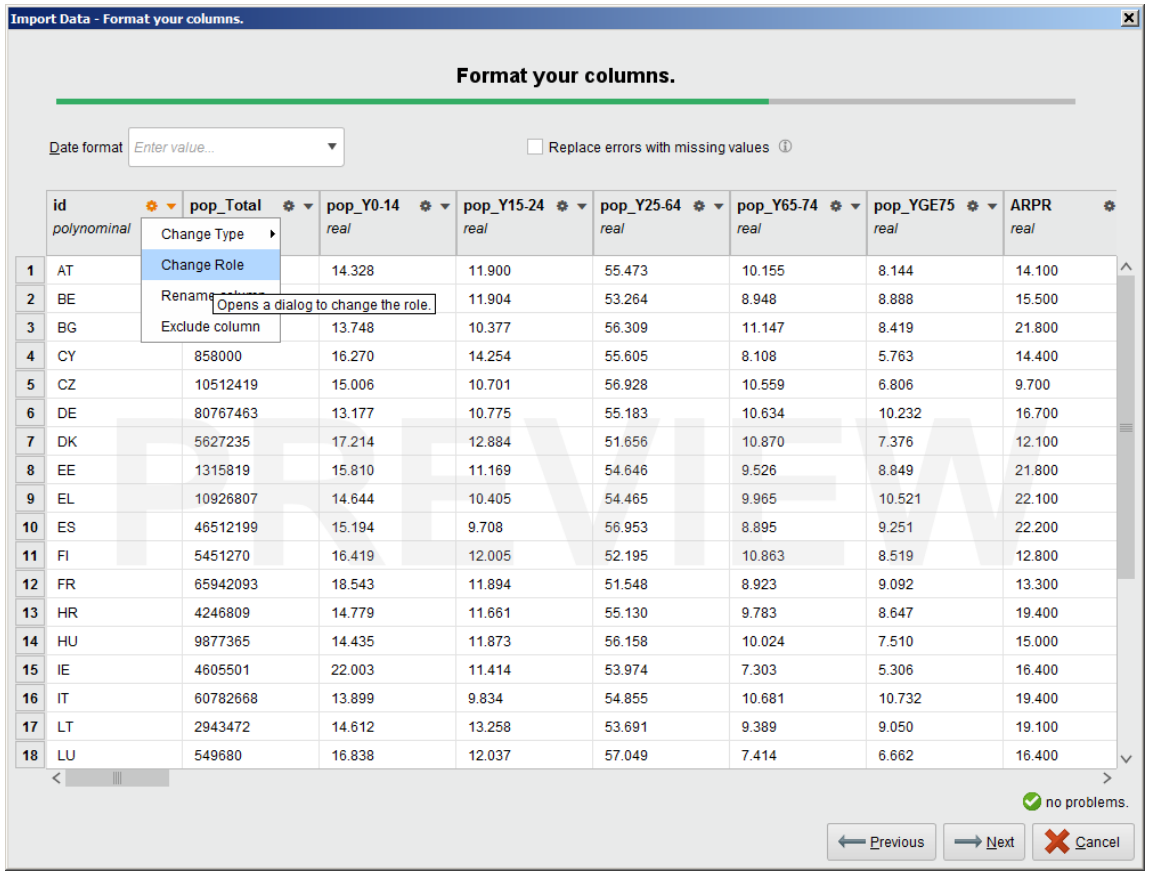

	id	pop_Total	pop_Y0-14	pop_Y15-24	pop_Y25-64	pop_Y65-74	pop_YGE75	ARPR
	polynominal		*real*	*real*	*real*	*real*	*real*	*real*
1	AT		14.328	11.900	55.473	10.155	8.144	14.100
2	BE			11.904	53.264	8.948	8.888	15.500
3	BG		13.748	10.377	56.309	11.147	8.419	21.800
4	CY	858000	16.270	14.254	55.605	8.108	5.763	14.400
5	CZ	10512419	15.006	10.701	56.928	10.559	6.806	9.700
6	DE	80767463	13.177	10.775	55.183	10.634	10.232	16.700
7	DK	5627235	17.214	12.884	51.656	10.870	7.376	12.100
8	EE	1315819	15.810	11.169	54.646	9.526	8.849	21.800
9	EL	10926807	14.644	10.405	54.465	9.965	10.521	22.100
10	ES	46512199	15.194	9.708	56.953	8.895	9.251	22.200
11	FI	5451270	16.419	12.005	52.195	10.863	8.519	12.800
12	FR	65942093	18.543	11.894	51.548	8.923	9.092	13.300
13	HR	4246809	14.779	11.661	55.130	9.783	8.647	19.400
14	HU	9877365	14.435	11.873	56.158	10.024	7.510	15.000
15	IE	4605501	22.003	11.414	53.974	7.303	5.306	16.400
16	IT	60782668	13.899	9.834	54.855	10.681	10.732	19.400
17	LT	2943472	14.612	13.258	53.691	9.389	9.050	19.100
18	LU	549680	16.838	12.037	57.049	7.414	6.662	16.400

Exemplos *Data Analytics*

» *Clustering* de países EU (no **RapidMiner**)

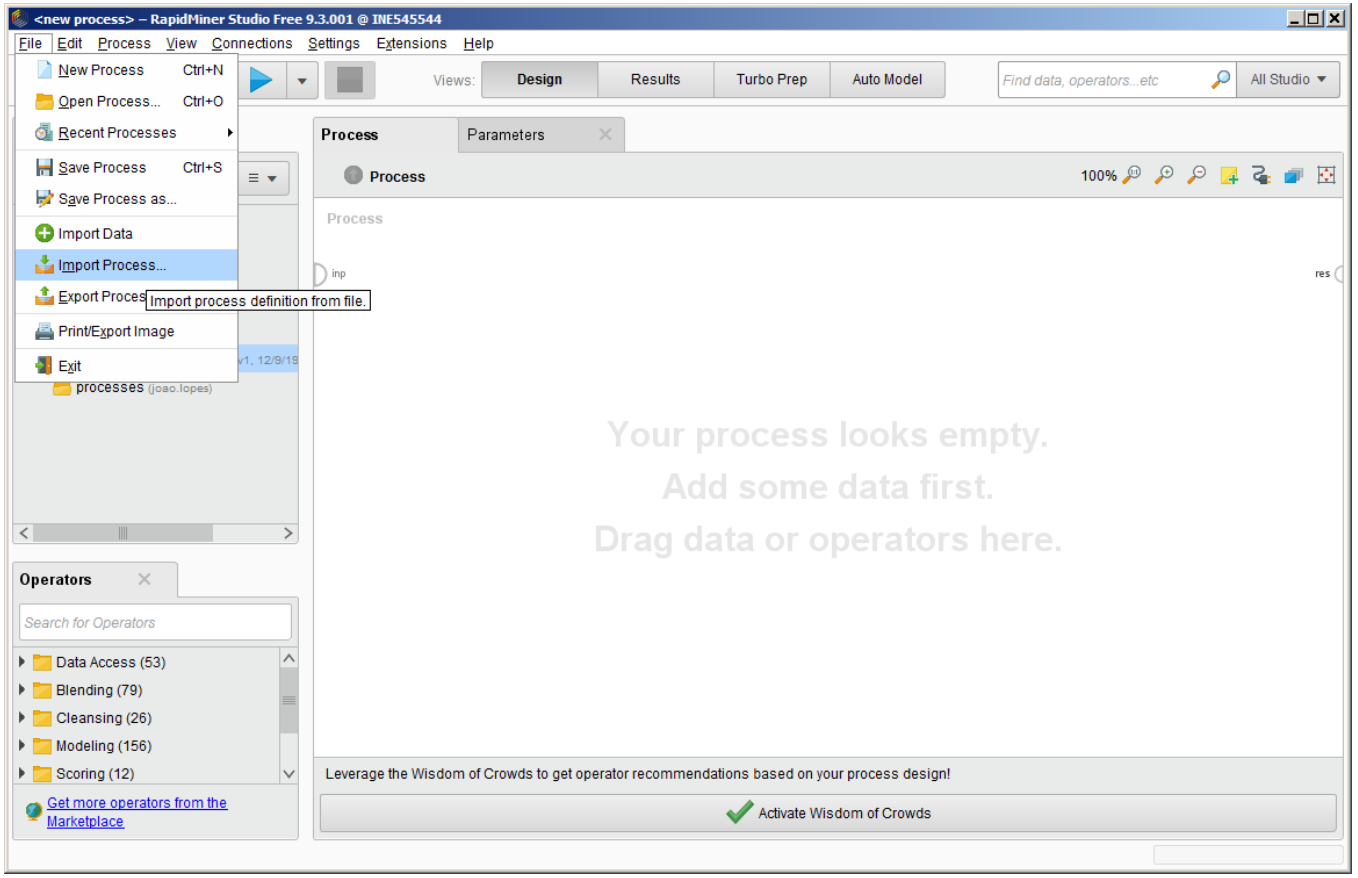

Exemplos *Data Analytics*

» *Clustering* de países EU (no **RapidMiner**)

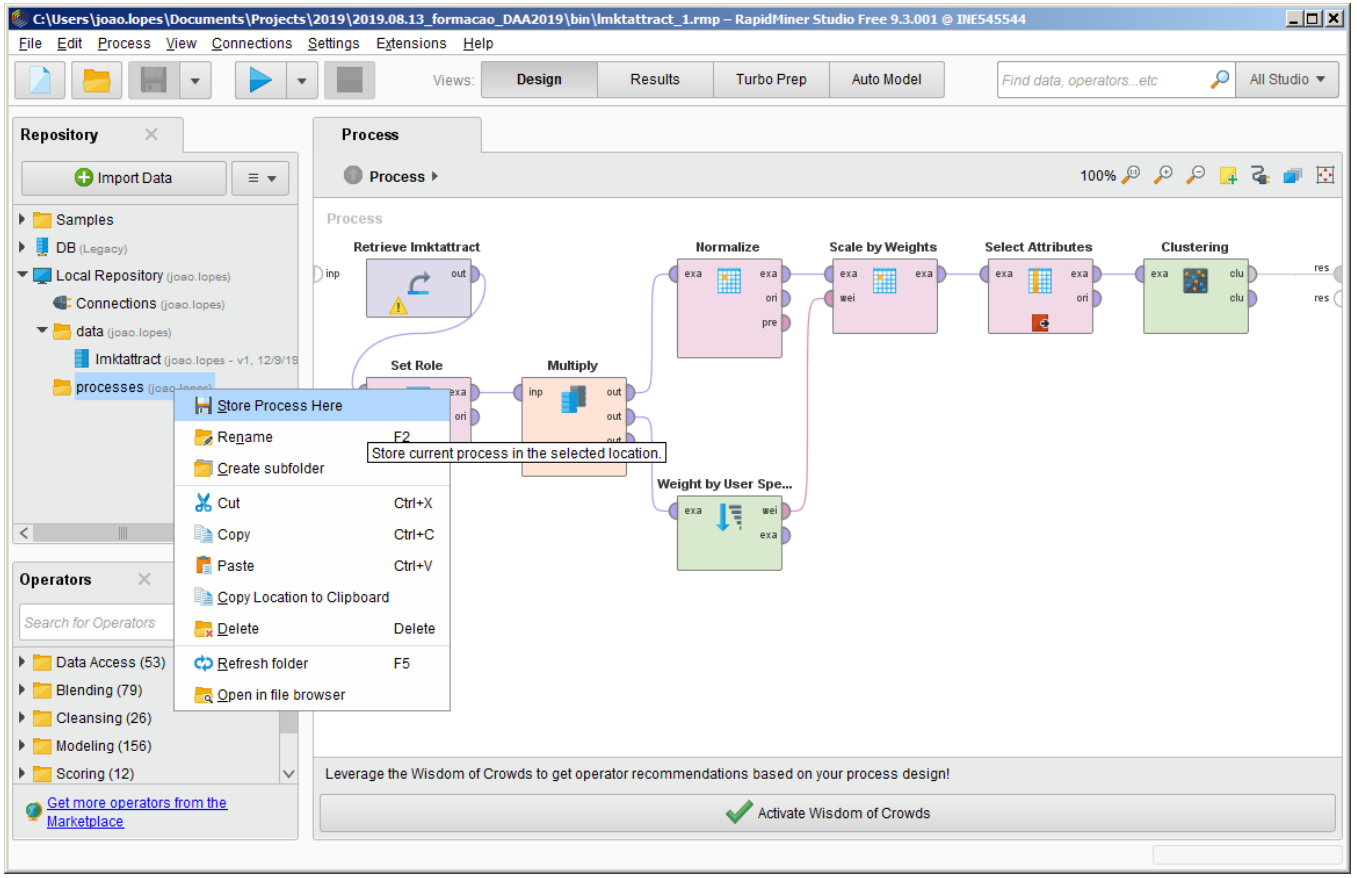

Exemplos *Data Analytics*

» *Clustering* de países EU (no **RapidMiner**)

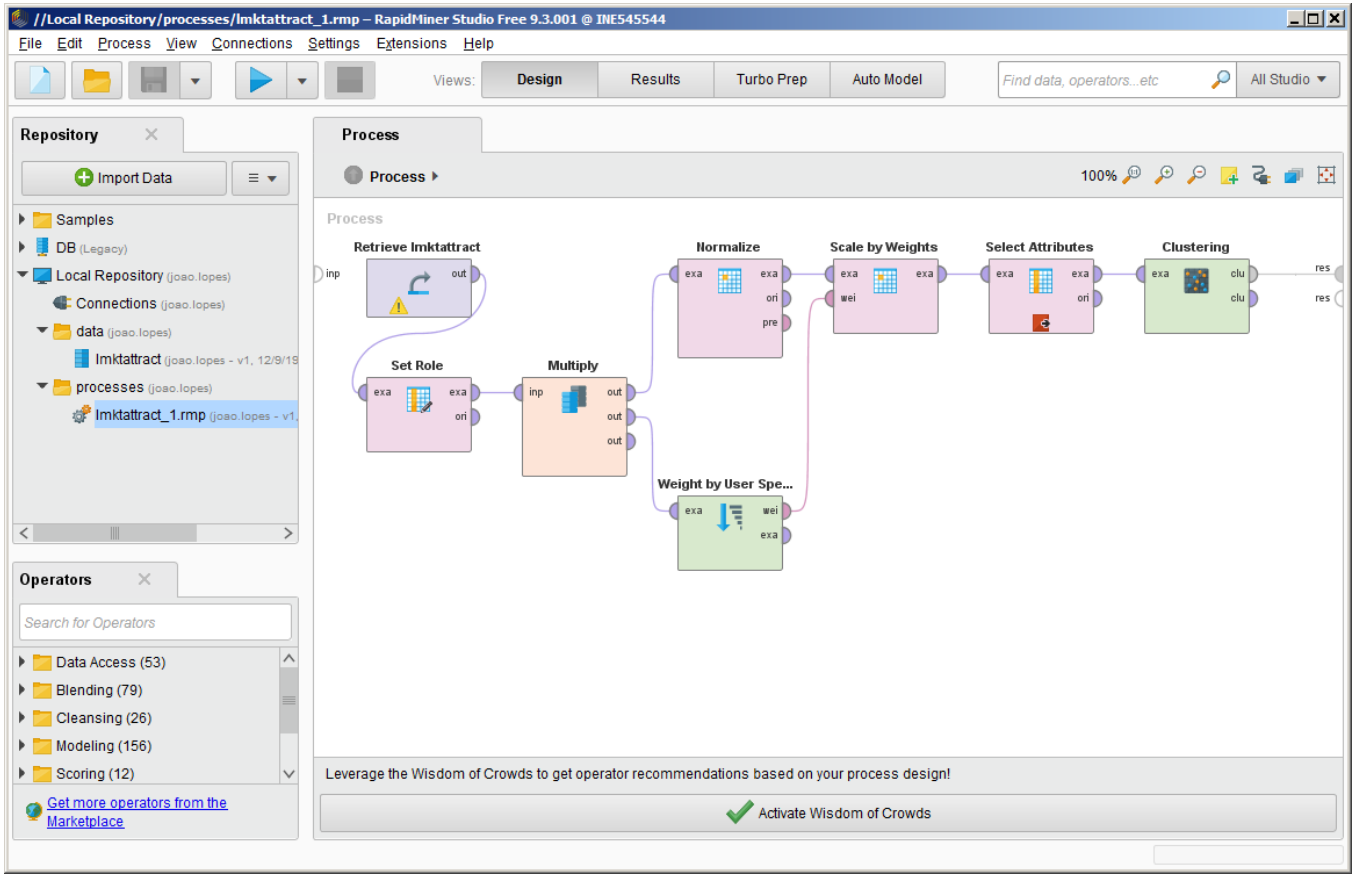

Exemplos *Data Analytics*

» *Clustering* de países EU (no **R**)

```
#1. FUNCTIONS
source("misc_v2.3.r")

#2. READ DATA
f1 <- "../data/lmktattract.csv"
x_all <- read.table(file=f1,header=TRUE,sep=",",dec=".",row.names=1)

# 3. ANALYSE DATA
set.seed(12345)
main1 <- "Labour market attractiveness"  #title for plots
col1 <- c(rbind(hsv(h=seq(0,1,len=8),s=1/3,v=5/5)[1:7],  #very light
                hsv(h=seq(0,1,len=8),s=2/3,v=5/5)[1:7],  #light
                hsv(h=seq(0,1,len=8),s=3/3,v=5/5)[1:7],  #normal
                hsv(h=seq(0,1,len=8),s=3/3,v=4/5)[1:7])) #dark
names(col1) = rownames(x_all)            #colours for EU28
```

Exemplos *Data Analytics*

```
#normalize and scale data
n_all <- c(1,5,1,1,1,1,1,6,2,3,20,2,1,1,1,1,27,1)
w_all <- rep(1/n_all,times=n_all)
x_norm <- t(apply(scale(x_all),1,function(x){x*w_all}))
x_dist <- dist(x_norm,method="euclidean") #calculate distances

#perform Social Network Analysis
set.seed(12345)
f1 <- "../results/lmktattract_1/net"
plot_sna_v2(x_dist,col1=col1,edge_thr=0.65,f1=f1,main=main1)

#perform Partition Around Medoids analysis
f1 <- "../results/lmktattract_1/pam"
plot_pam_v2(x_dist,col1=col1,f1=f1,main=main1)
kbest <- 10
f1 <- paste("../results/lmktattract_1/pam_grps",kbest,sep="")
plot_pam_v2(x_dist,kbest=kbest,col1=col1,f1=f1,main=main1)
```

Exemplos *Data Analytics*

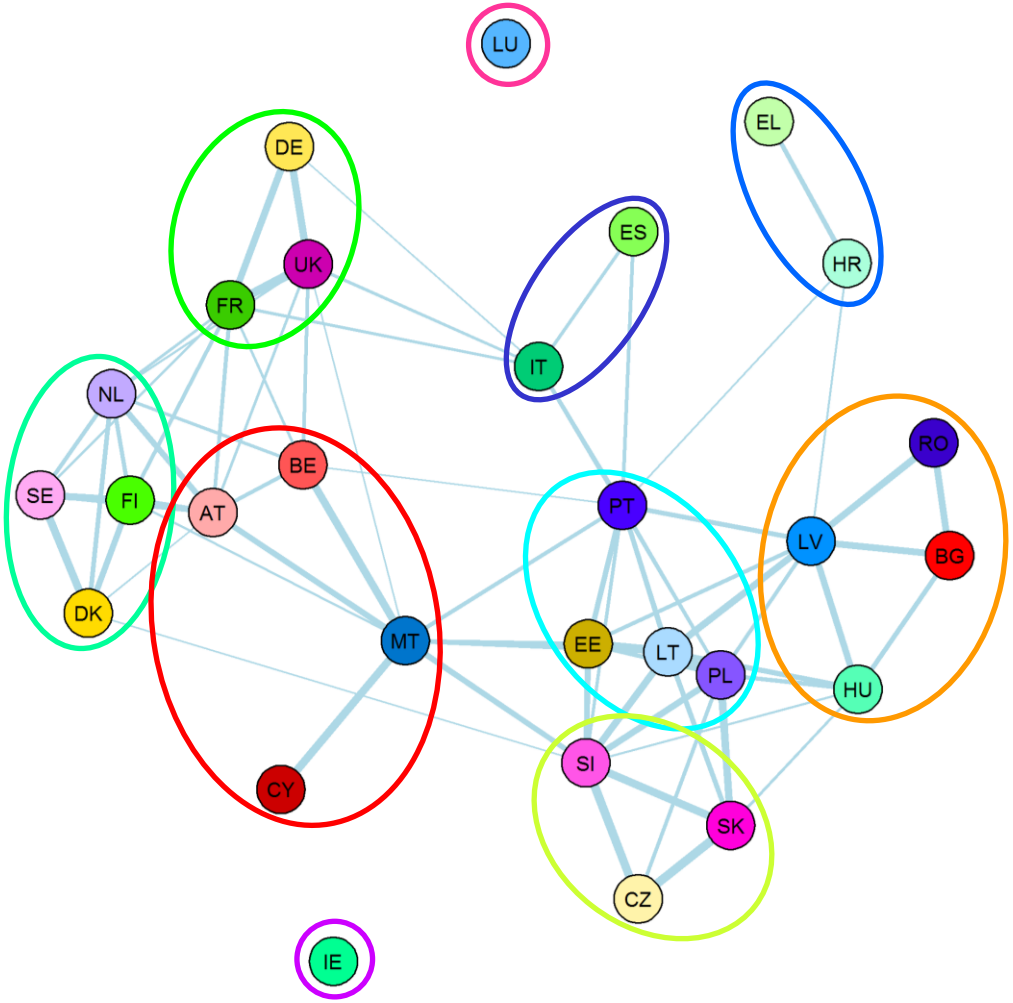

Exemplos *Data Analytics*

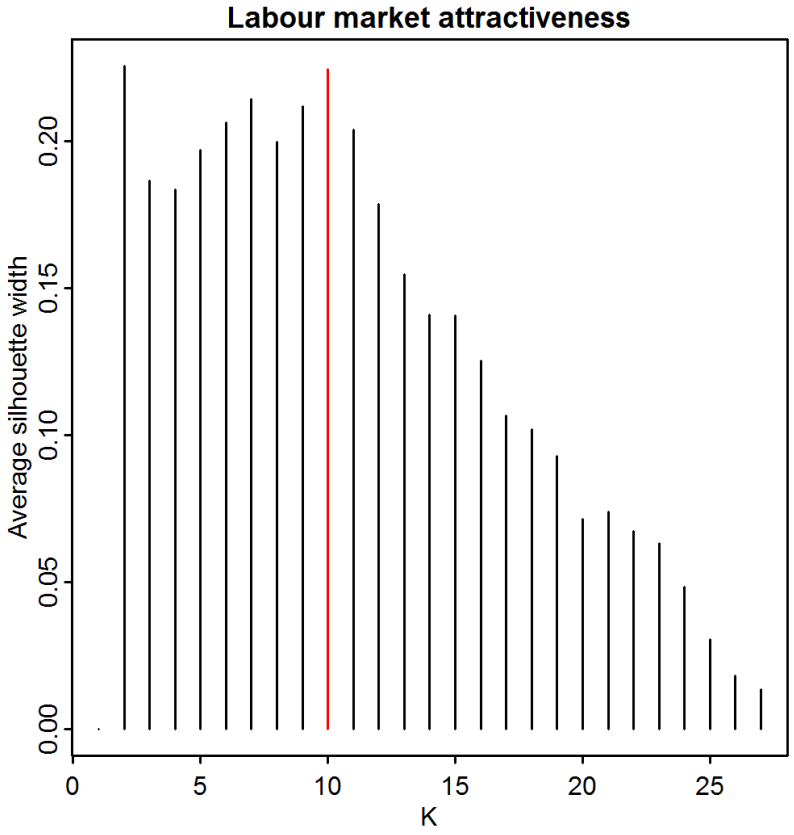

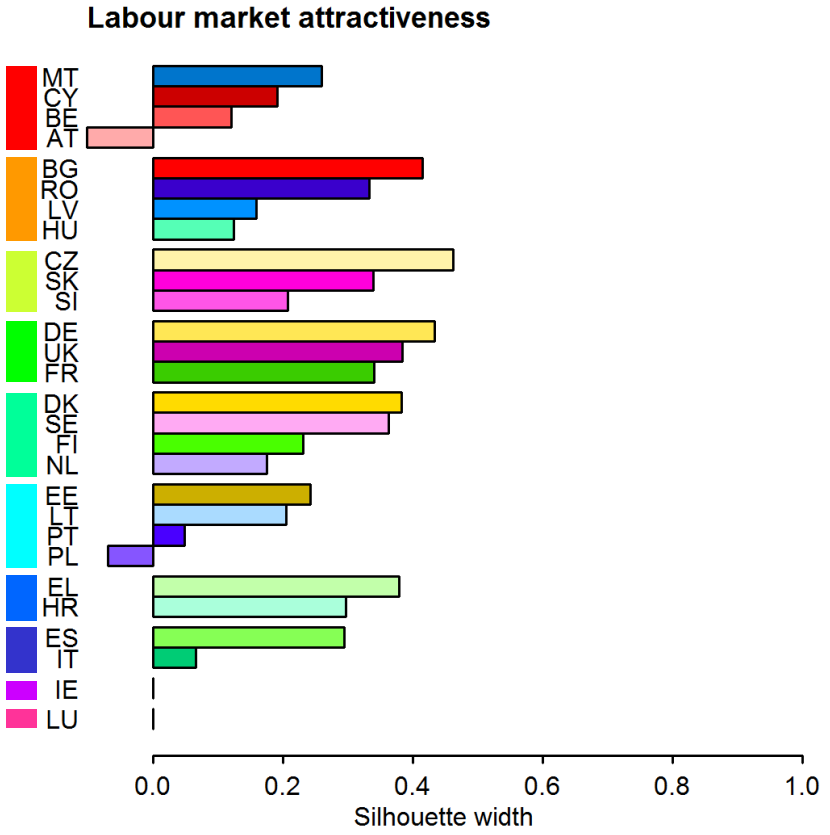

Exemplos *Data Analytics*

» Relação entre indicadores (no **RapidMiner**)

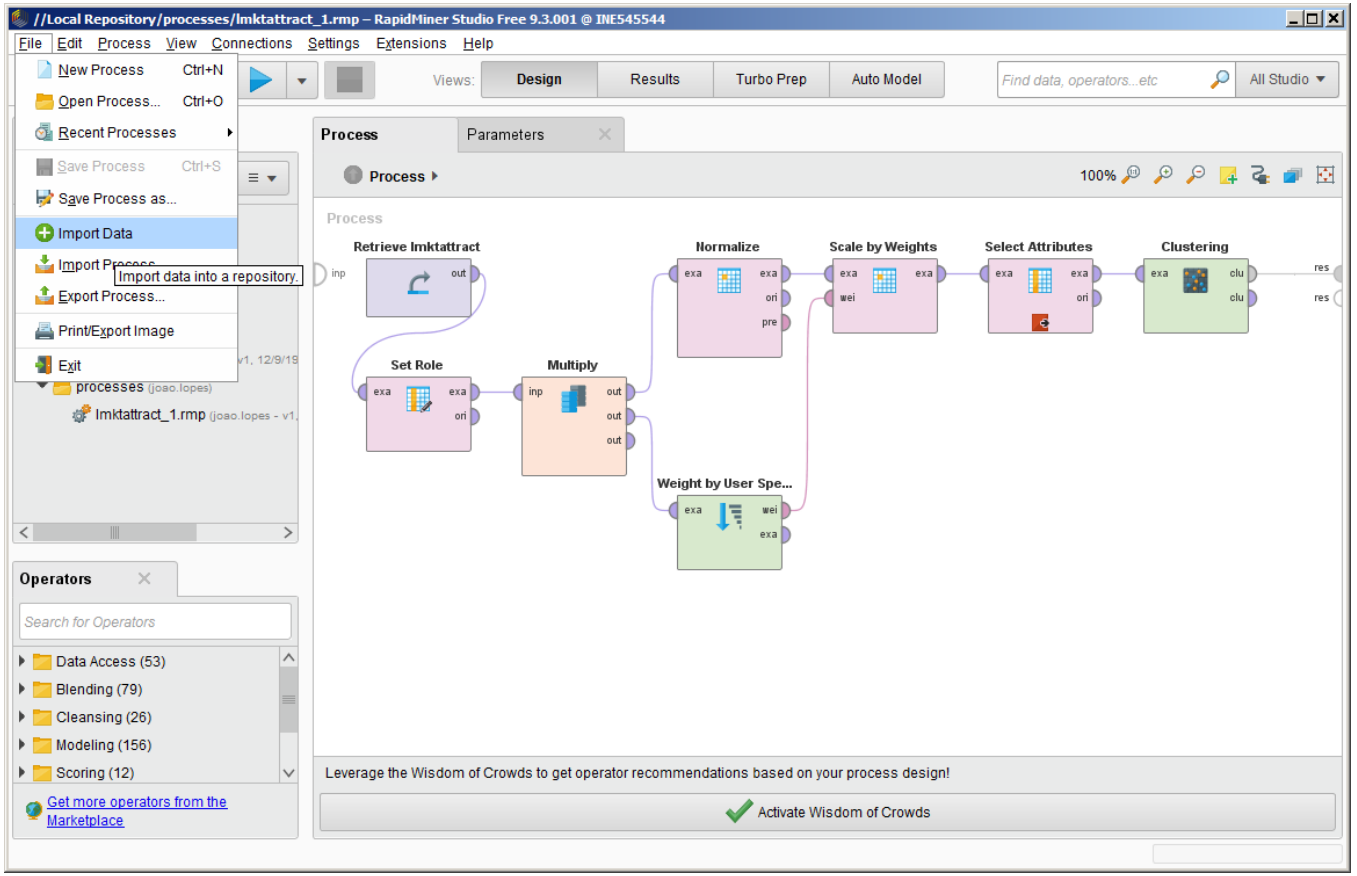

Exemplos *Data Analytics*

» Relação entre indicadores (no **RapidMiner**)

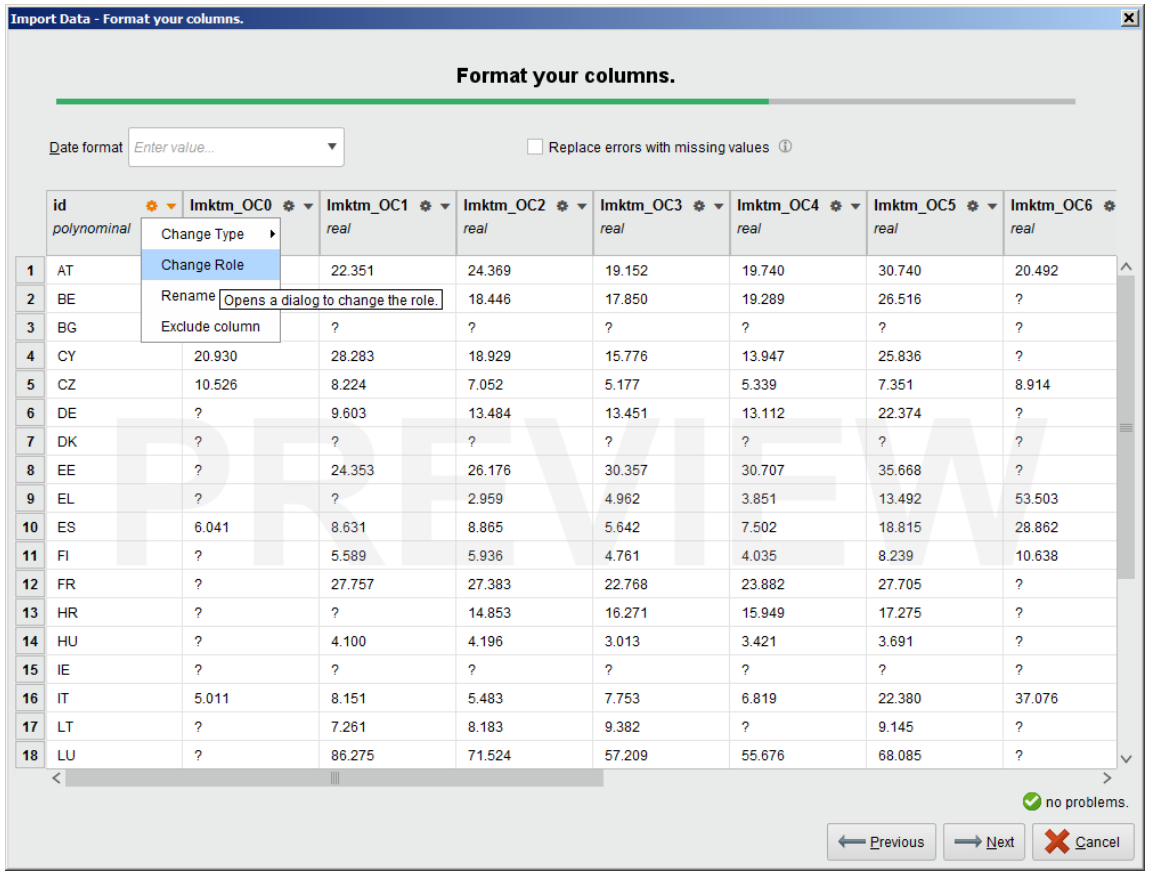

	id	lmktm_OC0	lmktm_OC1	lmktm_OC2	lmktm_OC3	lmktm_OC4	lmktm_OC5	lmktm_OC6
	polynominal		*real*	*real*	*real*	*real*	*real*	*real*
1	AT		22.351	24.369	19.152	19.740	30.740	20.492
2	BE			18.446	17.850	19.289	26.516	?
3	BG		?	?	?	?	?	?
4	CY	20.930	28.283	18.929	15.776	13.947	25.836	?
5	CZ	10.526	8.224	7.052	5.177	5.339	7.351	8.914
6	DE	?	9.603	13.484	13.451	13.112	22.374	?
7	DK	?	?	?	?	?	?	?
8	EE	?	24.353	26.176	30.357	30.707	35.668	?
9	EL	?	?	2.959	4.962	3.851	13.492	53.503
10	ES	6.041	8.631	8.865	5.642	7.502	18.815	28.862
11	FI	?	5.589	5.936	4.761	4.035	8.239	10.638
12	FR	?	27.757	27.383	22.768	23.882	27.705	?
13	HR	?	?	14.853	16.271	15.949	17.275	?
14	HU	?	4.100	4.196	3.013	3.421	3.691	?
15	IE	?	?	?	?	?	?	?
16	IT	5.011	8.151	5.483	7.753	6.819	22.380	37.076
17	LT	?	7.261	8.183	9.382	?	9.145	?
18	LU	?	86.275	71.524	57.209	55.676	68.085	?

Exemplos *Data Analytics*

» Relação entre indicadores (no **RapidMiner**)

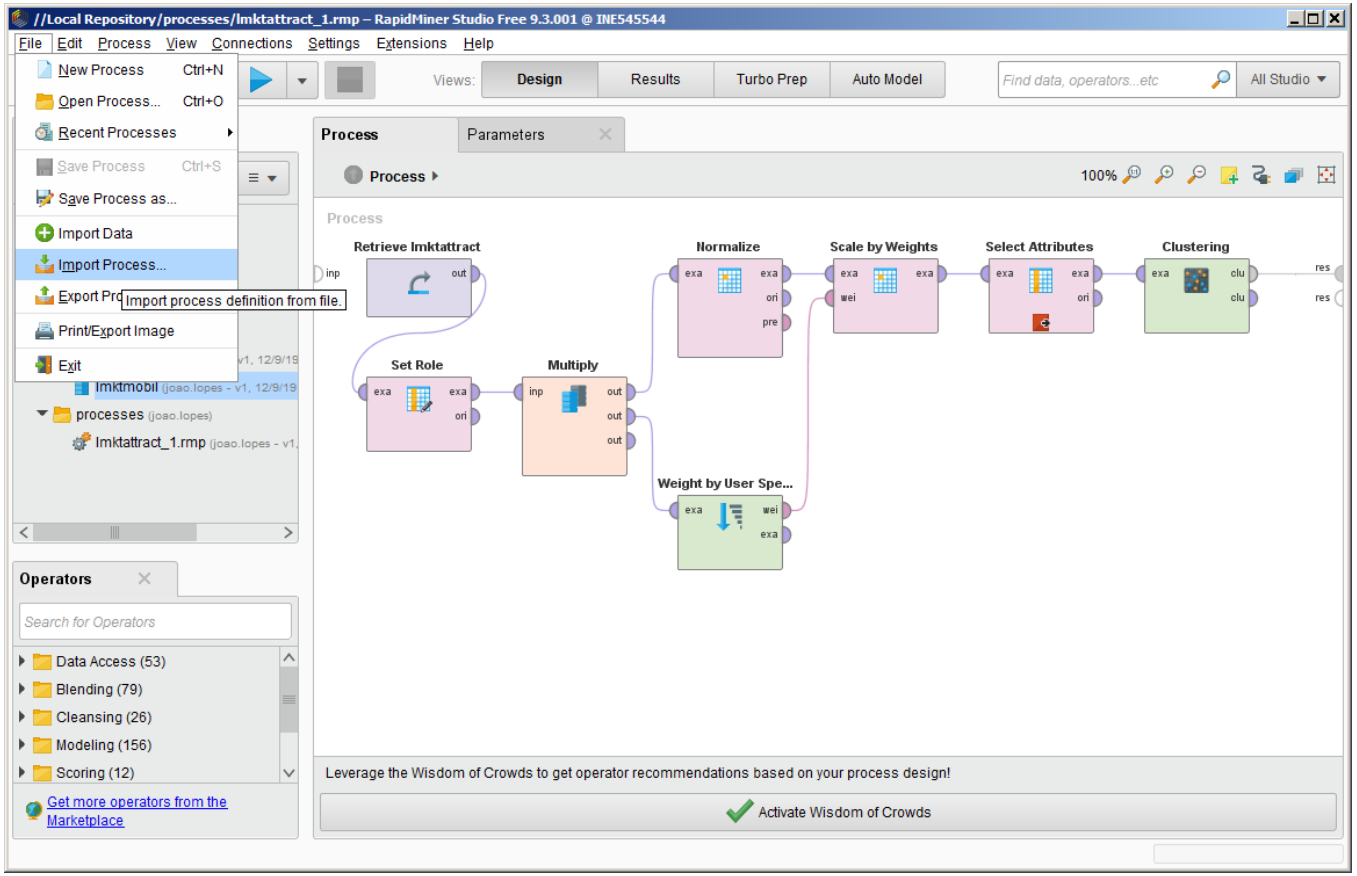

Exemplos *Data Analytics*

» Relação entre indicadores (no **RapidMiner**)

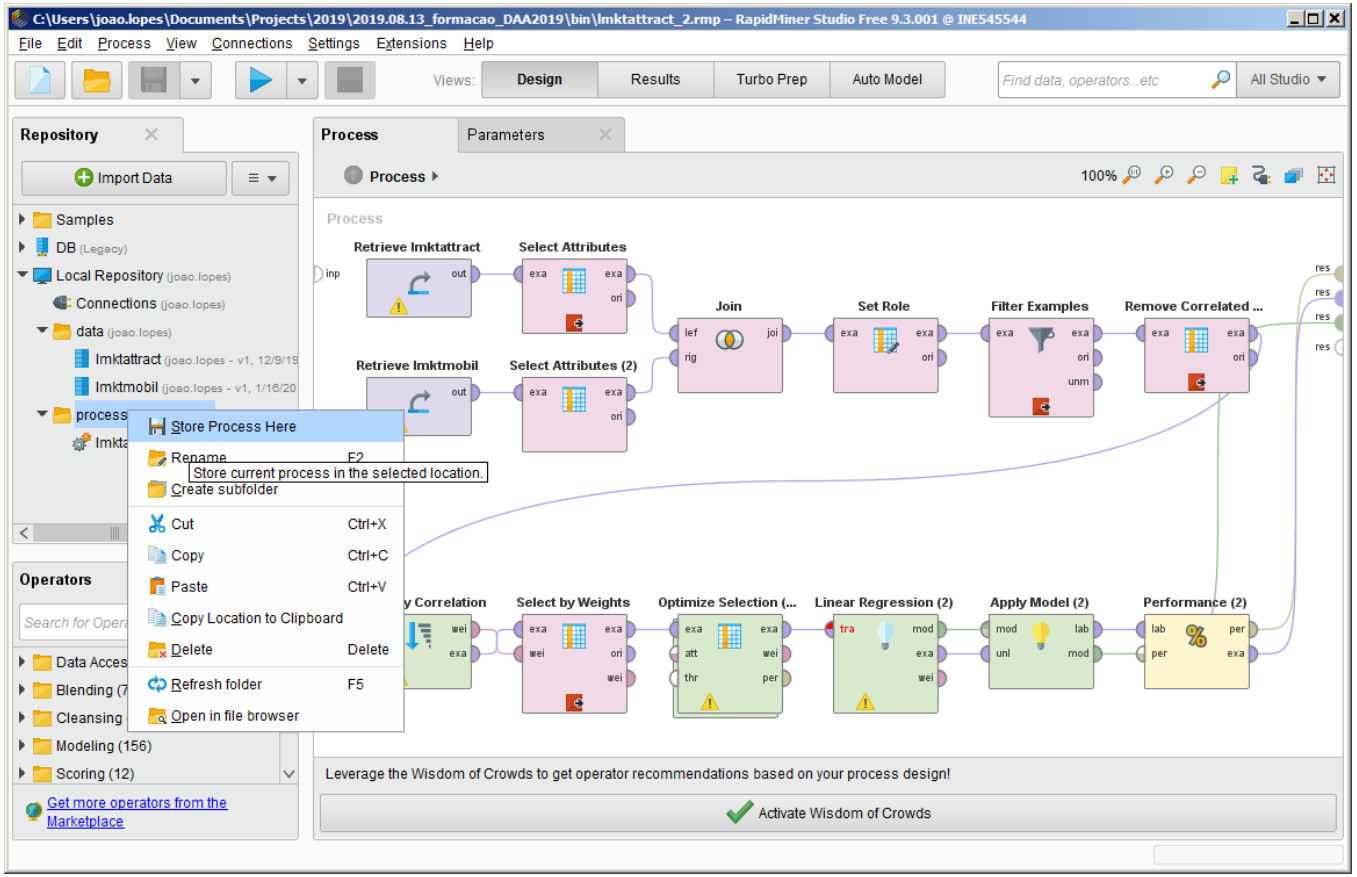

Exemplos *Data Analytics*

» Relação entre indicadores (no **RapidMiner**)

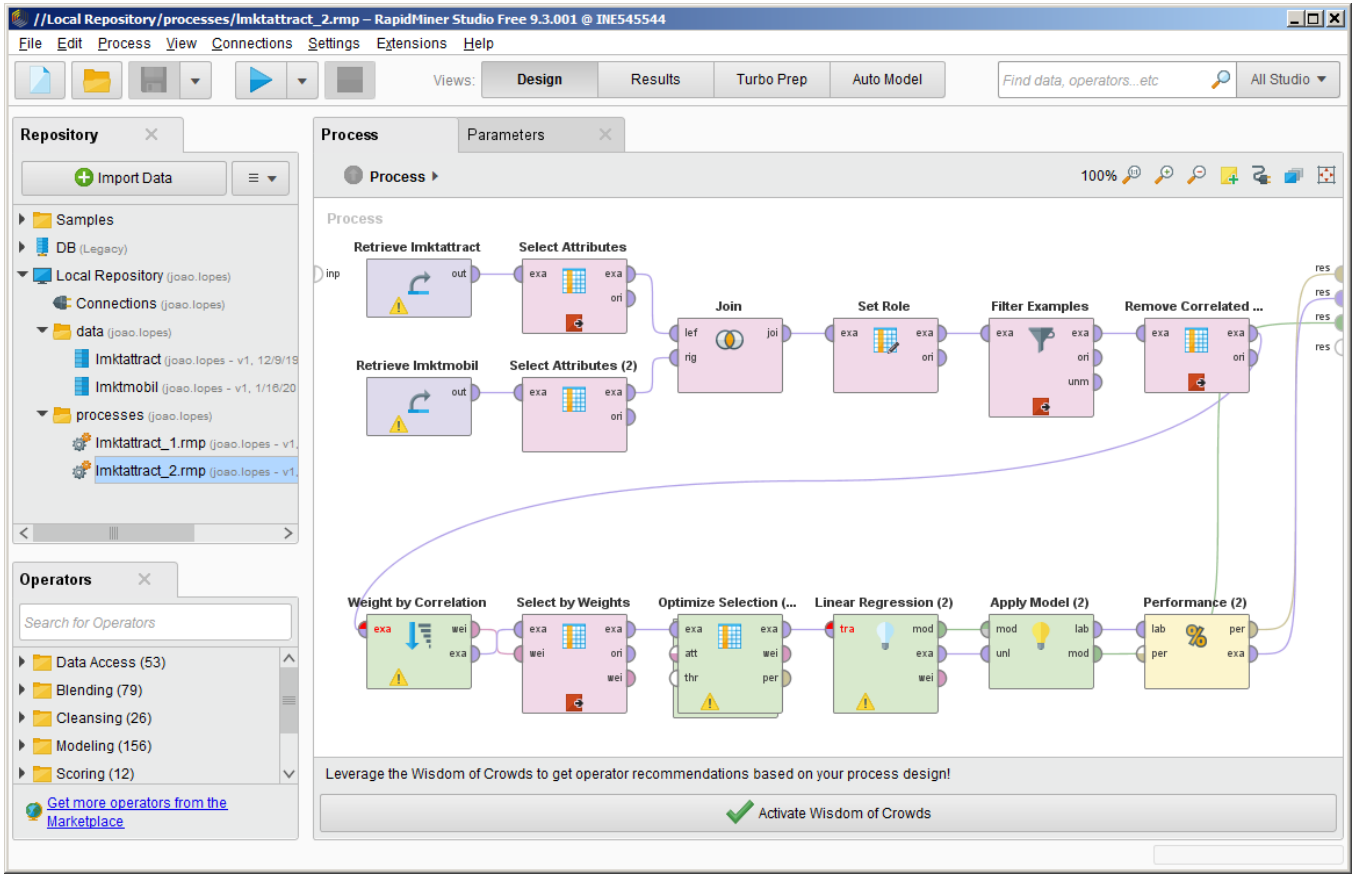

Exemplos *Data Analytics*

» Relação entre indicadores (no **R**)

```
#1. FUNCTIONS
source("misc_v2.3.r")

#2. READ DATA
f1 <- "../data/lmktattract.csv"
f2 <- "../data/lmktmobil.csv"
x_all <- read.table(file=f1,header=TRUE,sep=",",dec=".",row.names=1)
y_all <- read.table(file=f2,header=TRUE,sep=",",dec=".",row.names=1)

# 3. ANALYSE DATA
set.seed(12345)

#remove attributes with missing data
ina <- apply(x_all,2,function(x){any(is.na(x))})
x <- x_all[,!ina]
```

Exemplos *Data Analytics*

```
#remove data entries with missing data
y <- y_all[,"lmktm_Total",drop=FALSE]
ina <- is.na(y[,1])
x <- x[!ina,]
y <- y[!ina,,drop=FALSE]

#reduce number of attributes
f1 <- "../results/lmktattract_2/datred.log"
x <- reduce_predictors_v2(x,y[,1],
  thr1=0.90,          #upper threshold for correlation between predictors
  method="pearson",   #type of correlation
  thr2=NULL,          #lower threshold for correlation between predictors and response
  thr3=0.00,          #lower threshold for coefficient of variation
  thr4=Inf,           #upper threshold for Variance Inflation Factor (VIF)
  maxsize=30,         #maximum number of predictors
  f1=f1)
```

Exemplos *Data Analytics*

```
#perform GA
f1 <- "../results/lmktattract_2/modsel"
mod1 <- mod_select_lm_v2(x,y,
  maxs1=10,          #maximum number of attributes
  popsize = 100,     #population size
  mutrate = 0.001,   #per locus (i.e. per term) mutation rate, [0,1]
  sexrate = 0.1,     #sexual reproduction rate, [0,1]
  imm = 0.0,         #immigration rate, [0,1]
  deltaM=1e-6,       #Stop Rule: change in mean IC
  deltaB=1e-6,       #Stop Rule: change in best IC
  conseq = 5,        #Stop Rule: times with no improvement
  nreps = 4,         #number of repeats
  f1=f1)

#fit best model
f1 <- "../results/lmktattract_2/fit"
fit_lm(mod1$formula,mod1$data,f1=f1,main="LMkt Mobility")
```

Exemplos *Data Analytics*

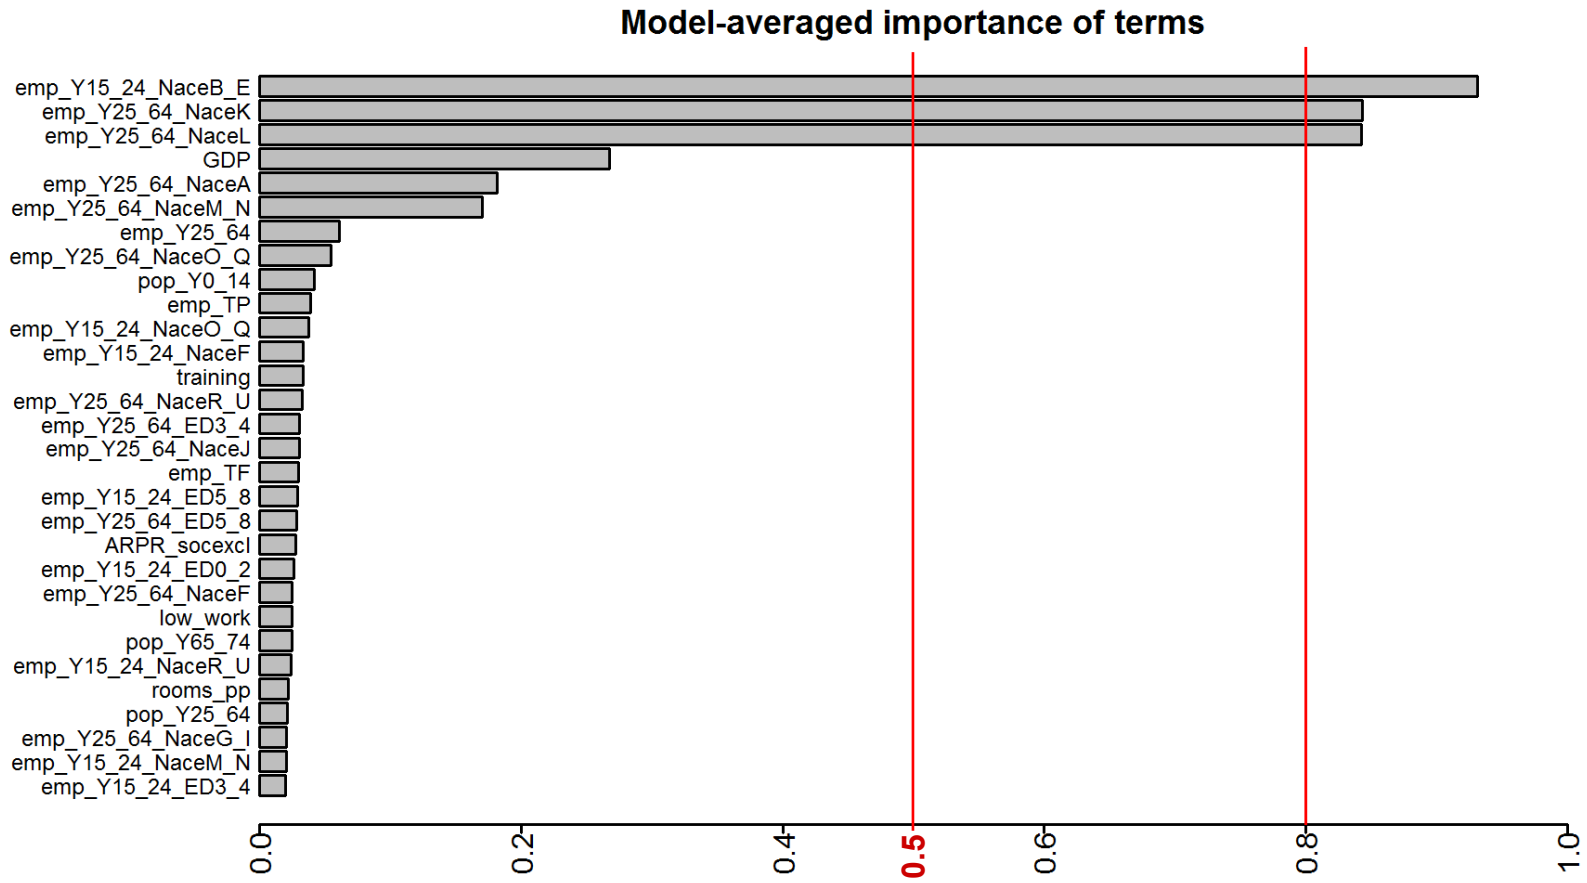

Exemplos *Data Analytics*

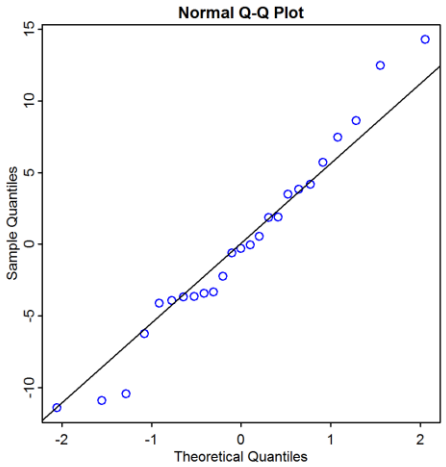

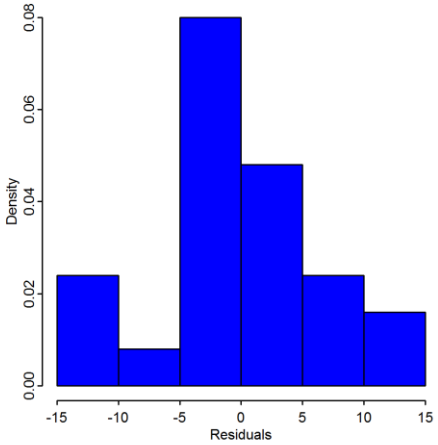

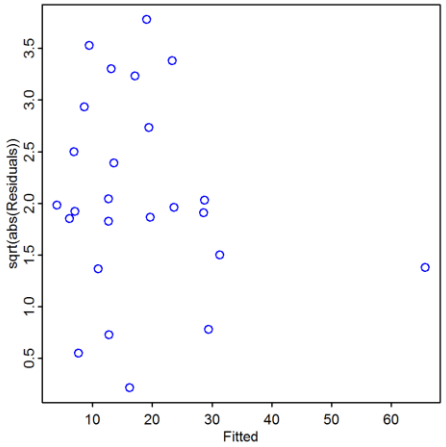

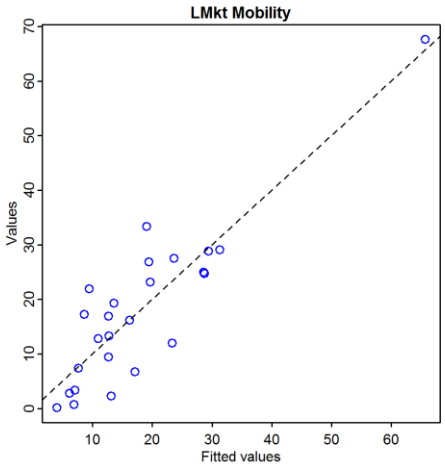

labels	value	st. err.	t value	Pr(>|t|)
(Intercept)	1.82	6.196	0.294	0.772
emp_Y15-24_NaceB-E	-0.38	0.198	-1.929	0.067
emp_Y25-64_NaceK	4.61	0.711	6.474	<0.001
emp_Y25-64_NaceL	10.04	2.832	3.474	<0.001

Adjusted-R^2 = 0.76; F(3, 21) = 25.85; p-value < 0.001.

Exemplos *Data Analytics*

» Relação não-linear entre indicadores (no **R**)

```
#1. FUNCTIONS
source("misc_v2.3.r")

#2. ANALYSE DATA
set.seed(12345)
decay <- 1e-4                          #parameter for weight decay
maxit <- 1000                          #maximum number of iterations
abstol <- 1e-6                         #absolute fit criterion
reltol <- 1e-12                        #relative fit criterion

#fit best model (nn size = 1)
size <- 1                              #number of units in the hidden layer
f1 <- "../results/lmktattract_3/fit_nnet1"
fit_nnet_v2(mod1$formula,mod1$data,nn_size=size,nn_decay=decay,nn_maxit=maxit,
  nn_abstol=abstol,nn_reltol=reltol,f1=f1,main="LMkt Mobility")
```

Exemplos *Data Analytics*

```
#fit best model (nn size = 3)
size <- 3                                  #number of units in the hidden layer
f1 <- "../results/lmktattract_3/fit_nnet3"
fit_nnet_v2(mod1$formula,mod1$data,nn_size=size,nn_decay=decay,nn_maxit=maxit,
  nn_abstol=abstol,nn_reltol=reltol,f1=f1,main="LMkt Mobility")

#fit best model (nn size = 10)
size <- 10                                 #number of units in the hidden layer
f1 <- "../results/lmktattract_3/fit_nnet10"
fit_nnet_v2(mod1$formula,mod1$data,nn_size=size,nn_decay=decay,nn_maxit=maxit,
  nn_abstol=abstol,nn_reltol=reltol,f1=f1,main="LMkt Mobility")
```

Exemplos *Data Analytics*

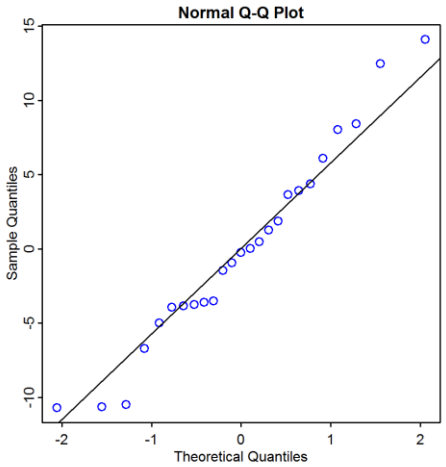

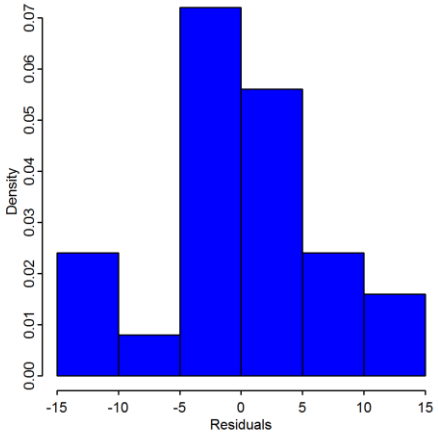

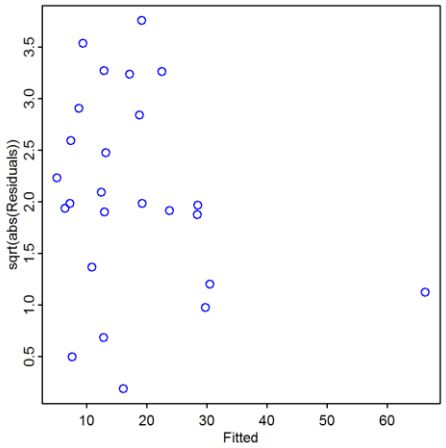

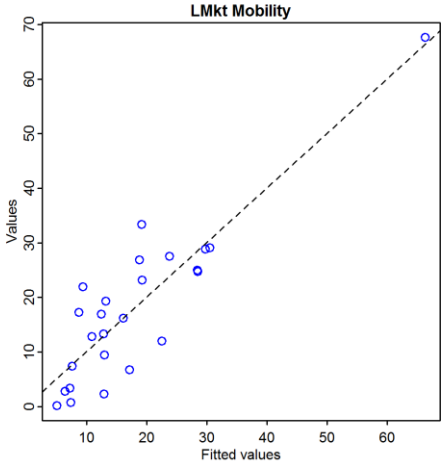

labels	Importance (Olsen, 2004)
emp_Y15-24_NaceB-E	-0.027
emp_Y25-64_NaceK	0.287
emp_Y25-64_NaceL	0.677

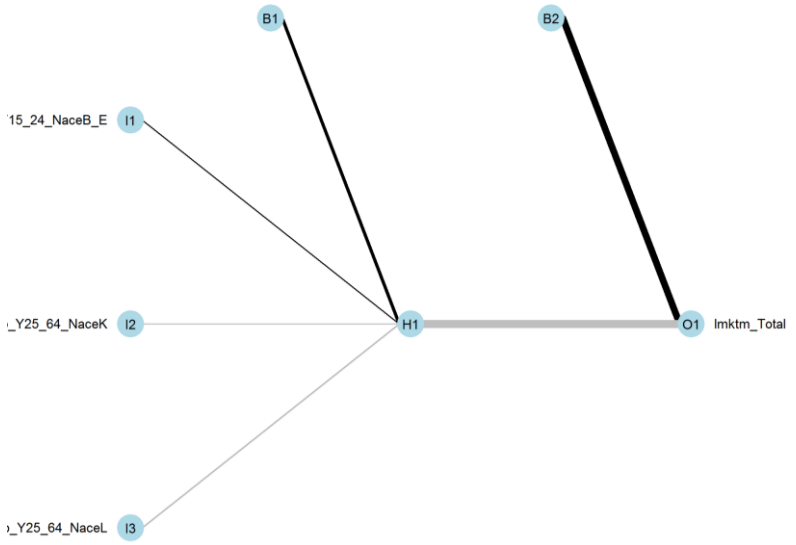

Exemplos *Data Analytics*

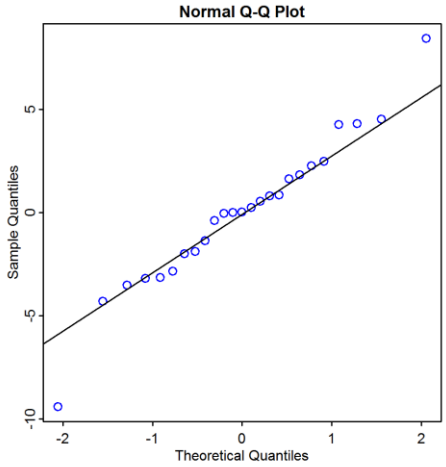

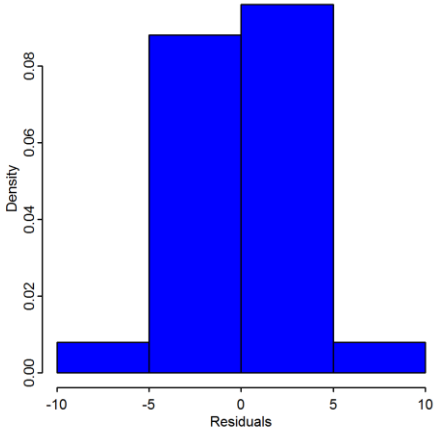

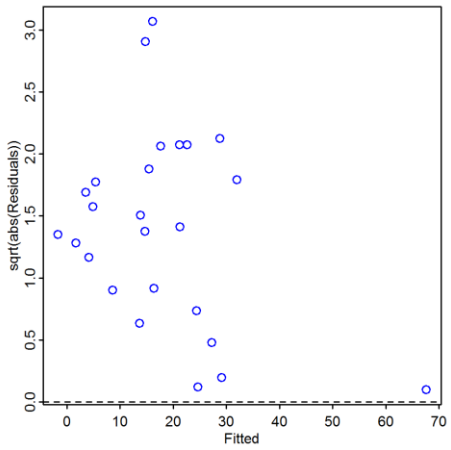

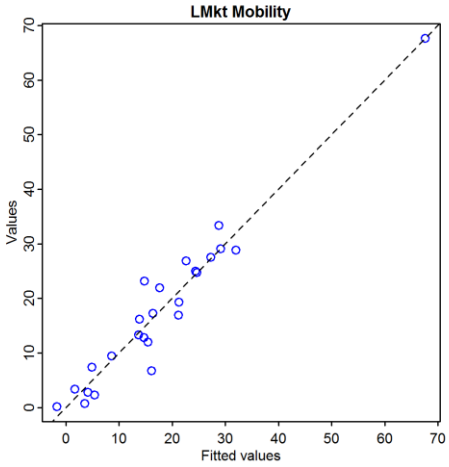

labels	Importance (Olsen, 2004)
emp_Y15-24_NaceB-E	-1.072
emp_Y25-64_NaceK	2.579
emp_Y25-64_NaceL	3.283

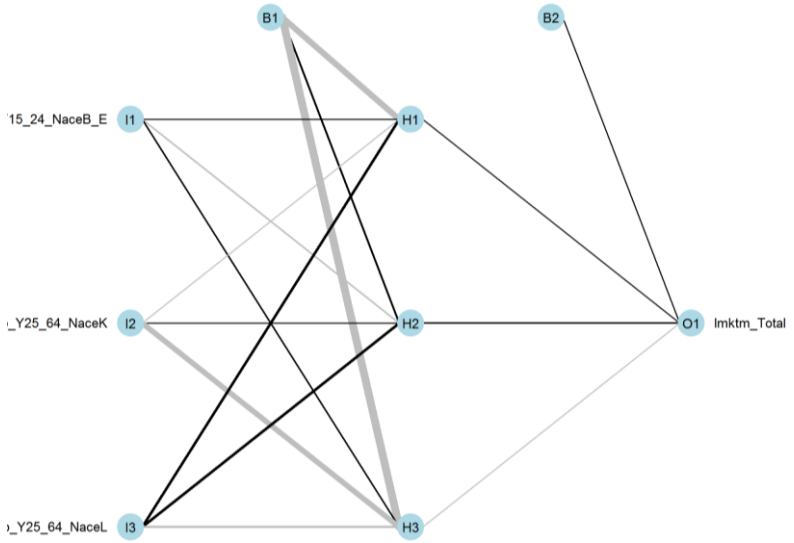

Exemplos *Data Analytics*

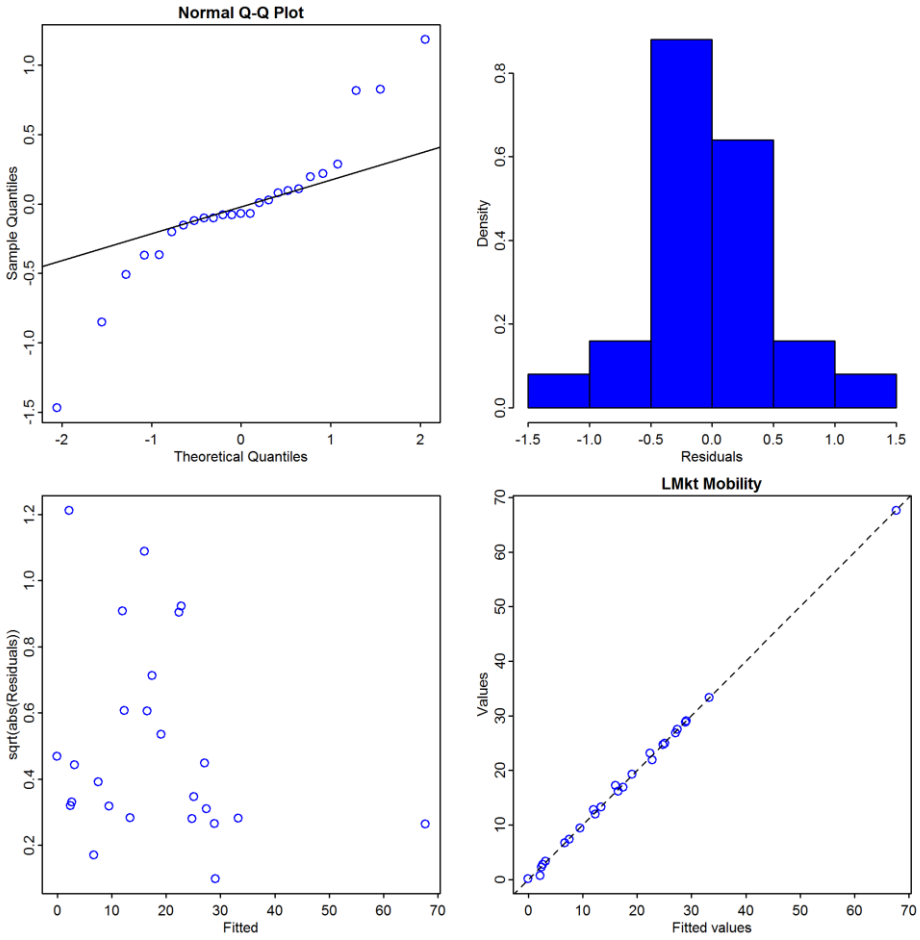

labels	Importance (Olsen, 2004)
emp_Y15-24_NaceB-E	0.440
emp_Y25-64_NaceK	-5.776
emp_Y25-64_NaceL	2.041

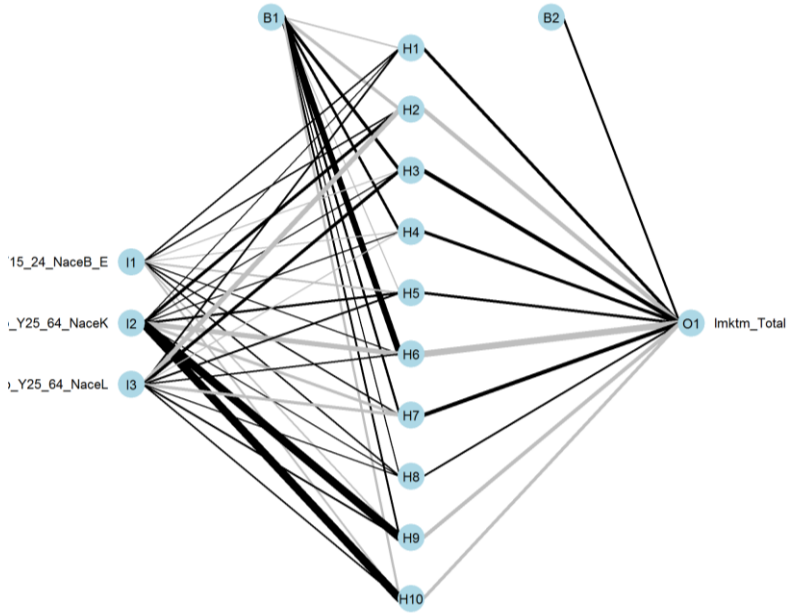

Gestão de projectos

» Boas práticas

- Estrutura de pastas;
- Nomes de ficheiros informativos;
- Nomes de ficheiros incluem data da versão;
- Nomes de ficheiros sem espaços nem sinais diacríticos;
- Ficheiro README.

Gestão de projectos

» Estrutura de pastas

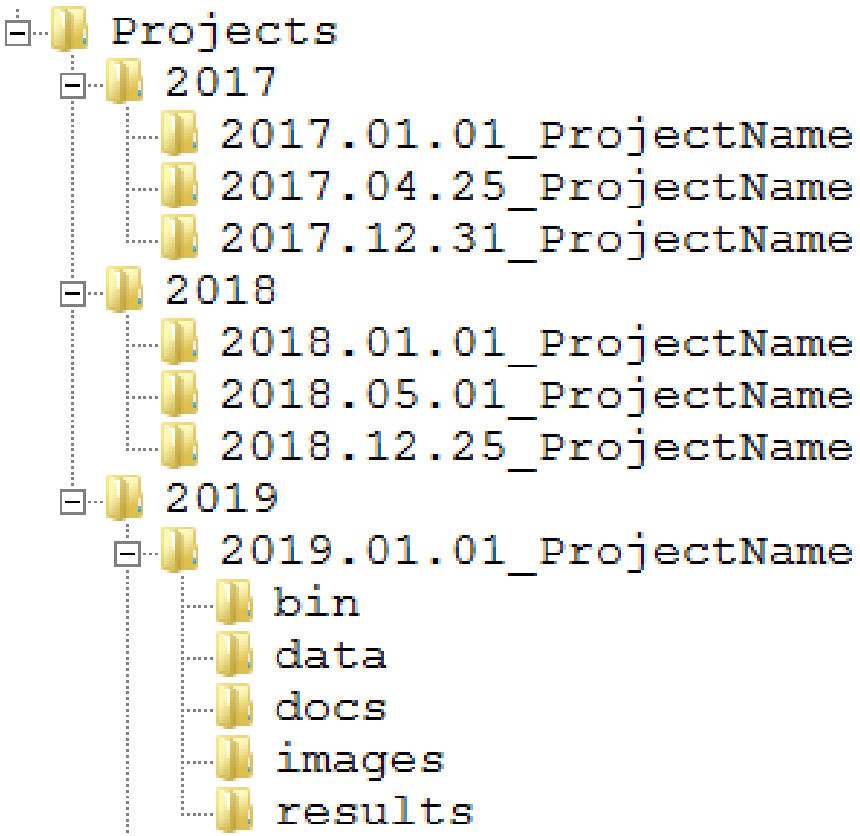

Gestão de projectos

» Ficheiro README

```
#autor:      Joao Sollari Lopes
#local:      INE, Lisboa
#criado:     03.12.2019
#modificado: 16.01.2020

+bin
  |decision_rule.r                    #aplicar regras de decisao
  |...
+data
  |...
+docs
  |...
  |DAA2019_JL_slides_20191126.pptx    #exercicios [v2019-11-26]
  |DAA2019_JL_slides_20191217.pptx    #exercicios [v2019-12-17]
  |...
+imagens
+results
  +lmktattract_1                      #resultados da aplicacao pratica 1
  +lmktattract_2                      #resultados da aplicacao pratica 2
  +lmktattract_3                      #resultados da aplicacao pratica 3
README.txt                            #Este ficheiro
```

Bibliografia

» Azzalini A & Scarpa B (2012) Data Analysis and Data Mining - An Introduction. Oxford University Press, New York.

» Due KL & Swamy MNS (2016) Search and Optimization by Metaheuristics - Techniques and Algorithms Inspired by Nature. Springer, Switzerland.

» Gama J, Carvalho APL, Faceli K, Lorena AC e Oliveira M (2017) Extração de Conhecimento de Dados. *Data Mining*. Edições Sílabo. Lisboa.

» Larose DT & Larose CD (2014) Discovering Knowledge in Data – An Introduction to Data Mining. John Wiley & Sons, New Jersey.

» Torgo L, (2017) Data Mining with R – Learning with Case Studies. Taylor & Francis Group, New York.

» Wickham H & Grolemund G (2017) R for Data Science. O'Reilly Media Inc., Sevastopol.